
بسم الله الرحمن الرحيم

دانشگاه صنعتی اصفهان
دانشکده مهندسی برق و کامپیوتر

طراحی و پیاده‌سازی چارچوب دوقلوهای دیجیتال چندعاملی برای پایش، پیش‌بینی و تصمیم‌گیری هوشمند سامانه‌های صنعتی

پایان‌نامه کارشناسی ارشد مهندسی کامپیوتر - نرم‌افزار

نوید نصیری

استاد راهنما

دکتر مسعودرضا هاشمی

استاد مشاور

دکتر عارف کریمی افشار

۱۴۰۰

دانشگاه صنعتی اصفهان

دانشکده مهندسی برق و کامپیوتر

پایان‌نامه کارشناسی ارشد رشته مهندسی کامپیوتر – نرم‌افزار آقای نوید نصیری

تحت عنوان

طراحی و پیاده‌سازی چارچوب دوقلوهای دیجیتال چندعاملی برای پایش، پیش‌بینی و تصمیم‌گیری هوشمند سامانه‌های صنعتی

تشکر و قدردانی

سپاس خدایی را که با وجود ناتوانی آفریدگان در گزاردن حقش، باز الطاف محبت بی‌کرانش بر همه می‌تابد.

قدردان راهنمایی‌های ارزنده استاد گرانقدر جناب آقای دکتر مسعودرضا هاشمی و جناب آقای دکتر عارف کریمی افشار هستم که بدون شک پشتیبانی و راهنمایی‌هایشان روشنگر مسیر انجام پژوهش بود. همچنین قدردان پدر، مادر و همسرم هستم که در این مسیر به من دلگرمی و انگیزه دادند.

کلیه حقوق مالکیت مادی و معنوی مربوط به این پایان نامه متعلق به دانشگاه صنعتی اصفهان و پدیدآورندگان است. این حقوق توسط دانشگاه صنعتي اصفهان و بر اساس خط مشی مالکیت فکری این دانشگاه، ارزش‌گذاری و سهم بندي خواهد شد.
هر گونه بهره برداري از محتوا، نتایج یا اقدام براي تجاري‌سازي دستاوردهاي این پایان نامه تنها با مجوز کتبی دانشگاه صنعتی اصفهان امکان‌پذیر است.

تقدیم به

پدر و مادر عزیزم

مستحکم ترین پشتوانه و حامیانم در این مسیر

و همسرم

که وجودش منشأ آرامش و انگیزه من است...

فهرست مطالب

عنوان	صفحه
فهرست مطالب	نه
فهرست شکل‌ها	سیزده
فهرست جداول	پانزده
فهرست اختصارات	شانزده
چکیده	۱
فصل اول : مقدمه	**۲**
۱ - ۱ بیان مسئله و ضرورت پژوهش	۲
۱ - ۲ اهمیت پژوهش	۳
۱ - ۳ اهداف پژوهش	۴
۱ - ۴ محدودیت‌های پژوهش	۵
۱ - ۵ خلاصه فصول	۵
فصل دوم : بررسی ادبیات و مبانی نظری	**۸**
۲ - ۱ مفاهیم پایه	۸
۲ - ۱ - ۱ مقدمه	۸
۲ - ۱ - ۲ دوقلو دیجیتال	۸
۲ - ۱ - ۳ عامل‌های هوشمند	۱۱
۲ - ۱ - ۴ سیستم‌های چندعاملی	۱۲
۲ - ۱ - ۵ هوش مصنوعی در دوقلوی دیجیتال	۱۲
۲ - ۱ - ۶ دوقلوهای دیجیتال چندعاملی	۱۳
۲ - ۱ - ۷ مدل‌های زبانی بزرگ و دوقلوی دیجیتال	۱۳
۲ - ۲ مرور کارهای مرتبط	۱۳
۲ - ۲ - ۱ پژوهش‌های مرتبط با دوقلوهای دیجیتال	۱۳
۲ - ۲ - ۲ پژوهش‌های مرتبط با دوقلوهای دیجیتال چندعاملی	۱۵
۲ - ۲ - ۳ پژوهش‌های مرتبط با کاربرد مدل‌های زبانی بزرگ در دوقلوهای دیجیتال	۱۶
۲ - ۲ - ۴ پژوهش‌های مرتبط با مجموعه داده CMAPSS	۱۷
۲ - ۲ - ۵ تحلیل شکاف‌های پژوهشی و جمع‌بندی	۱۷

فصل سوم : روش‌شناسی و معماری پیشنهادی ۱۹
۳-۱ رویکرد کلی پژوهش ۱۹
۳-۲ معماری پیشنهادی دوقلوی دیجیتال چندعاملی ۲۲
۳-۲-۱ نمای کلی و اصول طراحی ۲۲
۳-۲-۲ لایه موجودیت ۲۴
۳-۲-۳ لایه جمع‌آوری داده ۲۵
۳-۲-۴ لایه ادغام ۲۵
۳-۲-۵ لایه عامل‌های دوقلوی دیجیتال ۲۶
۳-۲-۶ لایه عامل‌های کاربرد ۲۷
۳-۲-۷ جریان تعامل و قرارداد ارتباطی ۲۸
۳-۲-۸ فرایند تعامل کاربر، عامل زبانی و عامل پیش‌بینی عمر مفید باقیمانده ۲۹
۳-۳ مجموعه داده CMAPSS و آماده‌سازی داده ۳۲
۳-۳-۱ معرفی و ساختار مجموعه داده ۳۲
۳-۳-۲ تحلیل اکتشافی و انتخاب ویژگی ۳۳
۳-۳-۳ پیش‌پردازش و تشکیل دنباله‌های زمانی ۳۶
۳-۴ انطباق معماری پیشنهادی بر مسئله CMAPSS ۳۸
۳-۴-۱ نگاشت لایه‌ها به اجزای مسئله ۳۸
۳-۴-۲ عامل پیش‌بینی و اتصال آن به جریان داده ۴۰
۳-۴-۳ فرایند تعامل چندعاملی و دوقلوی دیجیتال ۴۲
۳-۵ روش ارزیابی طراحی‌شده ۴۲
۳-۵-۱ معیارهای کمی پیش‌بینی ۴۳
۳-۵-۲ ارزیابی جهت خطا ۴۴
۳-۵-۳ ارزیابی عملکرد سامانه چندعاملی ۴۴
۳-۵-۴ خطوط مبنا و مقایسه تجربی ۴۵
۳-۶ جمع‌بندی ۴۵

فصل چهارم : پیاده‌سازی ۴۸
۴-۱ مقدمه ۴۸
۴-۲ نمای کلی معماری پیاده‌سازی ۴۹
۴-۲-۱ پشته فناوری ۵۰
۴-۲-۲ راه‌اندازی سرویس‌ها ۵۱
۴-۳ روش استقرار سامانه ۵۲
۴-۴ عامل دوقلوی دیجیتال ۵۲
۴-۴-۱ نقش عامل در معماری ۵۲
۴-۴-۲ ساختار داخلی سرویس ۵۳

۴-۴-۳ رابط برنامه‌نویسی ۵۴
۴-۴-۴ محدودیت وضعیت درون‌حافظه‌ای ۵۴
۴-۵ عامل پیش‌بینی عمر مفید باقیمانده ۵۴
۴-۵-۱ معماری شبکه پیش‌بینی ۵۴
۴-۵-۲ پارامترهای آموزش ۵۵
۴-۵-۳ سرویس پیش‌بینی ۵۶
۴-۶ عامل تعامل زبانی ۵۷
۴-۶-۱ الگوی طراحی ۵۷
۴-۶-۲ فضای نیت و مسیرهای تصمیم ۵۸
۴-۶-۳ نقاط پایانی HTTP و پیکربندی ۵۹
۴-۶-۴ نمونه‌های عملیاتی ۶۰
۴-۷ عامل پایش شبه‌بی‌درنگ ۶۱
۴-۷-۱ شبیه‌سازی جریان زمانی ۶۱
۴-۷-۲ مؤلفه‌های پایش ۶۳
۴-۷-۳ رابط کاربری عامل پایش ۶۴
۴-۸ عامل تابلو وضعیت ۶۴
۴-۹ فرایندهای سرتاسری سامانه ۶۶
۴-۹-۱ فرایند اول: پرس‌وجوی وضعیت موتور ۶۶
۴-۹-۲ فرایند دوم: خاموش‌سازی موتورهای در خطر ۶۶
۴-۱۰جمع‌بندی ۶۷

فصل پنجم : ارزیابی و بحث **۶۸**

۵-۱ مقدمه ۶۸
۵-۲ راهبرد ارزیابی ۶۹
۵-۳ تنظیم آزمایش‌ها ۷۰
۵-۳-۱ مجموعه داده و پروتکل ارزیابی ۷۰
۵-۳-۲ مدل‌های مورد مقایسه ۷۱
۵-۴ ارزیابی مدل پیش‌بینی عمر مفید باقیمانده ۷۱
۵-۴-۱ معیارهای ارزیابی ۷۱
۵-۴-۲ نتایج کمی و مقایسه با ادبیات ۷۳
۵-۴-۳ تحلیل کم‌برآورد و انتخاب تابع زیان ۷۵
۵-۴-۴ مقایسه پیش‌بینی و مقدار واقعی ۷۵
۵-۵ جایگاه مدل LSTM در معماری پیشنهادی ۷۷
۵-۶ ارزیابی عامل تعامل زبانی ۷۷
۵-۶-۱ تفسیر خروجی پیش‌بینی توسط عامل زبانی ۷۸

۵-۶-۲ ارزیابی زمان پاسخ ۷۸
۵-۷ ارزیابی پایش و حلقه بسته تصمیم ۸۰
۵-۸ مقایسه با پژوهش‌های مرتبط ۸۱
۵-۹ مزیت‌های معماری پیشنهادی ۸۴
۵-۱۰محدودیت‌های پژوهش ۸۵
۵-۱۱جمع‌بندی ۸۶

فصل ششم : نتیجه‌گیری و پیشنهادها **۸۹**

۶-۱ مقدمه ۸۹
۶-۲ جمع‌بندی پژوهش ۹۰
۶-۳ نتیجه‌گیری ۹۱
۶-۴ پیشنهادهایی برای کارهای آینده ۹۲
واژه نامه انگلیسی به فارسی ۹۵
واژه نامه فارسی به انگلیسی ۹۹
مراجع ۱۰۳
چکیده انگلیسی ۱۰۸

فهرست شکل‌ها

۲-۱ ساختار مفهومی دوقلوی دیجیتال شامل حلقه داده و اطلاعات بین فضای فیزیکی و فضای دیجیتال [۱۶] ۹

۲-۲ تفاوت بین دوقلوی دیجیتال، سایه دیجیتال و مدل دیجیتال [۱۸] ۱۰

۳-۱ مسیر هفت مرحله‌ای پژوهش که پس از بررسی پژوهش‌های مرتبط، دو شاخه موازی می‌شود و انتخاب داده به همراه طراحی معماری پیش می‌رود. در شناسایی شکاف‌ها به هم می‌رسند و در نهایت ارزیابی صورت می‌گیرد. ۲۱

۳-۲ معماری پنج‌لایه پیشنهادی دوقلوهای دیجیتال چندعاملی؛ لایه‌های موجودیت، جمع‌آوری، ادغام، عامل‌های دوقلوی دیجیتال و عامل‌های کاربرد، جریان صعودی داده و جریان نزولی فرمان و بازخورد را تشکیل می‌دهند. ۲۴

۳-۳ دیاگرام توالی تعامل برای پاسخ‌گویی به پرسش «عمر مفید باقیمانده موتور k چیست؟»؛ درخواست از کاربر به عامل زبانی و سپس به عامل دوقلو و عامل پیش‌بینی منتقل می‌شود و نتیجه پس از به‌روزرسانی وضعیت دوقلو، به‌صورت پاسخ توضیح‌پذیر به کاربر بازمی‌گردد. ۳۰

۳-۴ نقشه همبستگی Pearson ویژگی‌ها و برچسب عمر مفید باقیمانده در داده آموزشی FD001 پس از حذف ستون‌های ثابت ۳۵

۴-۱ نمای کلی معماری پیاده‌سازی: پنج عامل سامانه، کاربر و جریان ارتباط میان آن‌ها ۵۰

۴-۲ ساختار داخلی عامل دوقلوی دیجیتال و ارتباط آن با داده‌های CMAPSS، عامل زبانی و رابط تابلو وضعیت . . ۵۳

۴-۳ ساختار Workflow عامل تعامل زبانی و مسیرهای اصلی پردازش درخواست ۵۸

۴-۴ نمای Workflow پیاده‌سازی‌شده در محیط Dify و انشعاب مسیرهای تصمیم بر اساس سوال کاربر ۵۸

۴-۵ نمونه پاسخ عامل زبانی در شاخه راهنما و معرفی قابلیت‌های سامانه ۶۰

۴-۶ نمونه پاسخ عامل زبانی برای پرس‌وجوی وضعیت موتور شماره ۲ و تبدیل خروجی عددی به روایت فارسی ساختاریافته ۶۱

۴-۷ گفتگوی کاربر با دستیار هوشمند دربارهٔ وضعیت موتور ۲۴ (RUL = ۴۱.۲۷ سیکل — وضعیت بحرانی) . . ۶۲

۴-۸ معماری عامل پایش شبه‌بی‌درنگ؛ بخش سمت چپ منطق پیشرفت زمان و فراخوانی API و بخش سمت راست رابط کارت‌محور پایش را نشان می‌دهد ۶۳

۴-۹ رابط عامل پایش پس از فعال شدن ناوگان؛ کارت‌های هشدار و بحرانی بر اساس مقدار RUL نمایش داده می‌شوند ۶۴

۴-۱۰ معماری عامل تابلو وضعیت و جریان یک‌طرفه اطلاعات از عامل دوقلو به رابط نمایش ۶۵

۴-۱۱ رابط کاربری عامل تابلو وضعیت و فیلترهای ALL، ONLINE و OFFLINE ۶۶

۵-۱ مقایسه مقادیر پیش‌بینی‌شده و واقعی RUL برای موتورهای آزمون ۷۶

۵-۲ توزیع زمان پاسخ عامل زبانی برای ۳۰ درخواست ۷۹

۵-۳ نمودار جعبه‌ای زمان پاسخ عامل زبانی ۷۹
۵-۴ رابط پایش پس از اجرای فرمان خاموش‌سازی موتورهای در معرض خطر ۸۱

فهرست جداول

۳-۱ مشخصات زیرمجموعه‌های مجموعه داده CMAPSS ۳۳
۳-۲ فرایند انتخاب ویژگی در زیرمجموعه FD001 . . . . . ۳۶
۳-۳ نگاشت لایه‌های معماری پیشنهادی به اجزای پیاده‌سازی در مسئله Commercial Modular Aero-Propulsion System Simulation (CMAPSS) ۳۹

۴-۱ پشته فناوری سامانه به تفکیک مؤلفه ۵۱
۴-۲ مشخصات سرویس‌های سامانه و پورت مورد استفاده ۵۱
۴-۳ ماتریس ارتباط میان سرویس‌های سامانه ۵۱
۴-۴ نقاط پایانی رابط برنامه‌نویسی عامل دوقلو ۵۴
۴-۵ معماری شبکه پیش‌بینی عمر مفید باقیمانده ۵۵
۴-۶ پارامترهای اصلی آموزش مدل پیش‌بینی ۵۶
۴-۷ نقاط پایانی عامل پیش‌بینی ۵۶
۴-۸ کلاس‌های نیت و اقدام متناظر در عامل تعامل زبانی ۵۹
۴-۹ نقاط پایانی HTTP مورد استفاده در Workflow عامل زبانی ۵۹
۴-۱۰ متغیرهای محیطی اصلی عامل تعامل زبانی ۵۹
۴-۱۱ پارامترهای پیش‌فرض عامل پایش ۶۳

۵-۱ مشخصات مجموعه داده مورد استفاده در ارزیابی ۷۰
۵-۲ مشخصات مدل‌های مورد استفاده در ارزیابی ۷۱
۵-۳ مقایسه نتایج مدل‌های پژوهش حاضر با مدل LSTM گزارش‌شده در ادبیات ۷۳
۵-۴ فرایندهای ارزیابی عامل تعامل زبانی ۷۸
۵-۵ مقایسه قابلیت‌های پژوهش حاضر با پژوهش‌های پایه ۸۴

فهرست اختصارات

C

CMAPSS ..... Commercial Modular Aero-Propulsion System Simulation

G

GPT ..... Generative Pre-trained Transformer.

L

LSTM ..... Long Short-Term Memory

چکیده

با افزایش پیچیدگی تجهیزات صنعتی و هزینه‌های ناشی از توقف‌های پیش‌بینی‌نشده، توسعه سامانه‌هایی برای پایش پیوسته وضعیت، پیش‌بینی خرابی و اجرای تصمیم مناسب ضروری است. با وجود قابلیت دوقلوهای دیجیتال در اتصال دارایی‌های فیزیکی به بازنمایی‌های مجازی، یکپارچه‌سازی پیش‌بینی عمر مفید باقیمانده، پایش شبه‌بی‌درنگ، تعامل انسان و سامانه و تصمیم‌گیری ایمن در قالب معماری‌های توسعه‌پذیر همچنان یک چالش محسوب می‌شود. هدف این پژوهش، طراحی، پیاده‌سازی و ارزیابی یک چارچوب دوقلوی دیجیتال چندعاملی برای پایش و پیش‌بینی خرابی تجهیزات صنعتی با بهره‌گیری از یادگیری عمیق و مدل‌های زبانی بزرگ است. معماری پیشنهادی از پنج لایه موجودیت فیزیکی، گردآوری داده، یکپارچه‌سازی داده، عامل‌های دوقلوی دیجیتال و عامل‌های کاربردی تشکیل شده است. برای ارزیابی این چارچوب، دوقلوی دیجیتال موتورهای توربوفن بر پایه زیرمجموعه FD001 مجموعه‌داده CMAPSS ناسا توسعه یافته است. این زیرمجموعه شامل داده‌های ۱۰۰ موتور برای آموزش و ۱۰۰ موتور برای آزمون است. برای بررسی اثر تابع زیان بر رفتار پیش‌بینی، دو پیکربندی از یک معماری سه‌لایه مبتنی بر LSTM مورد ارزیابی قرار گرفتند. مدل پایه با تابع زیان MSE به مقدار RMSE برابر ۱۵٫۹۳ و MAE برابر ۱۱٫۹۵ دست یافت. در مدل دوم، تابع زیان نامتقارن Pinball با ضریب $\tau = 0.125$ به کار گرفته شد که مقدار RMSE برابر ۲۰٫۴۹ و MAE برابر ۱۴٫۷۲ را ایجاد کرد. با وجود افزایش خطای عددی، نسبت کم‌برآورد در این مدل از ۰٫۵۲ به ۰٫۷۱ افزایش یافت. این نتیجه نشان می‌دهد که تابع زیان نامتقارن توانسته است جهت خطای پیش‌بینی را به سمت کم‌برآورد تغییر دهد؛ هرچند این تغییر با افزایش خطای کلی همراه بوده است. عامل‌های مستقل پایش، پیش‌بینی، تابلو وضعیت و تعامل زبانی نیز برای به‌روزرسانی شبه‌بی‌درنگ وضعیت دوقلو، ارائه اطلاعات مورد نیاز و اجرای فرمان‌های عملیاتی از پیش تعریف‌شده پیاده‌سازی شدند. نتایج نشان می‌دهد که چارچوب پیشنهادی، بستری دارای اجزای مستقل، قابل تعویض و توسعه‌پذیر برای نگهداری و تعمیرات پیش‌بینانه ایمن، تعاملی و قابل انطباق با دارایی‌ها و داده‌های صنعتی دیگر فراهم می‌کند.

کلمات کلیدی: دوقلوی دیجیتال، سیستم چندعاملی، دوقلوهای دیجیتال چندعاملی، مدل زبانی بزرگ، نگهداری پیش‌بینانه، پیش‌بینی عمر مفید باقیمانده، LSTM، C-MAPSS ناسا، پایش بی‌درنگ، هوش مصنوعی توضیح‌پذیر.

فصل اول

مقدمه

۱-۱ بیان مسئله و ضرورت پژوهش

در صنایع بزرگ، عدم اطلاع دقیق از وضعیت سلامت و عمر مفید تجهیزات، ماشین‌آلات و دستگاه‌های صنعتی، یکی از عوامل اصلی بروز خرابی‌های ناگهانی و خسارت‌های سنگین اقتصادی محسوب می‌شود. خرابی‌های غیرمنتظره در سیستم‌های حیاتی، نه تنها عملیات تولید را مختل می‌سازد، بلکه موجب افزایش هزینه‌های نگهداری، کاهش بازدهی و تهدید ایمنی کارکنان و تجهیزات نیز می‌گردد. ریشه این مشکلات را می‌توان در رویکردهای سنتی نگهداری و تعمیر دانست که بر پایه بازه‌های زمانی ثابت و بدون در نظر گرفتن شرایط واقعی تجهیزات انجام می‌شوند [۱].

دستگاه‌های صنعتی در کارخانه‌ها، نیروگاه‌ها، پالایشگاه‌ها و سامانه‌های حمل‌ونقل، معمولاً با عمر طراحی‌شده‌ای حدود ده سال تولید می‌شوند [۲]. با این حال، قرار گرفتن در معرض شرایط سخت کاری، بارگذاری‌های غیرمتعارف، تغییرات دمایی، خوردگی و فرسودگی، منجر به کاهش عمر مفید واقعی این تجهیزات می‌شود. طبق گزارش‌ها، نرخ خرابی تجهیزات صنعتی بین سال‌های ۲۰۱۰ تا ۲۰۱۸ حدود ۴۰ درصد افزایش یافته است [۳]. علاوه بر این، تنها یک روز توقف ناگهانی در فرآیند تولید می‌تواند هزینه‌ای معادل ۱۰۰,۰۰۰ تا ۲۰۰,۰۰۰ یورو برای سازمان به همراه داشته باشد [۴].

در چنین شرایطی، ضرورت پژوهش در زمینه روش‌های نوین نگهداری و پایش[1] هوشمند تجهیزات بیش از پیش احساس می‌شود. یکی از فناوری‌های پیشرو در این حوزه، مفهوم «دوقلوهای دیجیتال[2]» است که با ایجاد نسخه‌ای دیجیتال از سیستم‌های فیزیکی، امکان شبیه‌سازی، پیش‌بینی و تصمیم‌گیری بهینه را فراهم می‌آورد [۵]. دوقلوی دیجیتال با بهره‌گیری از داده‌های بی‌درنگ حسگرها و سامانه‌های کنترل، نمایشی پویا از وضعیت واقعی موجودیت فیزیکی ارائه می‌کند و با استفاده از مدل‌های تحلیلی و هوش مصنوعی، قادر است رفتار آینده سیستم را پیش‌بینی نماید [۶].

در سال‌های اخیر، با ترکیب دوقلوهای دیجیتال و یادگیری عمیق، امکان تحلیل داده‌های حجیم و پیچیده فراهم شده است. این ترکیب منجر به توسعه روش‌های پیش‌بینی خرابی، بهینه‌سازی عملکرد و تشخیص نابهنجاری‌های بی‌سابقه شده است [۷، ۸]. همچنین ادغام دوقلوهای دیجیتال با مدل‌های زبانی بزرگ[3] بُعد جدیدی از تعامل انسان و ماشین را ایجاد کرده است، به‌گونه‌ای که کاربران می‌توانند با زبان طبیعی با سامانه‌های صنعتی گفت‌وگو کرده و عملیات مختلفی مانند پایش، تحلیل وضعیت و کنترل فرآیندها را به‌صورت هوشمند انجام دهند [۹].

پژوهش حاضر با تمرکز بر «طراحی و پیاده‌سازی چارچوب دوقلوهای دیجیتال چندعاملی»، به دنبال توسعه یک معماری لایه‌ای و تعاملی است که در آن عامل‌ها، نقش‌های مختلفی نظیر جمع‌آوری داده، ادغام، پیش‌بینی، پایش و کنترل را ایفا می‌کنند. هدف این چارچوب، ارائه راه‌حلی جامع برای مدیریت هوشمند وضعیت تجهیزات صنعتی و پیشگیری از خرابی‌های ناگهانی با بهره‌گیری از فناوری‌های نوین یادگیری عمیق و مدل‌های زبانی بزرگ است.

۱-۲ اهمیت پژوهش

پایش مستمر و پیش‌بینی خرابی تجهیزات صنعتی، یکی از ارکان اصلی افزایش قابلیت اطمینان، ایمنی و بهره‌وری در صنایع مدرن است. اهمیت این حوزه در آن است که با شناسایی زودهنگام مشکلات، از بروز خرابی‌های پرهزینه و توقف‌های ناگهانی جلوگیری می‌شود و تصمیم‌گیری در خصوص تعمیر یا جایگزینی تجهیزات بر پایه داده و تحلیل دقیق صورت می‌گیرد.

رویکردهای نگهداری صنعتی را می‌توان به سه دسته کلی تقسیم کرد [۱]:

۱. **نگهداری واکنشی**: تعمیر تجهیزات پس از وقوع خرابی؛ این روش اگرچه ساده است، اما باعث توقف

[1] Monitoring
[2] Digital Twins
[3] Large Language Model

طولانی و هزینه‌های بالا می‌شود.

۲. **نگهداری پیشگیرانه**: انجام تعمیرات دوره‌ای در فواصل زمانی ثابت بدون توجه به وضعیت واقعی تجهیزات؛ که در بسیاری از موارد منجر به اتلاف منابع و تعویض زودهنگام قطعات می‌شود.

۳. **نگهداری پیش‌بینانه**: تحلیل مداوم داده‌های حسگرها و پیش‌بینی زمان خرابی بر اساس الگوهای واقعی عملکرد دستگاه؛ این رویکرد موجب کاهش هزینه‌ها، افزایش عمر تجهیزات و بهره‌وری بالاتر می‌شود [۱۰].

پژوهش حاضر با تمرکز بر نگهداری پیش‌بینانه مبتنی بر دوقلوهای دیجیتال، به دنبال ایجاد بستری است که از طریق آن بتوان وضعیت سلامت تجهیزات را در هر لحظه رصد کرد و بر اساس داده‌های واقعی و الگوریتم‌های یادگیری عمیق، وقوع خرابی‌ها را پیش از رخداد شناسایی نمود. استفاده از مدل‌های زبانی بزرگ نیز امکان تعامل ساده و انسانی با این سامانه را فراهم کرده و بهره‌وری عملیات‌های صنعتی را افزایش می‌دهد.

۱-۳ اهداف پژوهش

اهداف این پژوهش در دو سطح کلی و اختصاصی به شرح زیر است:

اهداف کلی

- طراحی و توسعه یک چارچوب چندعاملی برای دوقلوهای دیجیتال به منظور پیش‌بینی خرابی و پایش بی‌درنگ تجهیزات صنعتی.
- ایجاد تعامل هوشمند با دوقلوی دیجیتال از طریق مدل‌های زبانی بزرگ و زبان طبیعی.

اهداف اختصاصی

- پیاده‌سازی دوقلوی دیجیتال برای موتورهای جت با استفاده از مجموعه داده‌های شبیه‌سازی موتورهای جت CMAPSS ناسا.
- توسعه عامل پیش‌بینی خرابی مبتنی بر شبکه عصبی Long Short-Term Memory (LSTM).
- طراحی عامل پایش بی‌درنگ و عامل تعاملی مبتنی بر مدل‌های زبانی بزرگ.
- ارزیابی عملکرد چارچوب پیشنهادی از نظر دقت پیش‌بینی، کارایی و قابلیت تعامل.

۱-۴ محدودیت‌های پژوهش

- داده‌های استفاده‌شده در این پژوهش مربوط به مجموعه داده شبیه‌سازی‌شده CMAPSS ناسا است که گرچه یکی از معتبرترین منابع در حوزه پیش‌بینی خرابی موتورهای جت به‌شمار می‌رود، اما داده‌های آن مصنوعی بوده و از محیط واقعی جمع‌آوری نشده است [۱۱].
- به دلیل محدودیت دسترسی به داده‌های صنعتی واقعی، اعتبارسنجی نهایی سامانه در محیط صنعتی واقعی انجام نشده است.
- مدل‌های زبانی بزرگ مورد استفاده برای تعامل با دوقلوی دیجیتال، نیازمند تنظیم دقیق برای دامنه صنعتی خاص هستند و در نسخه فعلی به‌صورت عمومی مورد استفاده قرار گرفته‌اند.
- پیاده‌سازی بی‌درنگ در این پژوهش با استفاده از داده‌های شبیه‌سازی‌شده انجام شده و امکان استقرار واقعی نیازمند زیرساخت‌های خاص صنعتی است.

۱-۵ خلاصه فصول

ساختار این پایان‌نامه به گونه‌ای طراحی شده است که خواننده به‌صورت تدریجی از مفاهیم پایه تا پیاده‌سازی عملی و تحلیل نتایج، با مسیر پژوهش آشنا شود. بدین منظور، محتوای پایان‌نامه در پنج فصل تنظیم شده است که هر فصل نقش مشخصی در پیشبرد هدف کلی پژوهش دارد.

در **فصل نخست**، مسئله اصلی پژوهش و ضرورت پرداختن به آن در بستر صنایع مدرن تشریح می‌شود. این فصل با مرور چالش‌های موجود در زمینه نگهداری تجهیزات صنعتی و هزینه‌های ناشی از خرابی‌های ناگهانی آغاز می‌گردد و سپس اهمیت استفاده از فناوری‌های نوینی همچون دوقلوهای دیجیتال، سیستم‌های چندعاملی[1] و مدل‌های زبانی بزرگ در بهبود فرآیند نگهداری و تجهیزات بیان می‌شود. همچنین اهداف کلی و اختصاصی پژوهش، محدودیت‌های آن و ساختار کلی پایان‌نامه در این فصل معرفی می‌گردد تا مسیر پژوهش برای خواننده روشن شود.

در **فصل دوم**، مبانی نظری و ادبیات مرتبط مورد بررسی قرار گرفته است. ابتدا مفاهیم بنیادین دوقلوی دیجیتال، سیستم‌های چندعاملی، هوش مصنوعی، و یادگیری عمیق به تفصیل معرفی می‌شوند. سپس نحوه استفاده از شبکه‌های عصبی بازگشتی به‌ویژه LSTM در مدل‌سازی زمان‌محور و پیش‌بینی خرابی تجهیزات تشریح می‌گردد. در ادامه، نقش مدل‌های زبانی بزرگ در ایجاد تعامل هوشمند با دوقلوهای دیجیتال و تسهیل تصمیم‌گیری‌های

[1] Multi Agent System

مبتنی بر زبان طبیعی توضیح داده می‌شود. بخش پایانی این فصل نیز به مرور پژوهش‌های مرتبط با دوقلوهای دیجیتال، معماری‌های چندعاملی و مجموعه داده CMAPSS اختصاص دارد تا جایگاه پژوهش حاضر در میان مطالعات پیشین مشخص گردد.

در **فصل سوم**، روش‌شناسی پژوهش و معماری پیشنهادی ارائه می‌شود. این فصل چارچوب پنج‌لایه پیشنهادی را معرفی می‌کند که شامل لایه موجودیت[۱]، لایه جمع‌آوری داده[۲]، لایه ادغام[۳]، لایه عامل‌های دوقلوی دیجیتال[۴] و لایه عامل‌های کاربرد[۵] است. در این بخش، وظایف هر لایه، نحوه ارتباط بین عامل‌ها و سازوکار[۶] کلی تعامل میان اجزای مختلف سامانه تشریح می‌گردد. همچنین مجموعه داده CMAPSS ناسا به عنوان داده مبنا معرفی شده و فرآیندهای آماده‌سازی و پیش‌پردازش آن به تفصیل توضیح داده می‌شود. در پایان فصل، نحوه انطباق معماری پیشنهادی با این داده و نقش مدل‌های یادگیری عمیق و زبان طبیعی در آن بیان می‌گردد.

در **فصل چهارم**، به پیاده‌سازی عملی چارچوب پیشنهادی و آزمایش‌های انجام‌شده پرداخته می‌شود. ابتدا مراحل پیاده‌سازی و ابزارهای مورد استفاده در هر بخش تشریح شده و سپس عامل‌های مختلف سامانه شامل عامل دوقلوی دیجیتال، عامل پیش‌بینی خرابی مبتنی بر شبکه LSTM، عامل پایش بی‌درنگ و عامل تعاملی مبتنی بر مدل زبانی بزرگ به‌صورت گام‌به‌گام معرفی می‌شوند. در ادامه، نحوه شبیه‌سازی جریان داده زنده و برقراری ارتباط میان سرویس‌ها توضیح داده شده و در پایان، روش استقرار و اجرای هم‌زمان عامل‌ها در قالب یک سامانه چندعاملی ارائه می‌گردد.

در **فصل پنجم**، نتایج حاصل از آزمایش‌ها و ارزیابی عملکرد چارچوب پیشنهادی مورد تحلیل قرار می‌گیرد. در این فصل، دقت پیش‌بینی مدل LSTM، نمودارهای عملکرد، پاسخ‌های بی‌درنگ سامانه، و نمونه‌های تعاملی میان عامل‌های زبانی و دوقلوی دیجیتال بررسی می‌شوند. همچنین میزان بهبود نسبت به روش‌های موجود، هزینه‌های محاسباتی، زمان پاسخ و قابلیت اعتماد سامانه ارزیابی می‌گردد. در ادامه، محدودیت‌های پژوهش و چشم‌اندازهای توسعه آن مطرح شده و در پایان، نوآوری‌های اصلی پژوهش شامل طراحی معماری چندلایه، ادغام مدل‌های زبانی بزرگ با دوقلوهای دیجیتال و ارائه روش تحلیل سنسورهای مؤثر بر عمر مفید تجهیزات، به‌صورت جمع‌بندی ارائه می‌شود.

در مجموع، این پژوهش با ترکیب مفاهیم دوقلوهای دیجیتال، سیستم‌های چندعاملی، یادگیری عمیق و مدل‌های زبانی بزرگ، تلاش دارد چارچوبی نوآورانه برای مدیریت و پیش‌بینی وضعیت تجهیزات صنعتی ارائه دهد که

---

[1] Entity Layer
[2] Data Collection Layer
[3] Integration Layer
[4] Digital Twin Agents Layer
[5] Application Agents Layer
[6] Mechanism

نه‌تنها از بروز خرابی‌های ناگهانی جلوگیری کند، بلکه با فراهم کردن امکان تعامل هوشمند انسانی، گامی مهم در مسیر تحول دیجیتال صنایع بردارد.

فصل دوم

بررسی ادبیات و مبانی نظری

۲-۱ مفاهیم پایه

۲-۱-۱ مقدمه

در عصر تحول دیجیتال و صنعت ۵، مفاهیم جدیدی همچون دوقلوهای دیجیتال، عامل‌های هوشمند، سیستم‌های چندعاملی و مدل‌های زبانی بزرگ به عنوان عناصر کلیدی در تحول سامانه‌های هوشمند مطرح شده‌اند. این فصل به بررسی عمیق مبانی نظری این مفاهیم می‌پردازد تا چارچوبی برای پژوهش حاضر فراهم شود [۵، ۱۲، ۱۳].

۲-۱-۲ دوقلو دیجیتال

مفهوم دوقلو دیجیتال نخستین بار توسط گریوز (۲۰۰۳) در دانشگاه میشیگان مطرح شد و توسط ناسا برای مأموریت‌های فضایی توسعه یافت [۱۳]. دوقلوی دیجیتال مدلی مجازی از یک موجودیت فیزیکی است که با داده‌های بی‌درنگ در تعامل است و رفتار سیستم واقعی را شبیه‌سازی و پیش‌بینی می‌کند [۱۲، ۱۴، ۱۵].

به‌طور کلی، یک دوقلوی دیجیتال شامل سه مؤلفه اصلی است:

۱. موجودیت فیزیکی[1]: تجهیز یا فرآیند واقعی که در دنیای فیزیکی قرار دارد.

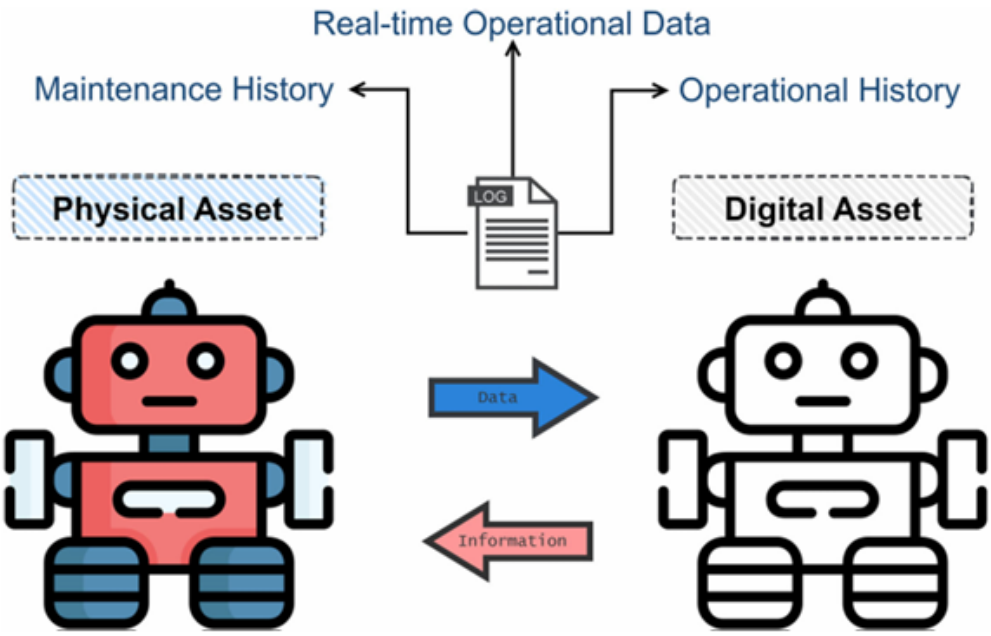
[1] Physical Entity

۲. مدل دیجیتال[1]: بازنمایی دیجیتال و محاسباتی از موجودیت فیزیکی.

۳. پیوند داده‌ای[2]: مسیر ارتباطی دوطرفه بین مدل و موجودیت برای تبادل داده دو طرفه.

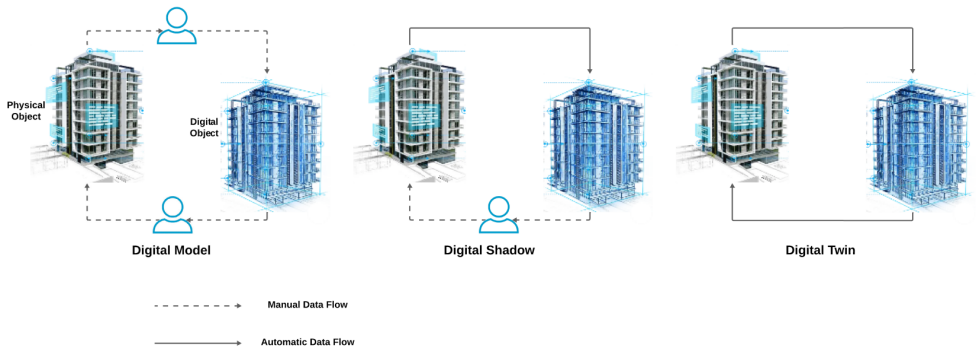
این سه مؤلفه را می‌توان در شکل ۲ - ۱ مشاهده کرد. همان‌طور که در شکل مشخص است، یک موجودیت فیزیکی در دنیای واقعی، دارای داده است. این داده‌ها به‌صورت بی‌درنگ برای دوقلوی دیجیتال خود در دنیای دیجیتال و غیر واقعی ارسال می‌شود. در دنیای دیجیتال امکان تحلیل و بررسی‌های گسترده‌ای روی این داده وجود دارد. پس از انجام این تحلیل و بررسی‌ها، اطلاعاتی فراهم می‌شود که می‌تواند در قالب فرمان‌های مناسب، به موجودیت فیزیکی در دنیای حقیقی، ارسال شود و تغییری روی آن رخ دهد [۱۶].

ارتباط بین موجودیت فیزیکی و دیجیتال، می‌تواند با استفاده از حسگرها و اینترنت اشیاء، انجام شود و مدل با استفاده از الگوریتم‌های مختلف هوش مصنوعی[3] از جمله یادگیری ماشین[4]، یادگیری عمیق[5] و یادگیری تقویتی[6]، وضعیت حال را بررسی کرده و رفتار آینده را پیش‌بینی کند [۵، ۱۷].



شکل ۲ - ۱: ساختار مفهومی دوقلوی دیجیتال شامل حلقه داده و اطلاعات بین فضای فیزیکی و فضای دیجیتال [۱۶]

[1] Digital Model
[2] Data Connection
[3] Artificial Intelligence
[4] Machine Learning
[5] Deep Learning
[6] Reinforcement Learning



شکل ۲-۲: تفاوت بین دوقلوی دیجیتال، سایه دیجیتال و مدل دیجیتال [۱۸]

بر اساس مرور جامع پژوهش‌های اخیر، یکی از چالش‌های اساسی در توسعه و پیاده‌سازی دوقلوهای دیجیتال، دشواری در یکپارچه‌سازی کامل تمامی لایه‌ها در یک سامانه واحد است. این مسئله به دلیل پیچیدگی زیاد در اتصال اجزای فیزیکی، داده‌ای و مجازی، به‌ویژه در سیستم‌های چندعاملی، از اهمیت بالایی برخوردار است [۱۳، ۱۸، ۱۹].

همان‌طور که در شکل ۲-۲ نشان داده شده است، به‌منظور توصیف سطوح مختلف بلوغ و یکپارچگی دوقلوهای دیجیتال، می‌توان آن را بر اساس میزان اتصال میان جهان فیزیکی و دیجیتال، به سه سطح اصلی تقسیم‌بندی کرد [۱۹، ۲۰]:

۱. مدل دیجیتال[1]: در این سطح، ارتباط میان سامانه فیزیکی و نسخه دیجیتال آن به‌صورت دستی انجام می‌شود. داده‌ها از دنیای واقعی به مدل دیجیتال از طریق ورود اطلاعات انسانی منتقل می‌گردند و هیچ‌گونه همگام‌سازی خودکار میان این دو وجود ندارد. هرگونه تغییر در سامانه فیزیکی باید به‌صورت دستی در مدل دیجیتال اعمال شود. بنابراین، در این سطح هنوز مفهوم واقعی دوقلوی دیجیتال تحقق نیافته است و تنها یک مدل ایستا از سامانه ارائه می‌شود [۵].

۲. سایه دیجیتال[2]: در این سطح، تعامل میان دنیای فیزیکی و مجازی به‌صورت یک‌طرفه[3] انجام می‌شود. به این معنا که تغییرات رخ‌داده در سامانه فیزیکی به‌طور خودکار در مدل دیجیتال بازتاب می‌یابد، اما برعکس آن ممکن نیست. در واقع، اطلاعات از دنیای واقعی به سمت فضای دیجیتال جریان دارد، اما هیچ تغییری از سوی مدل دیجیتال به دنیای فیزیکی منتقل نمی‌شود [۱۲، ۲۱]. این رویکرد در بسیاری از کاربردهای پایش و تحلیل وضعیت تجهیزات رایج است، زیرا به‌سادگی امکان ثبت و نمایش رفتار واقعی را فراهم می‌سازد.

[1] Digital Model
[2] Digital Shadow
[3] Unidirectional

۳. دوقلوی دیجیتال: در این لایه، ارتباط دوطرفه[1] میان دنیای فیزیکی و مدل دیجیتال برقرار است. تغییرات در هر یک از دو حوزه منجر به به‌روزرسانی خودکار دیگری می‌شود. این لایه موجب می‌شود تا مدل دیجیتال، بازنمایی دقیقی از وضعیت لحظه‌ای، تکامل و رفتار واقعی سامانه فیزیکی باشد [۱۸، ۲۰، ۲۲]. دوقلوی دیجیتال نه‌تنها برای پیش‌بینی خرابی و نگهداری پیش‌بینانه، بلکه برای کنترل، تصمیم‌سازی خودکار، و تعامل بی‌درنگ میان انسان و سامانه نیز کاربرد دارد. در واقع، این سطح از بلوغ، نقطه نهایی در مسیر تحقق دوقلوی دیجیتال محسوب می‌شود که مبنای طراحی چارچوب چندلایه این پژوهش نیز قرار گرفته است.

این طبقه‌بندی کمک می‌کند تا میزان پویایی و هوشمندی تعامل بین اجزای فیزیکی و مجازی را به‌صورت مرحله‌ای پیاده‌سازی و ارزیابی کرد. دوقلوی دیجیتال تنها یک مدل یا شبیه‌سازی ساده نیست، بلکه یک مدل زنده، هوشمند و در حال تکامل و توسعه است که به عنوان یک همتای دیجیتال در دنیای مجازی، برای موجودیت حقیقی ایجاد می‌شود.

۲-۱-۳ عامل‌های هوشمند

عامل هوشمند[2] موجودیتی نرم‌افزاری است که به‌صورت خودمختار عمل می‌کند، محیط را درک می‌کند و با تصمیم‌گیری مستقل اهداف خود را دنبال می‌کند [۲۳].

ویژگی‌های عامل هوشمند عبارت‌اند از:

- **خودمختاری**[3]: عملکرد بدون کنترل مستقیم انسان.
- **واکنش‌پذیری**[4]: توانایی پاسخ سریع به تغییرات محیطی.
- **پیش‌فعالی**[5]: اقدام آگاهانه برای دستیابی به اهداف.
- **اجتماع‌پذیری**[6]: توانایی تعامل و ارتباط با عامل‌ها و انسان‌ها.

علاوه‌بر ویژگی‌هایی که بیان شد، عامل‌ها می‌توانند بسته به کارکرد خود، ویژگی‌های دیگری نیز داشته باشند. همچنین بنابر عملکرد آن‌ها، ممکن است برخی از این ویژگی‌ها را دارا نباشد. پس هر عامل را می‌توان بر اساس این ویژگی‌ها بررسی کرد.

---
[1] Bidirectional
[2] Intelligent Agent
[3] Autonomy
[4] Reactivity
[5] Proactiveness
[6] Sociability

بررسی پژوهش‌های اخیر نشان می‌دهد عامل‌هایی که با مدل‌های زبانی بزرگ، ترکیب شده‌اند، نسل جدیدی از عامل‌های هوشمند تعاملی را ایجاد کرده‌اند که می‌توانند از طریق زبان طبیعی دستورات را پردازش و اجرا کنند [۲۴].

۲-۱-۴ سیستم‌های چندعاملی

سیستم‌های چندعاملی سیستم چندعاملی مجموعه‌ای از عامل‌های مستقل هستند که به‌صورت توزیع‌شده با یکدیگر همکاری می‌کنند تا مسئله‌ای پیچیده را حل کنند [۲۵، ۲۶].

مزایای اصلی سیستم چندعاملی عبارت‌اند از:

۱. افزایش مقیاس‌پذیری در مسائل صنعتی.

۲. تصمیم‌گیری غیرمتمرکز و خودمختار.

۳. قابلیت تعامل و مذاکره بین عامل‌ها.

در سیستم‌های چندعاملی می‌توان مسئله‌ها و وظیفه اصلی و بزرگ را به مسئله‌ها و وظیفه‌های کوچک‌تر تقسیم کرد و انجام هرکدام از آن‌ها را به عامل‌های جداگانه سپرد. با این کار می‌توان کارهای بزرگی که انجام آن‌ها توسط یک عامل بسیار سخت و پیچیده و هزینه‌بر است را به راحتی انجام داد [۲۵].

۲-۱-۵ هوش مصنوعی در دوقلوی دیجیتال

امروزه کمتر حوزه‌ای می‌توان یافت که در آن هوش مصنوعی دخالت نداشته باشد. در زمینه‌های مختلف، استفاده از روش‌ها و الگوریتم‌های هوش مصنوعی کاربرد فراوانی یافته است.

هوش مصنوعی در اوایل ظهور خود، با اینترنت اشیاء[1] پیوند خورد و محصولات تازه‌ای وارد بازار کرد. تعریف هوش مصنوعی اشیاء[2] از ترکیب فناوری هوش مصنوعی و اینترنت اشیاء ایجاد شده‌است. در گذشته دوقلوی دیجیتال و هوش مصنوعی دو مفهوم کاملا مجزایی دانسته می‌شدند اما امروزه با گسترش و تنوع چشم‌گیر حسگرها و همچنین پررنگ شدن اهمیت تحلیل داده و پاسخگویی و اقدام هوشمندانه و سریع بر اساس داده، قابل جدا سازی نیستند. هوش مصنوعی به عنوان بخشی از لایه‌های دوقلوی دیجیتال کاملا پذیرفته شده و در حال استفاده است. این موضوع را می‌توان در کاربردهای متنوع دوقلوهای دیجیتال مشاهده کرد.

دوقلوی دیجیتال به کمک هوش مصنوعی از داده‌های موجود در فرآیندها و موجودیت‌های واقعی، استفاده می‌کند تا بتواند تحلیل و پیش‌بینی‌های مورد نیاز را انجام دهد. این کارکرد نسبت به گذشته دوقلوی دیجیتال

[1] Internet of Things
[2] Artificial Intelligence of Things

که تنها یک شبیه‌سازی و نمایش سه‌بعدی از فرآیند بود، بسیار کاربردی‌تر و مهم‌تر است [۲۷]

۲-۱-۶ دوقلوهای دیجیتال چندعاملی

دوقلوهای دیجیتال چندعاملی[1] ترکیبی از دو فناوری سیستم‌های چندعاملی و دوقلوهای دیجیتال هستند که در آن هر دوقلو دیجیتال به عنوان یک عامل مستقل در محیط دیجیتال عمل می‌کند [۲۸، ۲۹]. این معماری به سیستم‌ها اجازه می‌دهد تا با تقسیم وظایف بین عامل‌های تخصصی، کارایی و سرعت تصمیم‌گیری را افزایش دهند.

در پژوهش‌های اخیر، از دوقلوهای چندعاملی برای پایش زنجیره تأمین، انرژی هوشمند و خطوط تولید استفاده شده است [۱۷].

۲-۱-۷ مدل‌های زبانی بزرگ و دوقلوی دیجیتال

مدل‌های زبانی بزرگ مدل‌های زبانی بزرگ مانند مدل‌های (GPT) .Generative Pre-trained Transformer[2] و Grok[3] توانایی درک و تولید زبان طبیعی را دارند و می‌توانند در دوقلوهای دیجیتال برای تحلیل معنایی داده‌ها و تعامل بین انسان و ماشین به کار روند [۳۲، ۳۳].

استفاده از ابزارهایی نظیر LangChain و Dify به عامل‌های دوقلوی دیجیتال امکان می‌دهد تا با زبان طبیعی دستورات دریافت کنند، توضیحات فنی ارائه دهند و حتی استدلال خود را بیان کنند [۲۴].

۲-۲ مرور کارهای مرتبط

۲-۲-۱ پژوهش‌های مرتبط با دوقلوهای دیجیتال

در سال‌های اخیر، پژوهش‌های متعددی به بررسی مفاهیم، معماری‌ها و کاربردهای دوقلوهای دیجیتال در صنایع مختلف پرداخته‌اند. در این بخش، پژوهش‌های مرتبط مرور شده‌اند تا چشم‌اندازی جامع از روند رشد و نوآوری‌های این حوزه ارائه شود.

در پژوهش وانگ، شو و ژانگ (۲۰۲۴) [۳۴] یک مرور جامع از توسعه فناوری دوقلوی دیجیتال در صنایع مختلف ارائه شده است. این پژوهش بر مدل‌سازی داده‌محور و استفاده از الگوریتم‌های یادگیری ماشین برای همگام‌سازی داده‌های فیزیکی و مجازی تمرکز دارد و به چالش‌های همگرایی داده در سیستم‌های ناهمگون اشاره می‌کند. نویسندگان یک چارچوب چهاربخشی برای پیاده‌سازی کارایی دوقلوهای دیجیتال معرفی کرده‌اند

---

[1] Multi Agent Digital Twins

[2] مانند GPT-4 و GPT-5، سیستم‌های هوش مصنوعی قدرتمندی از OpenAI هستند که برای درک و تولید متن شبیه به انسان طراحی شده‌اند و به عنوان ابزارهای همه‌کاره برای کدنویسی، نوشتن، خلاصه‌سازی و مکالمه عمل می‌کنند که همگی توسط یادگیری عمیق روی مجموعه داده‌های عظیم هدایت می‌شوند [۳۰].

[3] یک چت‌بات هوش مصنوعی و مدل زبان بزرگ از xAI است که به خاطر دسترسی بی‌درنگ به اطلاعات از سکو[4] X (توییتر) و استدلال پیشرفته شناخته می‌شود [۳۱].

که هدف آن کاهش تأخیر و افزایش دقت همگام‌سازی داده‌ها بین دنیای واقعی و مدل مجازی است. نوآوری اصلی این پژوهش، ارائه‌ی مدل ترکیبی داده‌محور برای بهبود کارایی در انتقال و تحلیل داده‌های صنعتی است.

در پژوهش ژو، لی و چن (۲۰۲۵) [۳۵] روند تحول دوقلوهای دیجیتال در صنعت نسل چهارم و پنجم[1] تحلیل شده است. این مطالعه، که بر داده‌های به‌دست‌آمده از ۴۳ شرکت بین‌المللی تکیه دارد، نشان می‌دهد استفاده از دوقلوهای دیجیتال در زمینه‌های نگهداری پیش‌بینانه، طراحی سیستم و مدیریت انرژی به‌صورت چشمگیری افزایش یافته است. نویسندگان، شاخصی با عنوان «شاخص بلوغ صنعتی[2]» را معرفی کرده‌اند که میزان آمادگی سازمان‌ها در پذیرش فناوری دوقلوی دیجیتال را اندازه‌گیری می‌کند. این شاخص برای نخستین بار به‌صورت کمی میزان نفوذ فناوری دوقلوی دیجیتال در صنایع را می‌سنجد.

گزارش صنعتی منتشرشده توسط شرکت ایرباس (۲۰۲۵) [۳۶] به تشریح پیاده‌سازی گسترده دوقلوهای دیجیتال در سامانه [۳۷] پرداخته است. در این سیستم بیش از ۱۲,۰۰۰ هواپیما از مدل‌های دوقلوی دیجیتال برای نظارت و نگهداری پیش‌بینانه استفاده می‌کنند. این گزارش نشان می‌دهد که استفاده از دوقلوی دیجیتال باعث کاهش زمان خرابی‌های برنامه‌ریزی‌نشده، بهبود بهره‌وری عملیاتی و افزایش ایمنی پروازها شده است. نوآوری کلیدی این پروژه، پیاده‌سازی دوقلو دیجیتال در مقیاس واقعی و استفاده از یادگیری ماشین برای تحلیل جریان داده‌های پروازی است.

در پژوهش آریدی، آریدی، بیگود و لمنان (۲۰۲۶) [۳۸] مبانی نظری و ارزش‌های عملی فناوری دوقلوهای دیجیتال در قالب یک مرور جامع بررسی شده است. نویسندگان با تحلیل ۱۴۶ مطالعهٔ علمی منتشرشده در پایگاه‌های معتبر، روند تحول دوقلوهای دیجیتال را از کاربردهای اولیه در تولید تا استفاده از آن‌ها در حوزه‌های چندرشته‌ای بررسی کرده‌اند. نتایج این مطالعه نشان می‌دهد که اگرچه بخش قابل‌توجهی از پژوهش‌ها بر ایجاد مدل‌های مجازی و همگام‌سازی آن‌ها با موجودیت فیزیکی تمرکز دارند، فاصلهٔ محسوسی میان توسعهٔ نظری و تحقق ارزش عملی دوقلوهای دیجیتال در محیط‌های واقعی وجود دارد. این پژوهش همچنین بر اهمیت فناوری‌های مکمل، از جمله زنجیرهٔ بلوکی، برای افزایش یکپارچگی داده، امنیت و قابلیت اعتماد در ارتباط میان بخش فیزیکی و مجازی تأکید می‌کند. نوآوری اصلی این مطالعه، ارائهٔ تصویری یکپارچه از مبانی نظری، کاربردهای عملی و موانع موجود برای ایجاد ارزش توسط دوقلوهای دیجیتال است.

در پژوهش بوانش و همکاران (۲۰۲۶) [۳۹] چارچوبی با عنوان Self-Learning Digital Twin برای بهینه‌سازی پیوستهٔ بهره‌وری انرژی در تجهیزات اینترنت اشیا ارائه شده است. در این چارچوب، دوقلوی دیجیتال با استفاده از سازوکارهای یادگیری مستمر، رفتار تجهیزات را از روی داده‌های عملیاتی تحلیل کرده و تنظیمات

[1] Industry4 and 5
[2] Industrial DT Adoption Index

مناسب را برای کاهش مصرف انرژی پیشنهاد می‌دهد. برخلاف معماری‌های ایستا که تنها وضعیت جاری تجهیز را بازنمایی می‌کنند، چارچوب پیشنهادی قابلیت سازگاری تدریجی با شرایط جدید و بهبود تصمیم‌های کنترلی را دارد. نوآوری اصلی این پژوهش، ترکیب دوقلوی دیجیتال با یادگیری خودکار و بهینه‌سازی مستمر در محیط‌های محدود از نظر منابع است. این یافته نشان می‌دهد که دوقلوهای دیجیتال می‌توانند از یک مدل صرفاً توصیفی به یک مؤلفهٔ تصمیم‌گیر و سازگارشونده در سامانه‌های هوشمند تبدیل شوند.

۲-۲-۲ پژوهش‌های مرتبط با دوقلوهای دیجیتال چندعاملی

در پژوهش [۱۶]، لوپز و همکاران (۲۰۲۴) چارچوبی با عنوان MADTwin برای توسعه دوقلوهای دیجیتال چندعاملی در محیط‌های انبارداری هوشمند ارائه کرده‌اند. در این چارچوب، هر عامل نمایانگر یک جزء فیزیکی (مانند ربات یا سامانه جابجایی کالا) است و با دوقلوی دیجیتال متناظر خود در محیط مجازی همگام می‌شود. این پژوهش بر مبنای فناوری‌های اینترنت اشیاء و سامانه‌های چندعاملی طراحی شده و امکان تعامل بی‌درنگ میان موجودیت‌های فیزیکی و دیجیتال را فراهم می‌کند. **نوآوری** ارائه‌ی چارچوبی مبتنی بر عامل با قابلیت خودسازماندهی برای بهینه‌سازی فرآیندهای حمل‌ونقل و تصمیم‌گیری توزیع‌شده در محیط‌های صنعتی پیچیده است.

در پژوهش [۴۰]، آلمیدا و همکاران (۲۰۲۵) به بررسی امکان ادغام سامانه‌های چندعاملی با دوقلوهای دیجیتال در حوزه مراقبت سلامت پرداخته‌اند. این پژوهش یک معماری ترکیبی برای نظارت بر بیماران و شبیه‌سازی رفتارهای بالینی ارائه می‌کند که در آن عامل‌ها نقش هماهنگ‌کننده تعامل بین داده‌های فیزیکی بیماران و مدل دیجیتال را بر عهده دارند.

در پژوهش گائو و همکاران (۲۰۲۶) [۴۱] چارچوبی برای ایجاد دوقلوهای دیجیتال خودتکامل‌یابنده در خطوط تولید انعطاف‌پذیر ارائه شده است. این چارچوب با استفاده از یک سامانهٔ چندعاملی مبتنی بر مدل زبان بزرگ، دوقلوی دیجیتال را در سه بُعد دانش، رفتار و هندسه تجزیه می‌کند و از یک گراف دانش تکامل‌یابنده برای به‌روزرسانی مدل مجازی بهره می‌گیرد. در معماری پیشنهادی، عامل‌ها وظایفی مانند تفسیر وضعیت خط تولید، هماهنگی عملیات، شناسایی خطا و پشتیبانی از تصمیم‌گیری را به‌صورت توزیع‌شده انجام می‌دهند. ارزیابی چارچوب در یک خط تولید شامل پایش عیب و دسته‌بندی قطعات نشان داده است که استفاده از این معماری می‌تواند زمان تغییر محصول و بازیابی خطا را کاهش دهد و نرخ هشدارهای نادرست را بهبود بخشد. نوآوری اصلی این پژوهش، ارائهٔ چارچوبی برای پیوند مدل‌های زبانی بزرگ با سامانه‌های چندعاملی و دوقلوهای دیجیتال خودتکامل‌یابنده است. چارچوبی که دوقلوی دیجیتال را از یک بازنمایی منفعل به یک سامانهٔ هماهنگ‌کننده و تصمیم‌گیر تبدیل می‌کند.

در مطالعه کولیبالی و همليش (۲۰۲۶) [۴۲] معماری‌ها، فناوری‌ها و چالش‌های باز مربوط به دوقلوهای دیجیتال مبتنی بر سامانه‌های چندعاملی برای نگهداشت پیش‌بینانه بررسی شده است. نویسندگان با انجام یک مرور نظام‌مند، یک رده‌بندی ساختاریافته از معماری‌های ترکیبی MAS–DT ارائه کرده و معماری سه‌لایه‌ای شامل لبه، مه و ابر را به‌عنوان یکی از مسیرهای مناسب برای استقرار توزیع‌شدهٔ این سامانه‌ها پیشنهاد داده‌اند. نتایج مطالعه نشان می‌دهد که سامانه‌های چندعاملی می‌توانند برای هماهنگی بین چند تجهیز، توزیع پردازش، تصمیم‌گیری محلی و مدیریت وضعیت دوقلوهای دیجیتال به کار گرفته شوند. بااین‌حال، محدودیت منابع سخت‌افزاری، نیاز به قراردادها[1]ی ارتباطی سبک، هماهنگی بین چند گره و تفسیرپذیری تصمیم‌ها همچنان از چالش‌های مهم این حوزه هستند. نویسندگان همچنین تخمین عمر باقیمانده، هوش مصنوعی قابل‌تفسیر و هماهنگ‌سازی[2] سلسله‌مراتبی دوقلوها را از مهم‌ترین مسیرهای پژوهشی آینده معرفی کرده‌اند. نوآوری این پژوهش در ارائهٔ یک چارچوب مفهومی منسجم برای ترکیب سامانه‌های چندعاملی و دوقلوهای دیجیتال در نگهداشت پیش‌بینانه و مشخص کردن فاصلهٔ موجود میان معماری‌های پژوهشی و سامانه‌های صنعتی قابل‌استقرار است.

۲-۲-۳ پژوهش‌های مرتبط با کاربرد مدل‌های زبانی بزرگ در دوقلوهای دیجیتال

پیژون، وویچیک و گولا (۲۰۲۶) در پژوهش [۳۲] چارچوبی مفهومی برای سامانه پشتیبان مدیریت تولید ارائه کرده‌اند که در آن مدل‌های زبانی بزرگ با دوقلوهای دیجیتال یکپارچه می‌شوند تا تعامل طبیعی کاربر با سامانه ممکن شود. این چارچوب با ایجاد یک دوقلوی دیجیتال هوشمند در نقش کارشناس تولید، به چالش پراکندگی داده‌ها پاسخ می‌دهد و امکان استدلال زمینه‌ای، تلفیق اطلاعات از منابع گوناگون و پشتیبانی بلادرنگ از تصمیم‌گیری را فراهم می‌آورد. نویسندگان نشان می‌دهند که بهره‌گیری از قابلیت‌های مدل‌های زبانی در تشخیص الگو، تحلیل پیش‌بینانه و تولید توصیه‌های خودکار می‌تواند مدیریت تولید را از حالت واکنشی به رویکردی فعال و پیش‌نگر سوق دهد.

در پژوهش [۴۳]، پاتل، سینگ و کومار (۲۰۲۴) به استفاده از ChatGPT در تحلیل بی‌درنگ داده‌های تولید پرداخته‌اند. نویسندگان نشان داده‌اند که مدل‌های زبانی می‌توانند وضعیت غیرعادی سیستم‌ها را تشخیص داده و هشدارهای متنی تولید کنند. نوآوری در «تعامل زبانی انسان–دوقلو دیجیتال» است که تجربه کاربری را به‌طور چشمگیری بهبود می‌بخشد.

[1] Protocol
[2] Orchestration

۲-۲-۴ پژوهش‌های مرتبط با مجموعه داده CMAPSS

در پژوهش [۴۴]، اسمیت، رائو و پاتل (۲۰۲۵) مدل‌های خطی برای پیش‌بینی عمر باقیمانده موتورهای جت توربینی[1] را با استفاده از داده‌های C-MAPSS ناسا بررسی کرده‌اند. نویسندگان نشان داده‌اند که مدل‌های خطی ساده در صورت هنجارسازی[2] مناسب، می‌توانند کارکرد قابل‌مقایسه‌ای با شبکه‌های عمیق داشته باشند. نوآوری آن‌ها در تحلیل اثر اختلال[3] سنجش و بهینه‌سازی وزن ویژگی‌ها است.

در پژوهش تانگ (۲۰۲۶) [۴۵] یک چارچوب یادگیری عمیق برای پیش‌بینی عمر باقیمانده موتورهای توربوفن در شرایط خرابی بخشی حسگرها ارائه شده است. نویسنده برای بازسازی پارامترهای ازدست‌رفته از یک مولد مبتنی بر شبکه مولد تخاصمی با گرادیان جریمه‌شده استفاده کرده و سپس خروجی بازسازی‌شده را به یک پیش‌بین ترکیبی CNN–LSTM برای تخمین عمر باقیمانده وارد کرده است. روش پیشنهادی با استفاده از مجموعه‌دادهٔ CMAPSS ارزیابی شده و هدف اصلی آن حفظ دقت پیش‌بینی در شرایطی است که بخشی از حسگرها دچار خرابی یا قطع داده شده‌اند. نتایج نشان می‌دهد که ترکیب بازسازی داده و مدل‌سازی هم‌زمان ویژگی‌های مکانی و زمانی می‌تواند نسبت به روش‌های پایه، پایداری بیشتری در برابر داده‌های ناقص ایجاد کند. نوآوری اصلی این پژوهش، طراحی یک چارچوب مقاوم برای پیش‌بینی عمر مفید باقیمانده[4] در شرایط خرابی حسگر و نزدیک کردن مسئلهٔ پیش‌بینی به شرایط واقعی سامانه‌های صنعتی است.

با وجود پیشرفت‌های یادشده، بیشتر این پژوهش‌ها فاقد چارچوبی جامع هستند که بتوانند تحلیل سری‌های زمانی را در سطح سیستم‌های چندعاملی و با تعامل هوشمند مدل‌های زبانی بزرگ، ترکیب کنند.

۲-۲-۵ تحلیل شکاف‌های پژوهشی و جمع‌بندی

بر اساس بررسی‌های انجام‌شده، چندین شکاف کلیدی در پژوهش‌های پیشین شناسایی می‌شود:

- بیشتر پژوهش‌های سیستم‌های چندعاملی و دوقلوهای دیجیتال فاقد قابلیت تفسیرپذیری تصمیمات و تعامل زبانی طبیعی با کاربران هستند.
- مطالعات مبتنی بر ترکیب مدل‌های زبانی بزرگ و دوقلوهای دیجیتال هنوز در مراحل اولیه‌اند و بیشتر بر تحلیل داده‌های متنی تمرکز دارند تا بر سیستم‌های صنعتی پویا.
- در حوزه پیش‌بینی عمر باقیمانده در مجموعه داده CMAPSS، مسئله کم برآورد کردن[5]، همچنان چالشی

[1] Turbofan
[2] Normalization
[3] Noise
[4] Remaining Useful Life
[5] Underestimate

مهم است که منجر به تصمیم‌های نادرست در نگهداری پیش‌بینانه می‌شود و اعتماد را به پیش‌بینی‌های انجام‌شده توسط هوش مصنوعی، غیرقابل اعتماد می‌کند.

- در حوزه پیش‌بینی عمر باقی مانده برای موتور جت توربینی در مجموعه‌داده CMAPSS ناسا، بیشتر پژوهش‌ها صرفاً بر بهبود دقت مدل‌های پیش‌بینی (مانند شبکه‌های LSTM) متمرکز بوده‌اند و به توضیح‌پذیری نتایج و تحلیل سهم هر حسگر در تصمیم نهایی مدل توجهی نکرده‌اند.

بنابراین، این پایان‌نامه با هدف پوشش این شکاف، چارچوبی پنج‌لایه برای ادغام سیستم‌های چندعاملی، دوقلوهای دیجیتال و مدل‌های زبانی بزرگ در تحلیل و پیش‌بینی مجموعه داده CMAPSS ارائه می‌دهد تا ضمن افزایش دقت پیش‌بینی، امکان تعامل هوشمند و تصمیم‌گیری توضیح‌پذیر را فراهم آورد.

فصل سوم

روش‌شناسی و معماری پیشنهادی

۳-۱ رویکرد کلی پژوهش

بررسی پژوهش‌های پیشین در فصل دوم نشان داد که حوزه پیش‌بینی عمر مفید باقیمانده و پایش تجهیزات صنعتی با چند شکاف بنیادین روبه‌روست. نبود چارچوبی یکپارچه که سیستم‌های چندعاملی، دوقلوهای دیجیتال و مدل‌های زبانی بزرگ را در یک معماری منسجم ترکیب کند؛ غفلت از توضیح‌پذیری نتایج پیش‌بینی و نقش حسگرهای مختلف در تصمیم مدل و بی‌توجهی به هزینه نامتقارن خطای بیش‌برآورد در نگهداری پیش‌بینانه[1]. این فصل پاسخ روش‌شناختی پژوهش حاضر به این شکاف‌ها را ارائه می‌دهد.

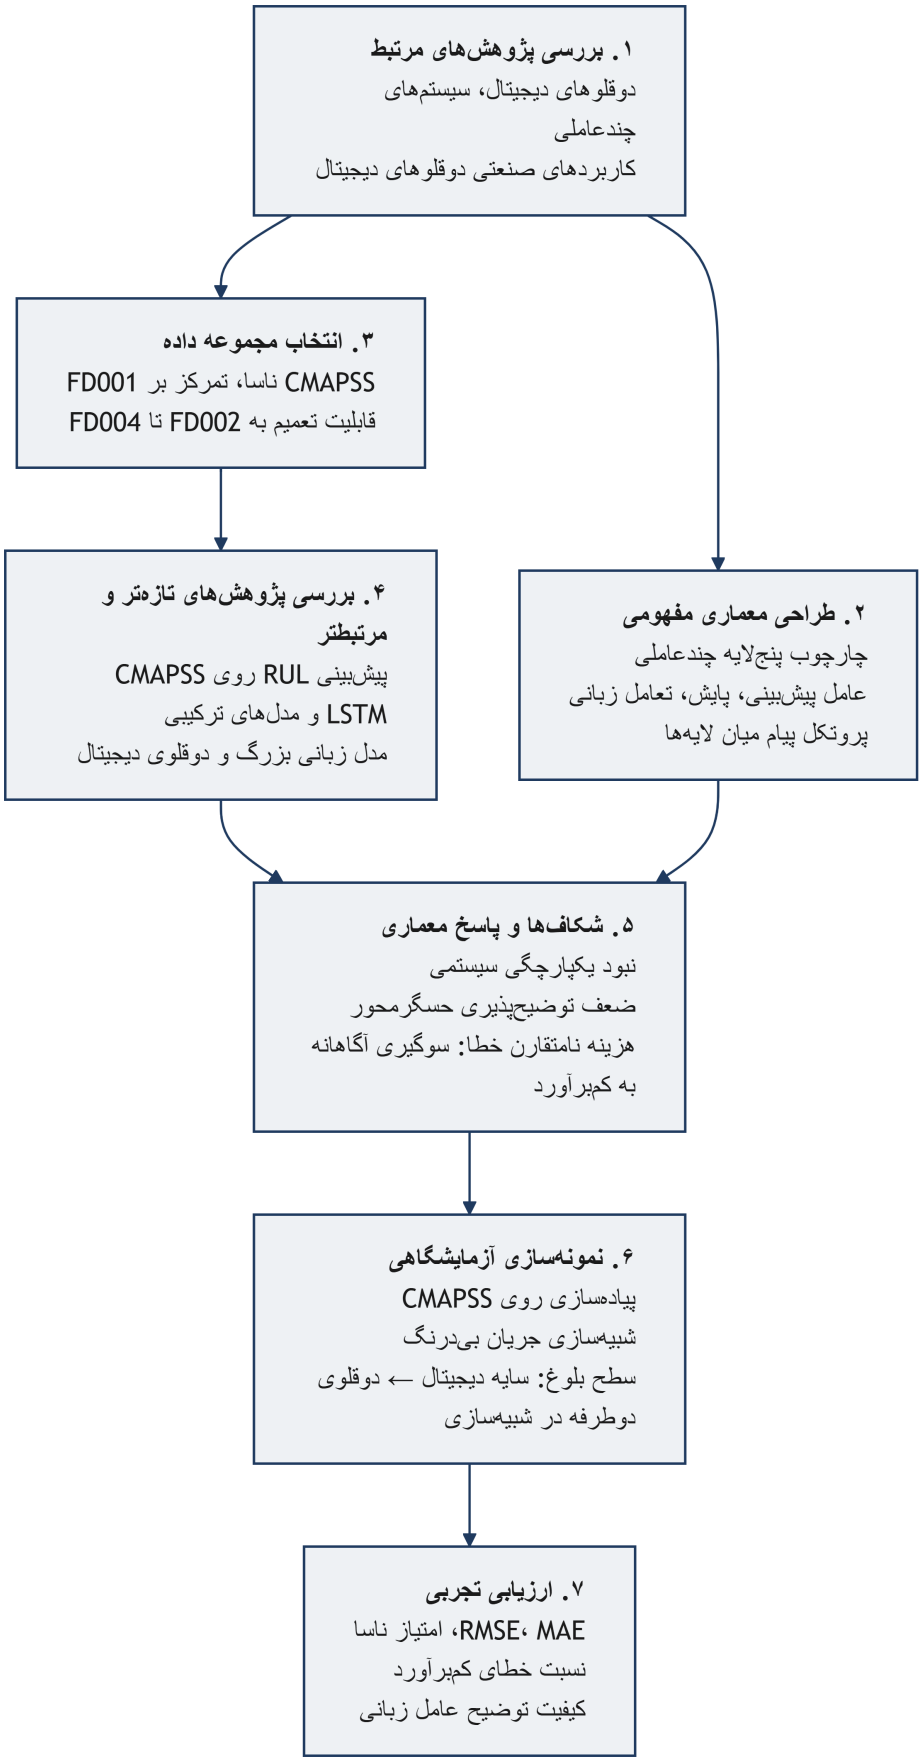
روش‌شناسی پژوهش حاضر به صورت خطی و یک مرحله‌ای نیست. پس از بررسی پژوهش‌های مرتبط در حوزه دوقلوی دیجیتال، سیستم‌های چندعاملی و کاربردهای صنعتی، کار در دو شاخه ادامه می‌یابد. شاخه نخست به انتخاب مجموعه داده CMAPSS و سپس مرور پژوهش‌های تازه‌تر — از جمله پیش‌بینی عمر مفید باقیمانده با LSTM و ادغام مدل زبانی بزرگ با دوقلوهای دیجیتال — می‌پردازد. شاخه دوم معماری پنج‌لایه چندعاملی را طراحی می‌کند. این دو شاخه در شناسایی شکاف‌ها به هم می‌رسند تا معماری پیشنهادی به مسائل موجود در شکاف‌های شناسایی شده پاسخ دهد. نبود سامانه و معماری یکپارچه دوقلوی دیجیتال، ضعف توضیح‌پذیری

[1] Predictive Maintenance

توسط حسگرها و هزینه نامتقارن خطا در پیش‌بینی مجموعه‌داده CMAPSS از جمله آن مسائل است. پس از آن، نمونه‌سازی آزمایشگاهی و ارزیابی تجربی انجام می‌شود. شکل ۳-۱ این مسیر هفت مرحله‌ای را نشان می‌دهد.

در سمت چپ شکل ۳-۱ ، انتخاب CMAPSS مرور ادبیات را به کارهای مسئله‌محور محدود می‌کند که شامل پژوهش‌های متنوع در زمینه این مجموعه داده است. در سمت راست، ادبیات پایه‌ای به طراحی مفهومی لایه‌ها، عامل‌ها و قرارداد تعامل می‌پردازد. نقطه تلاقی این دو شاخه مرحله شکاف‌هاست. معماری باید یکپارچگی چندعاملی، توضیح سهم حسگرها و سوگیری آگاهانه به کم‌برآورد را پوشش دهد. مرحله ششم این طراحی را روی داده شبیه‌سازی‌شده پیاده می‌کند و سطح بلوغ هدف را از سایه دیجیتال یک‌طرفه به دوقلوی دیجیتال با ارتباط دوطرفه در بستر شبیه‌سازی می‌رساند [۵]. مرحله پایانی معیارهای کمی پیش‌بینی، نسبت خطای کم‌برآورد و کیفیت توضیح عامل زبانی را ارائه می‌دهد.

در خصوص هزینه نامتقارن خطا، پژوهش حاضر رویکردی متمایز دارد. در نگهداری پیش‌بینانه، بیش‌برآورد عمر مفید باقیمانده — یعنی پیش‌بینی بیشتر از عمر واقعی تجهیز — می‌تواند باعث خرابی ناگهانی و ایجاد هزینه قابل توجه شود. در مقابل، کم‌برآورد عمر، اگرچه ممکن است بررسی تجهیز را زودتر از زمان واقعی، پیشنهاد دهد اما خطر خرابی را به‌شدت کاهش می‌دهد. بنابراین پژوهش حاضر تابع هزینه‌ای طراحی می‌کند که خطاها را آگاهانه به سمت کم‌برآورد سوق می‌دهد. به این معنا که اگر مدل در پیش‌بینی اشتباه کند، عمر باقیمانده را کمتر از واقعیت برآورد می‌کند، نه بیشتر. این انتخاب آگاهانه، یک انتخاب محافظه‌کارانه و ایمن در فرآیندهای صنعتی واقعی است.



شکل ۳-۱: مسیر هفت مرحله‌ای پژوهش که پس از بررسی پژوهش‌های مرتبط، دو شاخه موازی می‌شود و انتخاب داده به همراه طراحی معماری پیش می‌رود. در شناسایی شکاف‌ها به هم می‌رسند و در نهایت ارزیابی صورت می‌گیرد.

۳-۲ معماری پیشنهادی دوقلوی دیجیتال چندعاملی

۳-۲-۱ نمای کلی و اصول طراحی

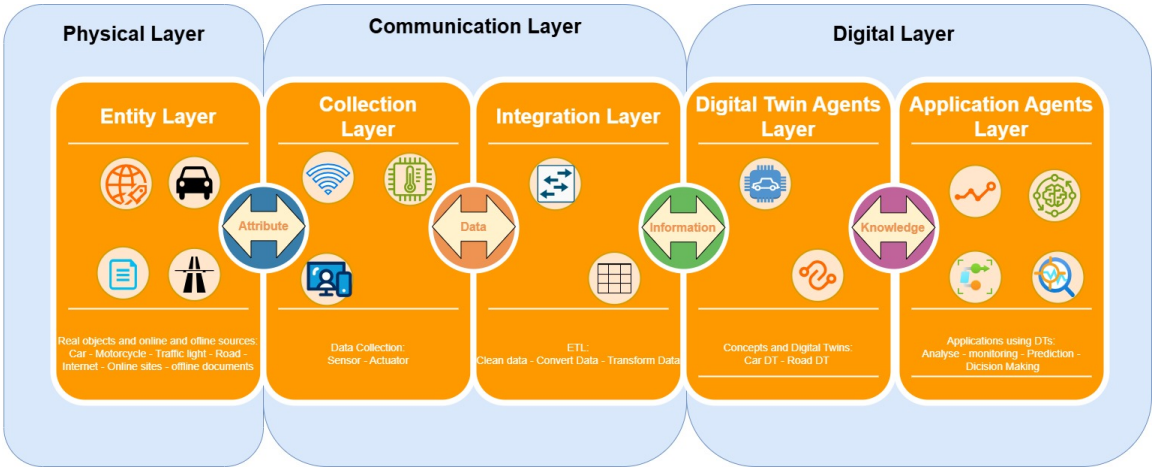
معماری پیشنهادی این پژوهش، یک چارچوب پنج‌لایه برای پیاده‌سازی دوقلوی دیجیتال چندعاملی در سامانه‌های پایش و نگهداری پیش‌بینانه است که با هدف ایجاد یک زنجیره یکپارچه از موجودیت فیزیکی تا تصمیم‌گیری سطح‌بالا طراحی شده است. ایده اصلی معماری آن است که داده‌های تولیدشده توسط موجودیت فیزیکی، پس از جمع‌آوری و آماده‌سازی، در یک لایه دیجیتال متشکل از عامل‌های دوقلوی دیجیتال بازنمایی شوند و سپس عامل‌های کاربردی بتوانند بر مبنای وضعیت جاری این دوقلوها، وظایفی نظیر پیش‌بینی عمر مفید باقیمانده، پایش وضعیت، تشخیص، زمان‌بندی نگهداری و تعامل زبانی با کاربر را انجام دهند. چنین تفکیکی با دیدگاه‌های کلاسیک درباره دوقلوی دیجیتال که بر پیوند دوسویه میان موجودیت فیزیکی و بازنمایی دیجیتال، همگام‌سازی وضعیت و استفاده از داده‌های بی‌درنگ تأکید دارند، سازگار است [۵، ۱۲، ۲۰، ۲۱]. در عین حال، استفاده از معماری چندعاملی امکان می‌دهد که پیچیدگی سامانه به مجموعه‌ای از واحدهای خودمختار اما هماهنگ تقسیم شود؛ به‌گونه‌ای که هر عامل مسئولیت مشخصی را بر عهده داشته باشد و از طریق قراردادهای ارتباطی تعریف‌شده با سایر عامل‌ها همکاری کند [۱۶، ۲۵، ۲۸، ۲۹].

معماری حاضر از پنج لایه اصلی شامل لایه موجودیت، لایه جمع‌آوری داده، لایه ادغام، لایه عامل‌های دوقلوی دیجیتال و لایه عامل‌های کاربرد تشکیل شده است. این پنج لایه را می‌توان در سه فضای مفهومی بزرگ‌تر نیز دسته‌بندی کرد: لایه موجودیت در فضای فیزیکی، لایه‌های جمع‌آوری و ادغام در فضای ارتباطی و دو لایه عامل‌های دوقلوی دیجیتال و عامل‌های کاربرد در فضای دیجیتال. این تفکیک با رویکردهای معماری دوقلوی دیجیتال که مرز میان موجودیت فیزیکی، جریان داده، مدل دیجیتال و خدمات کاربردی را مشخص می‌کنند هم‌راستا است [۵، ۲۱]. علاوه بر این، دوقلوهای دیجیتال مجهز به هوش مصنوعی در حال گذار از بازنمایی‌های صرفاً توصیفی به سامانه‌هایی هستند که قادر به پایش، پیش‌بینی، مداخله و در نهایت مدیریت خودکار می‌باشند. در این گذار، مدل‌های یادگیری ماشین و یادگیری عمیق، عامل‌های هوشمند و مدل‌های زبانی بزرگ می‌توانند در لایه‌های متفاوت چرخه عمر دوقلوی دیجیتال قرار گیرند [۴۶، ۴۷]. پس در معماری پیشنهادی، مدل زبان بزرگ به‌عنوان جایگزین مدل تخصصی پیش‌بینی عمر مفید باقیمانده در نظر گرفته نمی‌شود، بلکه در لایه کاربرد و تعامل به‌عنوان یک بخش استدلالی و زبانی مورد استفاده قرار می‌گیرد. این تفکیک سبب می‌شود که محاسبه عددی عمر مفید باقیمانده توسط یک مدل تخصصی و قابل ارزیابی مانند LSTM انجام شود و مدل زبان طبیعی بر روی وضعیت ساختاریافته تولیدشده توسط دوقلوی دیجیتال، وظایف تفسیر، ترکیب اطلاعات، پاسخ‌گویی و هدایت عامل‌ها را انجام دهد. چنین تفکیکی با جهت‌گیری پژوهش‌های جدید در زمینه

ادغام مدل‌های زبانی بزرگ و دوقلوهای دیجیتال نیز سازگار است که نقش مدل زبانی بزرگ را در تعامل، ساخت دانش، استدلال و ارائه خدمات سطح‌بالا تعریف می‌شود [۹، ۴۶، ۴۸].

سه اصل اساسی در طراحی این معماری عبارت‌اند از جداسازی مسئولیت‌ها، استقلال و همکاری عامل‌ها، و مقیاس‌پذیری. اصل نخست بیان می‌کند که دریافت داده، آماده‌سازی داده، نگهداری وضعیت دوقلوی دیجیتال، پیش‌بینی و تعامل با کاربر نباید در یک بخش واحد ادغام شوند؛ زیرا چنین ادغامی باعث افزایش وابستگی متقابل، دشواری آزمون و کاهش قابلیت جایگزینی اجزای سامانه می‌شود. در معماری پیشنهادی، لایه جمع‌آوری صرفاً مسئول دریافت داده است، لایه ادغام مسئول تبدیل داده خام به اطلاعات قابل استفاده، لایه عامل‌های دوقلوی دیجیتال مسئول نگهداری وضعیت دیجیتال موجودیت و لایه عامل‌های کاربرد مسئول ارائه خدمات هوشمند است. اصل دوم از مبانی سامانه‌های چندعاملی ناشی می‌شود. عامل‌ها باید بتوانند به‌صورت مستقل تصمیم‌های محلی خود را بگیرند، اما برای انجام وظایف پیچیده‌تر از طریق پیام‌های استاندارد با یکدیگر همکاری کنند [۲۵، ۲۸]. اصل سوم نیز تضمین می‌کند که افزایش تعداد موتورهای تحت پایش یا افزودن خدمات جدید، الزاماً نیازمند بازطراحی لایه‌های پایین‌تر نباشد. این ویژگی به‌خصوص در سامانه‌های دارای تعداد زیادی موجودیت فیزیکی اهمیت دارد و در چارچوب‌های دوقلوهای دیجیتال چندعاملی نیز به‌عنوان یکی از مزایای اصلی، تفکیک عامل‌ها مطرح شده است [۱۶، ۲۹].

شکل ۳-۲ نمای کلی معماری پنج‌لایه پیشنهادی را نشان می‌دهد. همان‌گونه که در شکل مشاهده می‌شود، جریان اصلی داده از موجودیت فیزیکی به سمت لایه‌های دیجیتال و کاربردی حرکت می‌کند، در حالی که درخواست‌ها، سیاست‌های کنترلی و فرمان‌های سطح‌بالا می‌توانند در جهت معکوس حرکت کنند. بنابراین، معماری ماهیتی دوطرفه دارد و دوقلوی دیجیتال صرفاً یک مخزن داده یا تصویر ایستا از تجهیز فیزیکی نیست بلکه واسطی برای ایجاد ارتباط میان وضعیت واقعی موجودیت، مدل دیجیتال، خدمات تحلیلی و تصمیم‌های سطح‌بالا محسوب می‌شود [۵، ۲۰، ۲۱].



شکل ۳-۲: معماری پنج‌لایه پیشنهادی دوقلوهای دیجیتال چندعاملی؛ لایه‌های موجودیت، جمع‌آوری، ادغام، عامل‌های دوقلوی دیجیتال و عامل‌های کاربرد، جریان صعودی داده و جریان نزولی فرمان و بازخورد را تشکیل می‌دهند.

۳-۲-۲ لایه موجودیت

لایه موجودیت پایین‌ترین لایه معماری و نقطه اتصال سامانه دیجیتال به جهان فیزیکی است. این لایه شامل تجهیز یا فرآیند واقعی مورد مطالعه، حسگرها، عملگرها و سایر مؤلفه‌هایی است که وضعیت فیزیکی سیستم را تعیین می‌کنند. در چارچوب دوقلوی دیجیتال، وجود این موجودیت فیزیکی به‌تنهایی کافی نیست، بلکه باید ارتباطی پایدار میان وضعیت آن و بازنمایی دیجیتال برقرار شود تا تغییرات موجودیت واقعی بتواند در مدل دیجیتال بازتاب شود و در صورت وجود مسیر کنترلی، تصمیم‌های حاصل از فضای دیجیتال نیز به موجودیت فیزیکی منتقل شوند [۵، ۱۲، ۲۰]. از این دید، لایه موجودیت را می‌توان منشأ تولید داده در سامانه دانست؛ زیرا داده‌های مربوط به چرخه کاری، وضعیت حسگرها و رویدادهای عملیاتی از همین لایه وارد زنجیره پردازش می‌شوند. در کاربرد مورد نظر این پژوهش، هر موتور هواپیما به‌عنوان یک موجودیت فیزیکی مستقل در نظر گرفته می‌شود و مجموعه‌ای از متغیرها و شاخص‌های آن موجودیت در طول چرخه‌های عملیاتی ثبت می‌گردد. این ساختار با نوع داده‌های CMAPSS نیز سازگار است؛ زیرا این مجموعه داده، توالی‌های چندمتغیره از وضعیت موتور را در چرخه‌های متوالی ارائه می‌کند و امکان مطالعه روند تخریب و برآورد عمر مفید باقیمانده را فراهم می‌سازد [۱۱].

در این لایه، مفهوم «دوقلو» نباید با صرفاً ذخیره‌سازی داده‌های شاخص‌ها اشتباه گرفته شود. مطابق ادبیات دوقلوی دیجیتال، تمایز اصلی میان یک مدل دیجیتال و یک دوقلوی دیجیتال در وجود ارتباط پویا و قابل‌اتکا میان موجودیت فیزیکی و مدل دیجیتال است به طوری که همراه با سازوکار به‌روزرسانی و تبادل اطلاعات باشد [۵، ۲۰]. از این رو، داده‌های تولیدشده در لایه موجودیت در معماری پیشنهادی مستقیماً به‌عنوان ورودی تصمیم‌گیری در نظر گرفته نمی‌شوند، بلکه از طریق لایه جمع‌آوری و سپس لایه ادغام به یک نمایش ساختاریافته

و قابل استفاده برای عامل‌های دیجیتال تبدیل می‌شوند.

۳-۲-۳ لایه جمع‌آوری داده

لایه جمع‌آوری داده مسئول برقراری ارتباط عملیاتی با موجودیت فیزیکی و دریافت داده‌های خام است. وظیفه اصلی این لایه، نمونه‌برداری، دریافت، زمان‌بندی و انتقال اندازه‌گیری‌های حسگرها به لایه‌های بالاتر است و از نظر معماری نباید مسئول استنتاج یا تصمیم‌گیری باشد. این جداسازی اهمیت ویژه‌ای دارد؛ زیرا در یک سامانه چندعاملی، اگر منطق تحلیل و جمع‌آوری داده در یک عامل واحد ترکیب شود، تغییر مدل پیش‌بینی یا افزودن منبع داده جدید می‌تواند کل زنجیره پردازش را تحت تأثیر قرار دهد. چارچوب‌های دوقلوهای دیجیتال نیز بر اهمیت زیرساخت داده برای حفظ همگام‌سازی میان موجودیت فیزیکی و فضای دیجیتال تأکید می‌کنند [۲۰، ۲۱].

در کاربرد حاضر، این لایه داده‌های مربوط به یک موتور را در هر چرخه کاری دریافت کرده و آن‌ها را با شناسه موجودیت، زمان یا شماره چرخه و مشخصات منبع داده برچسب‌گذاری می‌کند. در یک پیاده‌سازی واقعی، ملاحظاتی مانند نرخ نمونه‌برداری، تأخیر ارتباطی، از دست رفتن بسته‌ها، داده‌های ناقص و کشف تجهیزات جدید باید در همین لایه مدیریت شوند؛ اما در آزمایش مبتنی بر یک مجموعه داده مانند CMAPSS، تمرکز اصلی بر شبیه‌سازی جریان داده حسگری و حفظ ترتیب زمانی نمونه‌ها است. چنین رویکردی امکان می‌دهد که معماری پیشنهادی از یک طرف با محدودیت‌های یک محیط صنعتی واقعی سازگار باشد و از طرف دیگر، در محیط آزمایشگاهی نیز به‌صورت قابل تکرار ارزیابی شود.

۳-۲-۴ لایه ادغام

لایه ادغام واسط میان جریان داده خام و فضای معنایی مورد استفاده عامل‌های دیجیتال است. داده‌های خروجی از لایه جمع‌آوری در این بخش تمیز، هنجارسازی، هم‌تراز و به قالب استاندارد تبدیل می‌شوند تا هم برای مدل پیش‌بینی و هم برای وضعیت دوقلوی دیجیتال قابل استفاده باشند. در معماری پیشنهادی، این لایه شامل چهار عملیات اصلی است: کنترل کیفیت و پاک‌سازی داده‌ها، هنجارسازی ویژگی‌ها، تشکیل پنجره‌های زمانی و ایجاد یک قرارداد داده استاندارد برای تبادل اطلاعات با عامل‌های دیجیتال. این تفکیک از اهمیت ویژه‌ای برخوردار است، زیرا مدل‌های توالی‌محور مانند LSTM به ساختار زمانی منظم و مقیاس‌بندی مناسب ویژگی‌ها حساس هستند [۴۹] و در کاربردهای دوقلوهای دیجیتال نیز سازگاری قالب داده و معنای سیگنال‌ها برای ایجاد یکپارچگی میان اجزای مختلف سامانه ضروری است [۲۱].

در بخش پیش‌بینی عمر مفید باقیمانده، داده‌های چندمتغیره حسگرهای موتور در پنجره‌های زمانی متوالی سازمان‌دهی می‌شوند. بنابراین، اگر x_t بردار اندازه‌گیری‌های حسگری موتور در چرخه t باشد، یک پنجره ورودی

با طول L را می‌توان به‌صورت $\mathbf{X}_{t-L+1:t} = [x_{t-L+1}, \ldots, x_t]$ تعریف کرد. این پنجره پس از هنجارسازی به عامل پیش‌بینی ارسال می‌شود و مدل LSTM با استفاده از وابستگی‌های زمانی موجود در توالی، مقدار $\widehat{RUL}_t$ که نشان‌دهنده مقدار عمر باقیمانده پیش‌بینی‌شده است را تولید می‌کند. استفاده از مدل‌های بازگشتی برای برآورد عمر مفید باقیمانده کاربرد فراوانی دارد و LSTM به‌دلیل توانایی در مدل‌سازی وابستگی‌های زمانی یکی از خطوط مبنا[1] مهم این حوزه محسوب می‌شود [۴۹، ۵۰]. بنابراین، لایه ادغام در معماری حاضر صرفاً یک مرحله پیش‌پردازش نیست، بلکه نقطه‌ای است که در آن داده خام به یک نمایش زمانی و معنایی قابل استفاده برای اجزای تحلیلی تبدیل می‌شود.

خروجی این لایه به‌صورت یک قرارداد داده ساختاریافته تعریف می‌شود که حداقل شامل شناسه موتور، شماره چرخه، بردار حسگرهای هنجارشده، پنجره زمانی ورودی، کیفیت داده و آخرین وضعیت پیش‌بینی‌شده است. وجود چنین قراردادی باعث می‌شود عامل‌های لایه دیجیتال به جزئیات نحوه دریافت داده وابسته نباشند و بتوانند اطلاعات را از منابع متفاوت، مشروط بر رعایت قرارداد، دریافت کنند. این ویژگی در معماری‌های مقیاس‌پذیر دوقلوهای دیجیتال اهمیت اساسی دارد و با تأکید پژوهش‌های جدید بر استانداردسازی در سامانه‌های دوقلوی دیجیتال هم‌راستا است [۴۷، ۵۰].

۳-۲-۵ لایه عامل‌های دوقلوی دیجیتال

لایه عامل‌های دوقلوی دیجیتال هسته دیجیتال معماری پیشنهادی را تشکیل می‌دهد و مسئول نگهداری وضعیت جاری هر موجودیت فیزیکی در فضای دیجیتال است. در این لایه، به ازای هر موتور یا هر موجودیت تحت پایش، یک عامل دوقلوی دیجیتال می‌تواند مسئول نگهداری وضعیت همان موجودیت باشد. این عامل لزوماً خود مدل پیش‌بینی عمر مفید باقیمانده نیست؛ بلکه به‌عنوان نماینده دیجیتال موجودیت عمل کرده و داده‌های دریافتی، نتایج پیش‌بینی، وضعیت سلامت، زمان آخرین به‌روزرسانی و سایر متغیرهای مورد نیاز را در یک ساختار وضعیت منسجم نگهداری می‌کند. چنین تفکیکی با مفهوم دوقلوی دیجیتال چندعاملی سازگار است که در آن عامل‌ها می‌توانند نماینده موجودیت‌ها یا خدمات مختلف باشند و از طریق تعامل و تبادل پیام، یک سامانه توزیع‌شده را شکل دهند [۱۶، ۲۸، ۲۹].

وضعیت زنده هر عامل دوقلو را می‌توان به‌صورت یک بردار یا شیء ساختاریافته مانند رابطه (۳-۱) در نظر گرفت که در آن ID_k شناسه موتور، t شماره چرخه جاری، $\mathbf{x}_{t-L+1:t}$ پنجره اخیر داده‌های حسگری، $\widehat{RUL}_t$ مقدار عمر مفید باقیمانده پیش‌بینی‌شده، H_t وضعیت سلامت، Q_t شاخص کیفیت یا اطمینان داده و P_t وضعیت فعال یا غیر فعال‌بودن موتور است. در نتیجه، عامل دوقلو به جای آنکه تنها آخرین مقدار عمر مفید باقیمانده را

[1] Baseline

نگه دارد، یک وضعیت دیجیتال قابل پرس‌وجو در اختیار عامل‌های کاربرد قرار می‌دهد. این موضوع اهمیت زیادی دارد، زیرا پاسخ به یک پرسش سطح‌بالا مانند «عمر مفید باقیمانده موتور k چقدر است؟» ممکن است تنها به یک عدد محدود نشود و به اطلاعاتی درباره چرخه فعلی، وضعیت سلامت، آخرین به‌روزرسانی، روند تغییر عمر مفید باقیمانده و عوامل مؤثر نیز نیاز داشته باشد.

$$S_k(t) = \{ID_k, t, \mathbf{x}_{t-L+1:t}, \widehat{RUL}_t, H_t, Q_t, P_t\} \quad (۱-۳)$$

از منظر معماری، قرار دادن این وضعیت در یک لایه مستقل باعث می‌شود که عامل‌های کاربردی مستقیماً با لایه حسگر یا مدل پیش‌بینی درگیر نشوند. به بیان دیگر، عامل کاربردی به جای آنکه بداند داده حسگر با کدام قرارداد دریافت شده یا LSTM چگونه آموزش دیده است، تنها یک رابط معنایی برای پرس‌وجوی وضعیت دوقلوی دیجیتال در اختیار دارد. این ویژگی یکی از مهم‌ترین مزایای استفاده از دوقلوهای دیجیتال به‌عنوان واسط میان داده و کاربرد است و با معماری‌های چندعاملی دوقلوی دیجیتال که بر جداسازی مسئولیت موجودیت از خدمات کاربردی تأکید دارند، سازگار است [۱۶، ۲۸، ۲۹]. همچنین، با ورود مدل‌های بنیادین و عامل‌های هوشمند، دوقلوهای دیجیتال می‌توانند از یک نمایش منفعل[1] به یک موجودیت شناختی[2] و تصمیم‌محور[3] تبدیل شوند [۴۶، ۴۷].

۳-۲-۶ لایه عامل‌های کاربرد

لایه عامل‌های کاربرد بالاترین لایه معماری پیشنهادی و محل استقرار خدمات هوشمند و منطق تصمیم‌گیری سطح‌بالا است. برخلاف عامل‌های دوقلو که مسئول نگهداری وضعیت موجودیت هستند، عامل‌های این لایه وظیفه مشخصی را بر مبنای وضعیت موجود انجام می‌دهند. برای مثال، یک عامل می‌تواند مسئول پیش‌بینی عمر مفید باقیمانده، عامل دیگری مسئول پایش و تشخیص، عامل دیگری مسئول برنامه‌ریزی نگهداری و عامل دیگری مسئول تعامل طبیعی با کاربر باشد. این تفکیک، اصل تخصص نقش‌ها را در سامانه‌های چندعاملی محقق می‌کند و اجازه می‌دهد هر عامل با ابزار، مدل و منطق مناسب خود عمل کند [۲۵، ۲۸، ۲۹].

در معماری حاضر، عامل پیش‌بینی عمر مفید باقیمانده یک مؤلفه تخصصی یادگیری ماشین است که پنجره زمانی حسگرها را دریافت و $\widehat{RUL}$ را محاسبه می‌کند. از آنجا که هدف این پژوهش برآورد عددی و قابل ارزیابی عمر مفید باقیمانده است، مسئولیت این پیش‌بینی به LSTM واگذار می‌شود و LLM در مسیر اصلی استنتاج

[1] Passive
[2] Cognitive
[3] Decision-oriented

عددی قرار نمی‌گیرد. این تصمیم معماری از نظر علمی اهمیت دارد؛ زیرا مدل‌های زبانی بزرگ در درجه نخست برای پردازش و تولید زبان، استخراج دانش، استدلال و تعامل مناسب هستند، در حالی که مدل‌های تخصصی سری زمانی برای تخمین کمّی متغیرهایی مانند عمر مفید باقیمانده مناسب‌تر و از نظر ارزیابی نیز شفاف‌تر هستند [۵۱]. عامل تعامل زبانی یکی از مهم‌ترین اجزای لایه کاربرد است. وظیفه این عامل تبدیل درخواست طبیعی کاربر به یک عملیات ساختاریافته و سپس تبدیل خروجی سامانه به پاسخ قابل فهم است. در معماری‌های جدید مدل‌های زبانی بزرگ به همراه دوقلوهای دیجیتال، مدل زبانی می‌تواند در لایه‌های مختلف از ساخت و بهره‌برداری دوقلوی دیجیتال تا ارائه خدمات و تعامل با انسان به کار گرفته شود [۹، ۴۶]. بنابراین، در پژوهش حاضر مدل‌های زبانی بزرگ به‌عنوان یک رابط زبانی و عامل استدلالی عمل می‌کند که می‌تواند نیت کاربر را تشخیص دهد، شناسه موتور را استخراج کند، درخواست مناسب را به عامل دوقلو ارسال کند، نتایج ساختاریافته را دریافت نماید و در نهایت پاسخ توضیح‌پذیر تولید کند. پژوهش‌های جدید درباره کاربرد مدل‌های زبانی بزرگ در تولید نیز نشان می‌دهند که مدل‌های زبانی در محیط‌های صنعتی می‌توانند نقش‌هایی فراتر از تولید متن داشته باشند و در تعامل با داده‌های حسگرها، دانش سازمانی، دوقلوهای دیجیتال و سامانه‌های چندعاملی به‌عنوان واسط استدلالی و تعاملی عمل کنند [۴۸].

این لایه از نظر مقیاس‌پذیری نیز اهمیت دارد. در صورت نیاز به افزودن قابلیت جدید، می‌توان عامل جدیدی را در لایه کاربرد تعریف کرد، بدون آنکه لزوماً ساختار لایه موجودیت، جمع‌آوری یا ادغام تغییر کند. برای مثال، پس از توسعه عامل پیش‌بینی عمر مفید باقیمانده می‌توان عامل تشخیص خرابی، عامل تحلیل هزینه، عامل برنامه‌ریزی تعمیرات یا عامل ارزیابی ریسک را اضافه کرد. بنابراین، نقش عامل کاربردی در معماری حاضر تنها نمایش نتیجه عمر مفید باقیمانده نیست، بلکه تبدیل خروجی عددی مدل به دانش قابل استفاده برای تصمیم‌گیری است [۵۲].

۳-۲-۷ جریان تعامل و قرارداد ارتباطی

جریان تعامل در معماری پیشنهادی از یک الگوی ارتباطی دوسویه میان لایه‌های مجاور پیروی می‌کند. جریان صعودی حامل داده، اطلاعات و دانش حاصل از موجودیت فیزیکی به سمت خدمات کاربردی است، در حالی که جریان نزولی حامل درخواست، سیاست، پارامتر، فرمان یا بازخورد است. این ویژگی باعث می‌شود معماری نه‌تنها برای پایش و پیش‌بینی، بلکه برای ایجاد یک حلقه بسته میان مشاهده، تحلیل، تصمیم و در صورت وجود زیرساخت کنترلی، اقدام نیز قابل استفاده باشد [۵، ۲۱]. در شکل ۳-۲، این تبادل در چهار سطح مفهومی Attribute، Data، Information و Knowledge قابل مشاهده است. در مرز موجودیت و جمع‌آوری، ویژگی‌ها

و اندازه‌گیری‌های فیزیکی منتقل می‌شوند؛ در مرز جمع‌آوری و ادغام، داده خام به‌صورت جریان داده منتقل می‌شود؛ در مرز ادغام و عامل دوقلوی دیجیتال، داده پردازش‌شده به اطلاعات ساختاریافته تبدیل می‌شود؛ و در مرز عامل دوقلو و عامل کاربرد، اطلاعات وضعیت به دانش و خدمات قابل استفاده برای تصمیم‌گیری تبدیل می‌شود. این تفکیک مفهومی با روند تکامل دوقلوهای دیجیتال از جمع‌آوری داده به سمت تحلیل، پیش‌بینی و تصمیم‌گیری هوشمند سازگار است [۲۰، ۴۶، ۴۷].

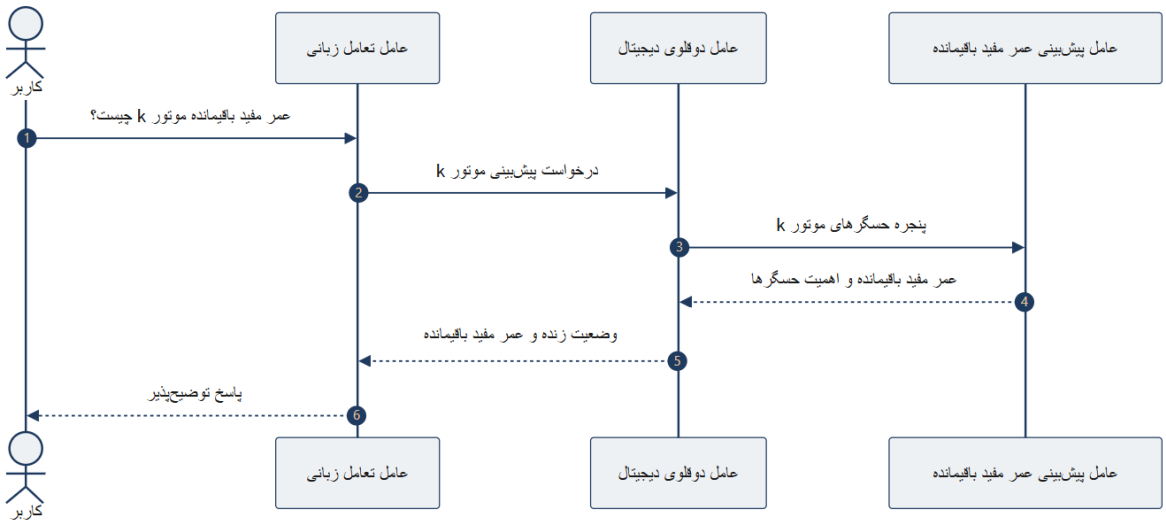
قرارداد ارتباطی میان این لایه‌ها باید علاوه بر محتوای پیام، شناسه موجودیت، زمان یا چرخه، نوع درخواست، نسخه وضعیت، کیفیت داده و منبع تولید اطلاعات را نیز مشخص کند. برای مثال، پیام خروجی لایه ادغام برای موتور k می‌تواند شامل شناسه موتور، شماره چرخه، پنجره حسگر، وضعیت کیفیت داده و آخرین $\widehat{RUL}$ باشد. عامل دوقلو این پیام را دریافت کرده و وضعیت $S_k(t)$ را به‌روزرسانی می‌کند. سپس عامل کاربردی، بسته به نوع خدمت، می‌تواند تنها بخشی از این وضعیت را درخواست کند. چنین قرارداد ساختاریافته‌ای از وابستگی مستقیم عامل‌ها به ساختار داخلی یکدیگر جلوگیری کرده و زمینه را برای جایگزینی مدل مورد استفاده، اضافه کردن مدل‌های جدید یا تغییر پیاده‌سازی عامل زبانی بدون بازطراحی کل سامانه فراهم می‌کند [۵۰].

در این معماری، یک نکته مهم تفکیک میان «پیش‌بینی» و «تفسیر» است. عامل پیش‌بینی، مقدار عددی عمر مفید باقیمانده و در صورت طراحی مدل، شاخص‌هایی نظیر اهمیت ویژگی‌ها یا عدم‌قطعیت پیش‌بینی را تولید می‌کند؛ عامل دوقلوی دیجیتال این خروجی را با وضعیت جاری موتور ترکیب و ذخیره می‌کند؛ و عامل زبانی از این وضعیت ساختاریافته برای تولید پاسخ انسانی استفاده می‌نماید. بنابراین، مدل زبانی بزرگ نباید بدون دسترسی به وضعیت معتبر دوقلو یا داده‌های ساختاریافته، مقدار عمر مفید باقیمانده را از خود تولید کند. این طراحی خطر ایجاد پاسخ‌های زبانی غیرمستند را کاهش داده و نقش مدل زبانی بزرگ را به حوزه‌ای محدود می‌کند که در آن بیشترین ارزش افزوده را دارد: تفسیر، ترکیب دانش، تعامل و هدایت جریان کار [۴۶].

۳-۲-۸ فرایند تعامل کاربر، عامل زبانی و عامل پیش‌بینی عمر مفید باقیمانده

شکل ۳-۳ نمونه‌ای از اجرای عملی معماری پیشنهادی را برای پرسش «عمر مفید باقیمانده موتور k چیست؟» نشان می‌دهد. این فرایند عمداً به‌گونه‌ای طراحی شده است که تعامل طبیعی کاربر با سامانه از منطق داخلی پیش‌بینی جدا باقی بماند. در این فرایند، کاربر مستقیماً با مدل LSTM یا پایگاه داده حسگرها ارتباط ندارد؛ بلکه درخواست خود را از طریق عامل تعامل زبانی مطرح می‌کند. عامل زبانی پس از تشخیص نیت و استخراج شناسه موتور، یک درخواست ساختاریافته برای عامل دوقلوی دیجیتال ایجاد می‌کند. عامل دوقلو با توجه به وضعیت جاری موتور، پنجره زمانی مورد نیاز را از لایه ادغام دریافت کرده و آن را به عامل پیش‌بینی عمر مفید باقیمانده ارسال می‌کند. عامل پیش‌بینی پس از اجرای مدل، مقدار $\widehat{RUL}$ و در صورت پشتیبانی مدل،

شاخص اهمیت حسگرها یا سایر شواهد پیش‌بینی را بازمی‌گرداند. عامل دوقلو سپس وضعیت دیجیتال موتور را به‌روزرسانی کرده و یک نمایش ساختاریافته از وضعیت را در اختیار عامل زبانی قرار می‌دهد. در مرحله نهایی، عامل زبانی این اطلاعات را به پاسخ طبیعی و توضیح‌پذیر برای کاربر تبدیل می‌کند. این معماری با رویکردهای جدیدی که مدل‌های زبانی را در لایه تعامل و سرویس دوقلوهای دیجیتال قرار می‌دهند و در عین حال مدل‌های تخصصی را برای وظایف تحلیلی حفظ می‌کنند، سازگار است [۹، ۴۶، ۴۸].



شکل ۳-۳: دیاگرام توالی تعامل برای پاسخ‌گویی به پرسش «عمر مفید باقیمانده موتور k چیست؟»؛ درخواست از کاربر به عامل زبانی و سپس به عامل دوقلو و عامل پیش‌بینی منتقل می‌شود و نتیجه پس از به‌روزرسانی وضعیت دوقلو، به‌صورت پاسخ توضیح‌پذیر به کاربر بازمی‌گردد.

مطابق شکل ۳-۳، نخست کاربر پرسش خود را از طریق رابط زبانی ارسال می‌کند. در گام دوم، عامل تعامل زبانی نیت کاربر را شناسایی کرده و شناسه k را از عبارت ورودی استخراج می‌کند. در گام سوم، عامل دوقلوی دیجیتال درخواست مربوط به موتور k را دریافت کرده و پنجره زمانی مورد نیاز برای پیش‌بینی را از لایه ادغام دریافت می‌کند؛ این پنجره شامل توالی آخرین اندازه‌گیری‌های حسگری مورد نیاز مدل عمر مفید باقیمانده است. در گام چهارم، عامل پیش‌بینی عمر مفید باقیمانده این توالی را به مدل تخصصی ارسال کرده و $\widehat{RUL}_k(t)$ را محاسبه می‌کند. در صورت استفاده از یک روش توضیح‌پذیر، اطلاعاتی مانند اهمیت نسبی حسگرها نیز در همین مرحله تولید می‌شود. در گام پنجم، نتیجه پیش‌بینی به عامل دوقلو بازگردانده شده و عامل دوقلو وضعیت زنده موتور را با مقدار جدید عمر مفید باقیمانده و سایر اطلاعات همراه به‌روزرسانی می‌کند. در گام ششم، عامل تعامل زبانی وضعیت ساختاریافته را دریافت کرده و پاسخ نهایی را تولید می‌کند؛ برای مثال، پاسخ می‌تواند شامل مقدار عمر مفید باقیمانده، وضعیت فعلی موتور، چرخه جاری، سطح هشدار و مهم‌ترین عوامل مؤثر بر پیش‌بینی

باشد.

این توالی نشان می‌دهد که معماری پیشنهادی در واقع یک زنجیره ساده "مدل‌های زبانی بزرگ → عمر مفید باقیمانده" نیست، بلکه یک حلقه "کاربر → مدل زبانی بزرگ → عامل دوقلوی دیجیتال → عامل عمر مفید باقیمانده → عامل دوقلوی دیجیتال → مدل زبانی بزرگ → کاربر" است. این تمایز از منظر طراحی سامانه اهمیت دارد، زیرا دوقلوهای دیجیتال در اینجا نقش حافظه وضعیت و واسط معنایی میان مدل‌های تخصصی و عامل‌های کاربردی را ایفا می‌کند. از سوی دیگر، مدل زبانی بزرگ وظیفه تولید یا جعل وضعیت فیزیکی را ندارد، بلکه فقط بر اساس وضعیت بازیابی‌شده از دوقلوی دیجیتال، پاسخ و توضیح تولید می‌کند [۴۶، ۴۷].

از دیدگاه نگهداری پیش‌بینانه، این معماری امکان گسترش فرایند پرسش و پاسخ ساده به فرآیندهای تصمیم‌گیری پیچیده‌تر را نیز فراهم می‌کند. برای مثال، پس از دریافت وضعیت موتور، یک عامل تشخیص می‌تواند علت احتمالی افت سلامت را بررسی کند، یک عامل برنامه‌ریزی می‌تواند زمان مناسب نگهداری را پیشنهاد دهد، یک عامل هزینه می‌تواند هزینه توقف و تعمیر را محاسبه کند و در نهایت عامل زبان طبیعی می‌تواند خروجی این عامل‌ها را برای کاربر ترکیب کند. چنین توسعه‌ای با روند اخیر حرکت از دوقلوهای دیجیتال منفرد به دوقلوهای دیجیتال چندعاملی و دوقلوهای دیجیتال عامل محور[1] سازگار است [۴۲]. در نتیجه، معماری حاضر می‌تواند به‌عنوان یک زیرساخت قابل توسعه برای حرکت از "پیش‌بینی عمر مفید باقیمانده" به نگهداری پیش‌بینانه عامل محور[2] مورد استفاده قرار گیرد.

بر این اساس، معماری پیشنهادی را می‌توان به‌صورت یک زنجیره لایه‌ای و در عین حال دوسویه تعریف کرد که در آن داده از موجودیت فیزیکی به سمت دانش و تصمیم حرکت می‌کند و فرمان یا درخواست در مسیر معکوس به سمت موجودیت بازمی‌گردد. این ساختار علاوه بر حفظ استقلال مدل‌های تخصصی، امکان افزودن مدل‌های زبانی بزرگ، عامل‌های جدید، روش‌های پیشرفته‌تر پیش‌بینی مانند تبدیل‌گرها[3] و سازوکارهای تصمیم‌گیری چندعاملی را فراهم می‌سازد. از این منظر، ارزش اصلی معماری پیشنهادی در یک مدل یادگیری منفرد خلاصه نمی‌شود، بلکه در ایجاد یک چارچوب یکپارچه برای اتصال داده‌های حسگری، پیش‌بینی عمر مفید باقیمانده، وضعیت دوقلوهای دیجیتال، استدلال زبانی و همکاری عامل‌ها است. چارچوبی که می‌تواند در مراحل بعدی پژوهش به سمت تصمیم‌گیری خودکار، برنامه‌ریزی نگهداری و حلقه بسته انسان–عامل–دوقلوی دیجیتال توسعه یابد.

[1] Agentic Digital Twin
[2] Agentic Predictive Maintenance
[3] Transformer

۳-۳ مجموعه داده CMAPSS و آماده‌سازی داده

۳-۳-۱ معرفی و ساختار مجموعه داده

برای ارزیابی تجربی معماری پیشنهادی، از مجموعه داده CMAPSS استفاده شده است. این مجموعه داده توسط مرکز پژوهشی NASA Ames Research Center تولید شده و یکی از مجموعه داده‌های مرجع در پژوهش‌های مرتبط با پیش‌بینی عمر مفید باقیمانده موتورهای جت به شمار می‌رود [۱۱]. در این شبیه‌سازی، وضعیت موتور در چرخه‌های کاری متوالی ثبت می‌شود و داده‌های حسگری حاصل از روند تخریب موتور، امکان توسعه و مقایسه روش‌های مختلف پیش‌آگاهی و پیش‌بینی عمر مفید باقیمانده را فراهم می‌کند.

اهمیت CMAPSS برای پژوهش حاضر از ماهیت چندمتغیره و زمانی داده‌ها ناشی می‌شود. هر موتور به‌صورت یک دنباله زمانی مستقل مشاهده می‌شود و مقادیر حسگرها در طول چرخه‌های متوالی تغییر می‌کنند. بنابراین، مسئله تنها یک مسئله رگرسیون ایستا نیست، بلکه پیش‌بینی عمر مفید باقیمانده مستلزم استخراج اطلاعات مرتبط با روند تغییرات وضعیت موتور، در طول زمان است. به همین دلیل، این مجموعه داده از نخستین سنجه‌های مهم برای بررسی روش‌های مبتنی بر شبکه‌های بازگشتی و همچنین روش‌های یادگیری عمیق در پیش‌بینی عمر مفید باقیمانده بوده است [۴۹]. همچنین، مطالعات بر روی مجموعه داده CMAPSS نشان داده‌اند که تفاوت در شرایط عملیاتی، تعداد حالت‌های خرابی، نویز حسگرها و نحوه پردازش داده می‌تواند تأثیر قابل‌توجهی بر مقایسه منصفانه مدل‌های پیش‌بینی داشته باشد [۱۱].

مجموعه داده CMAPSS از چهار زیرمجموعه FD001 تا FD004 تشکیل شده است. این زیرمجموعه‌ها از نظر تعداد شرایط عملیاتی و حالت‌های خرابی با یکدیگر تفاوت دارند. در FD001 تنها یک شرایط عملیاتی و یک حالت خرابی در نظر گرفته شده است؛ FD002 شامل شش شرایط عملیاتی و یک حالت خرابی است؛ FD003 شامل یک شرایط عملیاتی و دو حالت خرابی است؛ و FD004 شامل شش شرایط عملیاتی و دو حالت خرابی است [۱۱]. از این منظر، FD001 ساده‌ترین فرایند این مجموعه داده محسوب می‌شود و FD004 پیچیده‌ترین ترکیب شرایط عملیاتی و حالت‌های خرابی را ارائه می‌کند.

مشخصات چهار زیرمجموعه در جدول ۳-۱ ارائه شده است. در پژوهش حاضر، FD001 به‌عنوان فرایند اصلی آزمایش انتخاب شده است. این انتخاب به معنای برتری ذاتی FD001 نسبت به سایر زیرمجموعه‌ها نیست، بلکه با هدف ایجاد یک سناریوی کنترل‌شده برای ارزیابی اولیه معماری انجام شده است. از آنجا که در این زیرمجموعه تغییر شرایط عملیاتی و تنوع حالت خرابی نسبت به FD002 و FD004 محدودتر است، می‌توان اثر معماری پیشنهادی و مدل پیش‌بینی را با پیچیدگی کمتری بررسی کرد [۱۱]. ارزیابی زیرمجموعه‌های پیچیده‌تر می‌تواند در ادامه به‌عنوان توسعه آزمایش‌ها انجام شود.

جدول ۳-۱: مشخصات زیرمجموعه‌های مجموعه داده CMAPSS

زیرمجموعه	شرایط عملیاتی	حالت خرابی	موتور آموزش	موتور آزمون
FD001	۱	۱	۱۰۰	۱۰۰
FD002	۶	۱	۲۶۰	۲۵۹
FD003	۱	۲	۱۰۰	۱۰۰
FD004	۶	۲	۲۴۸	۲۴۸

در سطح رکورد، داده خام CMAPSS شامل ۲۶ ستون است که از شناسه موتور، شماره چرخه کاری، سه متغیر تنظیم عملیاتی و ۲۱ متغیر حسگری تشکیل می‌شود. شناسه موتور با unit_number مشخص شده و برای تفکیک تاریخچه موتورهای مختلف به‌کار می‌رود. متغیر time_in_cycles نیز موقعیت مشاهده در چرخه عمر موتور را نشان می‌دهد. سه متغیر تنظیم عملیاتی شرایط کاری شبیه‌سازی‌شده را توصیف می‌کنند و ۲۱ حسگر اطلاعات مرتبط با وضعیت عملیاتی و سلامت موتور را ثبت می‌کنند [۱۱].

از دیدگاه یادگیری ماشین، داده هر موتور را می‌توان به‌صورت یک سری زمانی چندمتغیره نمایش داد. اگر $x_t \in \mathbb{R}^d$ بردار ویژگی‌های موتور در چرخه t باشد، تاریخچه موتور به‌صورت دنباله‌ای از بردارهای $\{\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_T\}$ در نظر گرفته می‌شود. این ساختار امکان استفاده از مدل‌های توالی‌محور مانند LSTM را فراهم می‌کند؛ زیرا چنین مدل‌هایی می‌توانند اطلاعات چند گام زمانی متوالی را در فرآیند برآورد عمر مفید باقیمانده لحاظ کنند [۴۹].

در آزمایش اصلی این پژوهش، فایل آموزش train_FD001.txt شامل ۲۰۶۳۱ مشاهده مربوط به ۱۰۰ موتور است و تاریخچه هر موتور تا چرخه خرابی در دسترس قرار دارد. فایل test_FD001.txt نیز شامل ۱۳۰۹۶ مشاهده مربوط به ۱۰۰ موتور است؛ با این تفاوت که تاریخچه موتورهای آزمون پیش از خرابی متوقف شده است. بنابراین، زمان واقعی خرابی موتورهای آزمون مستقیماً در فایل آزمون مشاهده نمی‌شود و برای محاسبه مقدار واقعی عمر مفید باقیمانده باید از فایل RUL_FD001.txt استفاده شود. این ساختار، مسئله آزمون را به فرایندی نزدیک می‌کند که در آن وضعیت فعلی تجهیز مشاهده می‌شود اما زمان خرابی آینده هنوز رخ نداده است [۱۱].

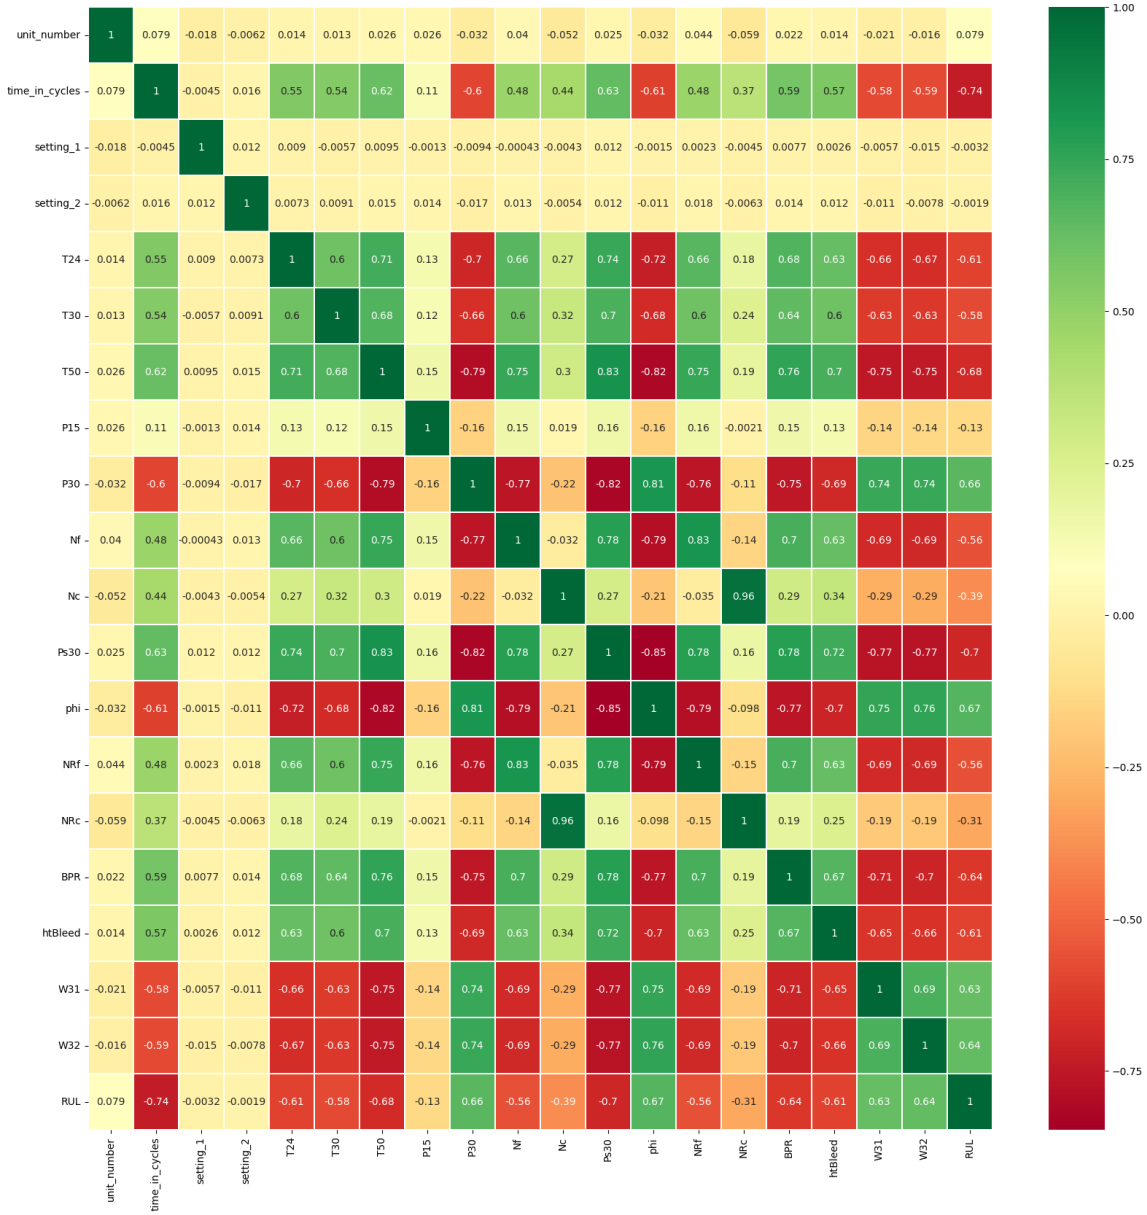
۳-۳-۲ تحلیل اکتشافی و انتخاب ویژگی

پیش از تشکیل ورودی مدل، داده آموزشی از نظر تغییرپذیری ویژگی‌ها، ارتباط با متغیر هدف و تغییرات مقادیر حسگرها بررسی شد. هدف از این مرحله کاهش ویژگی‌هایی است که یا فاقد اطلاعات تغییرپذیر هستند، یا اطلاعات تکراری ارائه می‌کنند، یا در چارچوب آزمایش حاضر، ارزش پیش‌بینی محدودی دارند. استفاده از چنین مرحله‌ای با رویه‌های رایج در مطالعات CMAPSS سازگار است. با این حال، مجموعه ویژگی نهایی باید بر اساس داده و قرارداد همان پژوهش تعیین شود، زیرا انتخاب ویژگی در مطالعات مختلف CMAPSS یکسان

نیست [۴۴، ۵۳].

در پژوهش حاضر، ابتدا ویژگی‌های فاقد تغییرپذیری مؤثر در داده آموزشی شناسایی و حذف شدند. علاوه بر آن، همبستگی میان متغیرهای حسگرها و عمر مفید باقیمانده بررسی شد تا متغیرهایی که در فرایند FD001 اطلاعات محدودی ارائه می‌کنند مشخص شوند. در این مرحله، ضریب همبستگی Pearson به‌عنوان یک معیار توصیفی مورد استفاده قرار گرفت. لازم به تأکید است که مقدار همبستگی به‌تنهایی مبنای کافی برای حذف یک حسگر نیست؛ زیرا رابطه یک حسگر با عمر مفید باقیمانده ممکن است غیرخطی یا وابسته به تاریخچه زمانی باشد. ازاین‌رو، نتایج همبستگی در این پژوهش به‌عنوان ابزار تحلیل اکتشافی و نه یک آزمون قطعی اهمیت ویژگی تفسیر شده‌اند.

پس از محاسبه برچسب عمر مفید باقیمانده، ضریب همبستگی Pearson میان ویژگی‌های باقیمانده و متغیر هدف محاسبه شد. همان‌گونه که در شکل ۳-۴ مشاهده می‌شود، عمر مفید باقیمانده با time_in_cycles، Ps30، T50 و BPR رابطه منفی نسبتاً قوی دارد؛ به این معنا که با افزایش چرخه‌های کاری و نزدیک شدن موتور به انتهای عمر، مقدار عمر مفید باقیمانده کاهش می‌یابد. در مقابل، ویژگی‌هایی نظیر phi، W31 و W32 رابطه مثبت قابل‌توجهی با عمر مفید باقیمانده نشان می‌دهند. همچنین، دو متغیر setting_1 و setting_2 رابطه بسیار ضعیفی با متغیر هدف دارند و P15 نیز ارتباط محدودی نشان می‌دهد. نکته مهم دیگر، همبستگی بسیار بالای میان Nc و NRc با مقدار تقریبی 0.96 است که نشان می‌دهد نگه‌داری هم‌زمان این دو متغیر می‌تواند اطلاعات تکراری وارد مدل کند. از این رو، انتخاب ویژگی در پژوهش حاضر صرفاً بر مبنای مقدار همبستگی با عمر مفید باقیمانده انجام نشده، بلکه ترکیبی از حذف ویژگی‌های ثابت، حذف ویژگی‌های کم‌اطلاع و کاهش هم‌خطی میان متغیرهای حسگری مورد توجه قرار گرفته است.



شکل ۳-۴: نقشه همبستگی Pearson ویژگی‌ها و برچسب عمر مفید باقیمانده در داده آموزشی FD001 پس از حذف ستون‌های ثابت

بر اساس تحلیل انجام‌شده در پژوهش حاضر، ویژگی‌های TRA، T2، P2، epr، farB، Nf_dmd و PCNfR_dmd به دلیل داشتن مقدار ثابت و عدم ارائه اطلاعات مفید برای پیش‌بینی، از مجموعه ورودی حذف شدند. همچنین setting_1 و setting_2 به دلیل اطلاعات محدود در فرایند FD001 و P15 به دلیل ارزش پیش‌بینی پایین در تحلیل حاضر کنار گذاشته شدند. افزون بر آن، به دلیل هم‌خطی شدید میان Nc و NRc، تنها Nc حفظ شد. چنین تصمیمی با مشاهدات مطالعات پیشین درباره وجود ویژگی‌های کم‌اطلاع یا بسیار هم‌بسته در داده‌های CMAPSS هم‌راستا است [۴۴، ۵۳].

در نهایت، ۱۳ حسگر شامل T24، T30، T50، P30، Nf، Nc، Ps30، phi، NRf، BPR، htBleed، W31 و

W32 برای استفاده در مدل انتخاب شدند. علاوه بر این، شماره چرخه به‌صورت هنجارشده با نام cycle_norm ایجاد شد تا موقعیت نسبی موتور در طول عمر مشاهده‌شده آن به مدل ارائه شود. در جدول ۳-۲ مراحل انتخاب ویژگی به صورت خلاصه نشان داده می‌شود.

جدول ۳-۲: فرایند انتخاب ویژگی در زیرمجموعه FD001

مرحله	ویژگی‌ها / تصمیم
حذف ویژگی‌های فاقد تغییرپذیری مؤثر	TRA، T2، P2، epr، farB، Nf_dmd و PCNfR_dmd
حذف ویژگی‌های کم‌اطلاع	setting_1، setting_2 و P15
کاهش هم‌خطی	حذف NRc و حفظ Nc
حسگرهای نهایی	T24، T30، T50، P30، Nf، Nc، Ps30، phi، NRf، BPR، htBleed، W31 و W32

۳-۳-۳ پیش‌پردازش و تشکیل دنباله‌های زمانی

پس از پاک‌سازی و انتخاب ویژگی، داده‌ها برای استفاده در مدل توالی‌محور به نمونه‌های زمانی با طول ثابت تبدیل شدند. نخستین مرحله، محاسبه برچسب عمر مفید باقیمانده برای داده آموزشی است. از آنجا که تاریخچه موتورهای آموزشی تا خرابی در دسترس است، اگر $t_{\text{end}}^{(i)}$ آخرین چرخه مشاهده‌شده برای موتور i باشد، مقدار واقعی عمر مفید باقیمانده در چرخه t از رابطه ۳-۲ محاسبه می‌شود:

$$y^{(i)}(t) = t_{\text{end}}^{(i)} - t. \tag{۳-۲}$$

در نتیجه، مقدار عمر مفید باقیمانده در آخرین چرخه موتور برابر صفر است و برای چرخه‌های قبل، متناسب با فاصله زمانی تا خرابی افزایش می‌یابد. این تعریف با مسائل رایج عمر مفید باقیمانده در داده‌های حرکت به سوی شکست[1] سازگار است [۱۱، ۴۹].

برای داده آزمون، دنباله هر موتور پیش از وقوع خرابی قطع شده است. بنابراین، برخلاف داده آموزشی، لحظه خرابی در فایل آزمون مشاهده نمی‌شود. فایل RUL_FD001.txt تنها مقدار عمر مفید باقیمانده را در آخرین چرخه مشاهده‌شده هر موتور ارائه می‌دهد. اگر $t_{\text{last}}^{(i)}$ آخرین چرخه مشاهده‌شده موتور i و $r_{\text{file}}^{(i)}$ مقدار ثبت‌شده در این فایل باشد، لحظه خرابی به‌صورت $t_{\text{fail}}^{(i)} = t_{\text{last}}^{(i)} + r_{\text{file}}^{(i)}$ بازسازی می‌شود. سپس برچسب همه چرخه‌های همان موتور، مشابه رابطه (۳-۲)، از فاصله تا لحظه خرابی به‌دست می‌آید:

[1] run-to-failure

$$y^{(i)}(t) = t^{(i)}_{\text{last}} + r^{(i)}_{\text{file}} - t = t^{(i)}_{\text{fail}} - t. \tag{۳-۳}$$

در نتیجه، در آخرین چرخه مشاهده‌شده داریم $y^{(i)}(t^{(i)}_{\text{last}}) = r^{(i)}_{\text{file}}$ و برچسب با مقدار مرجع ناسا یکی است. ارزیابی کمی مدل نیز روی همین نقطه، یعنی آخرین پنجره زمانی هر موتور آزمون، انجام می‌شود.

برای هم‌مقیاس‌سازی ویژگی‌ها از روش استانداردسازی مبتنی بر میانگین و انحراف معیار، یعنی StandardScaler، استفاده شد. در این روش، هر ویژگی به‌صورت زیر تبدیل می‌شود:

$$x_{\text{scaled}} = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}, \tag{۴-۳}$$

که در آن μ_{train} و σ_{train} به‌ترتیب میانگین و انحراف معیار ویژگی مورد نظر در داده‌های آموزشی هستند. این پارامترها تنها از داده‌های آموزشی محاسبه شده و سپس بدون برازش مجدد برای استانداردسازی داده‌های آزمون به کار گرفته می‌شوند. بدین ترتیب، اطلاعات آماری مجموعه آزمون در تعیین پارامترهای استانداردسازی دخالت داده نمی‌شود.

برای تولید برچسب‌های آموزشی، علاوه بر فاصله تا آخرین چرخه موتور، از سقف‌گذاری مقدار عمر مفید باقیمانده در ۱۲۵ چرخه استفاده شده است. در نتیجه، برچسب آموزشی به‌صورت زیر تعریف می‌شود:

$$y^{(i)}(t) = \min\left(125,\, t^{(i)}_{\text{end}} - t\right). \tag{۵-۳}$$

این تعریف موجب می‌شود مقادیر بزرگ عمر مفید باقیمانده در مراحل ابتدایی عمر موتور از یک مقدار مشخص فراتر نروند و مدل بر یادگیری تغییرات مرتبط با فرایند فرسایش و نزدیک‌شدن به خرابی تمرکز کند.

پس از استانداردسازی و تولید برچسب‌ها، داده‌های هر موتور به‌صورت مستقل و بر اساس ترتیب چرخه‌های کاری مرتب شدند. سپس از روش پنجره لغزنده با طول ۳۰ چرخه و گام حرکت یک چرخه استفاده شد. اگر $\mathbf{x}_t$ بردار ۱۴بعدی ویژگی‌های ورودی در چرخه t باشد، ورودی مدل در زمان t به‌صورت زیر تعریف می‌شود:

$$\mathbf{X}_{t-29:t} = [\mathbf{x}_{t-29}, \mathbf{x}_{t-28}, \ldots, \mathbf{x}_t]. \tag{۶-۳}$$

بنابراین، هر نمونه ورودی شامل ۳۰ گام زمانی متوالی و ۱۴ ویژگی در هر گام است و ابعاد آن به‌صورت

14×30 خواهد بود. برچسب متناظر با هر پنجره نیز برابر با مقدار عمر مفید باقیمانده در آخرین چرخه آن پنجره، یعنی $y(t)$، در نظر گرفته می‌شود.

پس از تشکیل تمام پنجره‌های آموزشی، مجموعه حاصل با استفاده از روش تقسیم تصادفی به دو بخش آموزش و اعتبارسنجی تقسیم شد. در این تقسیم، ۸۰ درصد نمونه‌های توالی برای آموزش و ۲۰ درصد برای اعتبارسنجی در نظر گرفته شدند. برای قابلیت بازتولید این تقسیم، مقدار بذر تصادفی برابر ۸۳ تنظیم شد.

در مجموعه آزمون نیز برای هر موتور، حداکثر پنج پنجره زمانی متوالی از انتهای تاریخچه مشاهده‌شده استخراج می‌شود. با این حال، معیارهای نهایی گزارش‌شده در این پژوهش بر اساس پیش‌بینی پنجره نهایی هر موتور محاسبه شده‌اند؛ زیرا هدف، ارزیابی مقدار عمر مفید باقیمانده در آخرین نقطه زمانی در دسترس برای هر موتور است. برچسب واقعی این نقطه نیز مستقیماً از فایل RUL_FD001.txt استخراج می‌شود.

لازم به ذکر است که تقسیم آموزش و آزمون در سطح موتورهای مجزا حفظ شده است؛ به این معنا که موتورهای مجموعه آزمون در فرایند آموزش مدل حضور ندارند. با این حال، تقسیم داخلی آموزش و اعتبارسنجی پس از تشکیل پنجره‌های لغزنده و در سطح نمونه‌های توالی انجام شده است. از آنجا که پنجره‌های متوالی یک موتور دارای هم‌پوشانی زمانی هستند، ممکن است پنجره‌های یک موتور در هر دو بخش آموزش و اعتبارسنجی حضور داشته باشند. این موضوع در تفسیر معیارهای اعتبارسنجی باید در نظر گرفته شود؛ هرچند ارزیابی نهایی روی موتورهای مجزای مجموعه آزمون انجام شده است.

۳-۴ انطباق معماری پیشنهادی بر مسئله CMAPSS

پس از آماده‌سازی داده، مرحله بعدی پژوهش به نگاشت معماری پیشنهادی بر مسئله مشخص پیش‌بینی عمر مفید باقیمانده اختصاص می‌یابد. هدف این نگاشت، تبدیل معماری مفهومی معرفی‌شده در فصل‌های پیشین به یک نمونه قابل پیاده‌سازی و ارزیابی است؛ به‌گونه‌ای که مشخص شود داده از لحظه ورود به سامانه تا تولید پیش‌بینی و ارائه آن به کاربر چگونه در میان اجزای مختلف معماری جریان پیدا می‌کند.

در این پژوهش، داده‌های CMAPSS به‌عنوان داده شبیه‌سازی‌شده از رفتار موتورهای جت در طول چرخه عمر در نظر گرفته می‌شوند و نه به‌عنوان داده حاصل از یک سامانه فیزیکی برخط. بنابراین، نیاز است تا لایه‌های مربوط به معماری به اجزای این مسئله نگاشت شود. [۲۱، ۲۲].

۳-۴-۱ نگاشت لایه‌ها به اجزای مسئله

در لایه موجودیت، هر موتور موجود در زیرمجموعه FD001 به‌عنوان یک موجودیت مستقل در نظر گرفته می‌شود. شناسه unit_number برای شناسایی این موجودیت و ویژگی‌های آن استفاده می‌شود. تاریخچه چرخه‌های

کاری و داده‌های حسگرهای هر موتور نیز وضعیت آن موجودیت را تشکیل می‌دهد.

لایه جمع‌آوری داده مسئول دریافت مشاهدات چرخه‌ای از مجموعه داده است. در پیاده‌سازی آزمایشگاهی، داده‌ها از فایل‌های CMAPSS خوانده می‌شوند و به‌صورت ترتیبی در اختیار اجزای بعدی سامانه قرار می‌گیرند. بنابراین، اگرچه منشأ داده یک فایل آموزشی یا آزمونی است، جریان داده در معماری به‌گونه‌ای سازمان‌دهی می‌شود که دریافت متوالی داده‌های حسگری یک سامانه پایش را بازنمایی کند.

لایه ادغام مسئول تبدیل داده خام به یک نمایش استاندارد برای اجزای تحلیلی سامانه است. این لایه شامل انتخاب ویژگی، استانداردسازی و تشکیل دنباله‌های زمانی است. در پیاده‌سازی حاضر، ۱۳ متغیر حسگری منتخب به همراه شمارنده چرخه، در مجموع ۱۴ ویژگی ورودی را تشکیل می‌دهند. این ویژگی‌ها پس از استانداردسازی، در پنجره‌های زمانی ۳۰ چرخه‌ای سازمان‌دهی می‌شوند.

خروجی این لایه یک رکورد منفرد حسگری نیست، بلکه یک نمایش زمانی ساختاریافته با ابعاد ۳۰×۱۴ است که به‌عنوان ورودی عامل پیش‌بینی مورد استفاده قرار می‌گیرد. تفکیک مسئولیت انتخاب ویژگی، استانداردسازی و تشکیل پنجره زمانی، موجب کاهش وابستگی میان اجزای سامانه و امکان جایگزینی مستقل مدل یادگیری می‌شود.

این تفکیک مسئولیت اهمیت معماری دارد؛ زیرا عامل پیش‌بینی نباید هم‌زمان مسئول مدیریت فایل خام، انتخاب ویژگی و تشکیل پنجره زمانی باشد. جدا کردن این وظایف موجب کاهش وابستگی میان اجزای سامانه و امکان جایگزینی مستقل عامل پیش‌بینی یا عامل پردازش داده می‌شود. چنین نگاهی با رویکردهای سرویس‌محور در معماری دوقلوهای دیجیتال نیز هم‌خوانی دارد [۲۱، ۲۲].

جدول ۳-۳: نگاشت لایه‌های معماری پیشنهادی به اجزای پیاده‌سازی در مسئله CMAPSS

لایه	نقش معماری	مصداق در آزمایش
لایه موجودیت	نمایندگی موجودیت	موتورهای شبیه‌سازی‌شده FD001
لایه جمع‌آوری داده	دریافت داده چرخه‌ای	خواندن ترتیبی مشاهدات CMAPSS
لایه ادغام	استانداردسازی و ساخت توالی	انتخاب ویژگی، StandardScaler و پنجره زمانی به طول ۳۰
لایه عامل‌های دوقلوی دیجیتال	نگهداری وضعیت دیجیتال	وضعیت جاری هر موتور در سامانه
لایه عامل‌های کاربرد	ارائه خدمات تحلیلی و تعاملی	عامل پیش‌بینی، پایش، تعامل زبانی و تابلو وضعیت[1]

در لایه عامل‌های دوقلوی دیجیتال، برای هر موتور یک وضعیت دیجیتال قابل به‌روزرسانی نگهداری می‌شود. این وضعیت می‌تواند شامل شناسه موتور، آخرین چرخه مشاهده‌شده، آخرین پنجره حسگری، آخرین مقدار پیش‌بینی‌شده عمر مفید باقیمانده و وضعیت پایش باشد. بنابراین، دوقلو در این پژوهش صرفاً یک رکورد

ثابت از موتور نیست، بلکه یک ساختار نرم‌افزاری برای نگهداری و به‌روزرسانی وضعیت موجودیت است.

این برداشت با مفهوم دوقلوی دیجیتال به‌عنوان پیوند میان موجودیت فیزیکی و نمایش دیجیتال آن سازگار است؛ با این تفاوت که در آزمایش حاضر، موجودیت فیزیکی مستقیماً به یک حسگر برخط متصل نیست و وضعیت آن از داده شبیه‌سازی‌شده CMAPSS دریافت می‌شود [۲۱، ۲۲]. بنابراین، عبارت «دوقلوی دیجیتال آزمایشی» برای توصیف دقیق‌تر پیاده‌سازی حاضر مناسب‌تر از ادعای وجود یک دوقلوی دیجیتال کامل در محیط واقعی است. اما با این حال، معماری پیشنهادی دوقلوی دیجیتال و چگونگی پیاده‌سازی‌ها در این آزمایش کاملا قابل تعمیم به یک دوقلوی دیجیتال در محیط واقعی است.

در لایه عامل‌های کاربردی، خدمات تخصصی سامانه از یکدیگر جدا می‌شوند. عامل پیش‌بینی، مسئول اجرای مدل LSTM و تولید $\widehat{RUL}$ است. عامل پایش، خروجی مدل را دریافت کرده و بر اساس قواعد تعیین‌شده، وضعیت موتور را ارزیابی می‌کند. عامل تعامل زبانی، رابط میان کاربر و خدمات سامانه را فراهم می‌کند و عامل تابلو وضعیت، وظیفه نمایش وضعیت موتورها را بر عهده دارد.

این تفکیک با منطق سامانه‌های چندعاملی سازگار است؛ زیرا هر عامل مسئولیت مشخصی دارد و هماهنگی میان آن‌ها از طریق وضعیت و پیام‌های ساختاریافته انجام می‌شود. مطالعات جدید درباره ترکیب سامانه‌های چندعاملی و دوقلوهای دیجیتال نیز بر همین موضوع، یعنی تفکیک نقش‌ها، هماهنگی عامل‌ها و استفاده از دوقلوی دیجیتال به‌عنوان نمایش وضعیت سامانه، تأکید دارند [۱۶، ۲۸].

۳-۴-۲ عامل پیش‌بینی و اتصال آن به جریان داده

در معماری پیشنهادی، پیش‌بینی عددی عمر مفید باقیمانده به یک عامل تخصصی واگذار شده است. این عامل مدل LSTM به همراه سازوکار توجه را به‌عنوان یک خدمت تحلیلی در اختیار سایر اجزای سامانه قرار می‌دهد. ورودی عامل پیش‌بینی، آخرین پنجره زمانی تولیدشده توسط لایه ادغام است و خروجی اصلی آن مقدار عددی $\widehat{RUL}$ است.

استفاده از LSTM در این بخش بر ماهیت زمانی مسئله استوار است. هایمز نشان داد که شبکه‌های بازگشتی می‌توانند برای مدل‌سازی توالی‌های حاصل از روند تخریب مورد استفاده قرار گیرند [۴۹]. مطالعات بعدی نیز نشان داده‌اند که LSTM با حفظ اطلاعات زمانی طولانی‌تر می‌تواند برای تخمین عمر مفید باقیمانده از داده‌های حسگری چندمتغیره مناسب باشد [۴۹]. ازاین‌رو، در معماری حاضر مدل یادگیری عمیق وظیفه‌ای تخصصی و قابل ارزیابی را بر عهده دارد و خروجی آن به‌صورت یک سرویس در اختیار سایر عامل‌ها قرار می‌گیرد.

نکته مهم در طراحی حاضر، جداسازی مسیر استنتاج عددی از مسیر تعامل زبانی است. مدل زبانی مستقیماً مسئول تولید مقدار عددی عمر مفید باقیمانده نیست؛ بلکه مقدار پیش‌بینی‌شده توسط عامل تخصصی را دریافت

می‌کند و در صورت نیاز آن را برای کاربر تفسیر یا توضیح می‌دهد. بنابراین، صحت مقدار عمر مفید باقیمانده را می‌توان مستقل از کیفیت تولید متن ارزیابی کرد.

در سطح تابع هدف نیز هزینه خطا به‌صورت متقارن در نظر گرفته نمی‌شود. در مسئله پیش‌بینی عمر مفید باقیمانده، کم‌برآورد و بیش‌برآورد عمر مفید باقیمانده الزاماً پیامدهای یکسانی ندارند؛ به‌ویژه، بیش‌برآورد عمر مفید باقیمانده می‌تواند موجب تأخیر در تصمیم‌گیری برای انجام عملیات نگهداری و در نتیجه افزایش احتمال ادامه بهره‌برداری از تجهیز در شرایط نزدیک به خرابی شود. ازاین‌رو، در پژوهش‌های جدید پیش‌بینی عمر مفید باقیمانده بر روی مجموعه داده CMAPSS نیز توجه به جهت خطای پیش‌بینی و استفاده از معیارها یا توابع هزینه نامتقارن مورد توجه قرار گرفته است [۵۴–۵۶]. در این رویکردها، هدف صرفاً کاهش خطای عددی پیش‌بینی نیست، بلکه جلوگیری از خطاهای بیش‌برآوردی که می‌توانند هشدار دیرهنگام ایجاد کنند نیز اهمیت دارد. به همین دلیل، در پژوهش حاضر نیز تابع هدف به‌گونه‌ای انتخاب شده است که نسبت به جهت خطای پیش‌بینی حساس باشد و مدل را به سمت برآورد محافظه‌کارانه‌تر عمر مفید باقیمانده هدایت کند. در پژوهش حاضر، برای ایجاد این سوگیری از تابع زیان Pinball با $\tau = 0.125$ استفاده شده است.

در سطح تابع هدف، هزینه خطای پیش‌بینی به‌صورت نامتقارن تعریف شده است تا تفاوت میان پیامدهای عملیاتی کم‌برآورد و بیش‌برآورد عمر مفید باقیمانده در فرایند آموزش مدل منعکس شود. در این چارچوب، فرض بر آن است که بیش‌برآورد عمر مفید باقیمانده، یعنی پیش‌بینی مقداری بزرگ‌تر از عمر واقعی تجهیز، می‌تواند موجب به‌تعویق‌افتادن تصمیم نگهداری و افزایش ریسک بهره‌برداری تا نزدیکی خرابی شود. به همین دلیل، در کاربردهای پیش‌بینی مبتنی بر خطر، استفاده از توابع زیان نامتقارن و به‌ویژه زیان Pinball امکان کنترل جهت‌دار خطای پیش‌بینی را فراهم می‌کند. این تابع با تعریف هزینه متفاوت برای خطاهای مثبت و منفی، به مدل اجازه می‌دهد به‌جای تمرکز صرف بر کمینه‌سازی خطای متوسط، به سمت خطای مورد نظر نسبت به متغیر هدف متمایل شود [۵۷].

اگر $e = y - \hat{y}$ خطای پیش‌بینی تعریف شود که در آن y مقدار عمر مفید باقیمانده و $\hat{y}$ مقدار پیش‌بینی شده باشد، تابع زیان Pinball برای چندک[1] τ به‌صورت زیر بیان می‌شود:

$$L_\tau(e) = \begin{cases} \tau e, & e \geq 0, \\ (\tau - 1)e, & e < 0. \end{cases} \qquad (۷-۳)$$

در این تعریف، $e > 0$ متناظر با کم‌برآوردی، یعنی $\hat{y} < y$، و $e < 0$ متناظر با بیش‌برآوردی، یعنی $\hat{y} > y$، است. بنابراین، برای خطای کم‌برآورد ضریب τ و برای خطای بیش‌برآورد ضریب $1 - \tau$ در نظر گرفته می‌شود.

[1] Quantile

در پژوهش حاضر با انتخاب $\tau = 0.125$، تابع هدف به کم‌برآورد و بیش‌برآورد وزن یکسانی نمی‌دهد؛ به‌طوری‌که شیب تابع زیان در سمت کم‌برآورد برابر 0.125 و در سمت بیش‌برآورد برابر 0.875 است. در نتیجه، برای خطاهایی با قدرمطلق یکسان، هزینه بیش‌برآورد هفت برابر هزینه کم‌برآورد خواهد بود. این نامتقارن‌سازی باعث می‌شود مدل در فرایند بهینه‌سازی نسبت به بیش‌برآورد عمر مفید باقیمانده حساس‌تر شود و در صورت وجود عدم‌قطعیت در داده، به سمت برآورد محافظه‌کارانه‌تر متمایل گردد. در اینجا، محافظه‌کارانه بودن به معنای افزایش احتمال کم‌برآورد کنترل‌شده عمر واقعی است و نه الزاماً افزایش دقت مطلق پیش‌بینی. از این رو، اثر انتخاب $\tau = 0.125$ باید در کنار معیارهای عمومی خطا و معیارهای حساس به جهت خطا ارزیابی شود تا مشخص شود که کاهش ریسک بیش‌برآورد با حفظ سطح قابل قبول دقت پیش‌بینی همراه بوده است.

۳-۴-۳ فرایند تعامل چندعاملی و دوقلوی دیجیتال

برای بررسی انسجام معماری، جریان سرتاسری سامانه از دریافت داده تا ارائه پاسخ به کاربر به‌صورت یک سناریوی چندعاملی تعریف شده است. در این فرایند، مشاهده جدید موتور ابتدا وارد لایه جمع‌آوری می‌شود. پس از انجام پیش‌پردازش و تشکیل پنجره زمانی، وضعیت دوقلوی دیجیتال موتور مربوطه به‌روزرسانی می‌شود. سپس عامل پیش‌بینی آخرین وضعیت قابل استفاده را دریافت کرده و مقدار $\widehat{RUL}$ را محاسبه می‌کند.

خروجی عامل پیش‌بینی در ادامه به عامل پایش منتقل می‌شود. عامل پایش می‌تواند مقدار پیش‌بینی‌شده را با آستانه‌های عملیاتی تعریف‌شده مقایسه کرده و وضعیت موتور را به‌عنوان وضعیت عادی، هشدار یا بحرانی طبقه‌بندی کند. نتیجه این مرحله در وضعیت دوقلو ثبت می‌شود و برای عامل تعامل زبانی و تابلو وضعیت قابل دسترسی خواهد بود.

در صورت دریافت پرسش کاربر، عامل تعامل زبانی ابتدا درخواست را به یک عملیات ساختاریافته تبدیل می‌کند. برای مثال، در پرسش «عمر مفید باقیمانده موتور k چقدر است؟»، شناسه موتور و نوع عملیات از درخواست استخراج می‌شود. سپس عامل مربوطه وضعیت موتور k را از دوقلو دریافت کرده و در صورت نیاز عامل پیش‌بینی را فراخوانی می‌کند. نتیجه عددی پس از بازگشت به عامل تعامل زبانی، به همراه اطلاعات وضعیت موجود، برای تولید پاسخ طبیعی مورد استفاده قرار می‌گیرد.

۳-۵ روش ارزیابی طراحی‌شده

روش ارزیابی پژوهش حاضر با هدف بررسی هم‌زمان عملکرد مدل پیش‌بینی و قابلیت‌های معماری پیشنهادی طراحی شده است. از آنجا که هدف پژوهش تنها توسعه یک مدل رگرسیون برای تخمین عمر مفید باقیمانده نیست، ارزیابی در دو سطح اصلی انجام می‌شود. سطح نخست، ارزیابی مدل تخصصی پیش‌بینی از نظر دقت و

جهت خطا و سطح دوم، ارزیابی سامانه از نظر عملکرد جریان چندعاملی و تعامل با کاربر است.

این تفکیک اهمیت دارد، زیرا بهبود عملکرد یک مدل LSTM لزوماً به معنای بهبود عملکرد کل سامانه نیست. برای مثال، ممکن است مدل پیش‌بینی مقدار مناسبی برای عمر مفید باقیمانده تولید کند، اما عامل تعامل نتواند درخواست کاربر را به سرویس مناسب هدایت کند. از سوی دیگر، پاسخ زبانی مناسب نیز نمی‌تواند ضعف مدل عددی را جبران کند. بنابراین، نتایج این دو سطح به‌صورت مستقل گزارش و سپس در سطح معماری تفسیر می‌شوند.

۳-۵-۱ معیارهای کمی پیش‌بینی

برای سنجش دقت عددی مدل، معیارهای MAE و RMSE به‌عنوان معیارهای اصلی و R^2 به‌عنوان معیار تکمیلی محاسبه می‌شوند. معیار MAE که در رابطه ۳-۸ نشان داده شده، میانگین قدرمطلق خطا را اندازه‌گیری می‌کند.

$$\mathrm{MAE} = \frac{1}{N}\sum_{i=1}^{N} |\hat{y}_i - y_i| \,. \tag{۳-۸}$$

در این رابطه، N تعداد نمونه‌های ارزیابی، y_i مقدار واقعی عمر مفید باقیمانده و $\hat{y}_i$ مقدار پیش‌بینی‌شده است. مقدار کمتر MAE نشان‌دهنده فاصله متوسط کمتر میان پیش‌بینی و مقدار واقعی است.

معیار RMSE با مجازات بیشتر خطاهای بزرگ تعریف می‌شود. رابطه ۳-۹ این معیار را نشان می‌دهد.

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} (\hat{y}_i - y_i)^2}. \tag{۳-۹}$$

به دلیل وجود توان دوم، یک خطای بزرگ تأثیر بیشتری بر مقدار RMSE دارد. بنابراین، استفاده هم‌زمان از MAE و RMSE امکان تفکیک خطای متوسط از حساسیت مدل به خطاهای بزرگ را فراهم می‌کند.

برای ارزیابی تکمیلی، ضریب تعیین R^2 که در رابطه ۳-۱۰ آمده است، نیز محاسبه می‌شود:

$$R^2 = 1 - \frac{\sum_{i=1}^{N} (\hat{y}_i - y_i)^2}{\sum_{i=1}^{N} (y_i - \bar{y})^2}. \tag{۳-۱۰}$$

در این رابطه، $\bar{y}$ میانگین مقادیر واقعی عمر مفید باقیمانده است. مقدار بالاتر R^2 در حالت معمول نشان‌دهنده توانایی بیشتر مدل در توضیح تغییرپذیری متغیر هدف است. با این حال، در مسئله عمر مفید باقیمانده، R^2 به‌تنهایی برای ارزیابی مناسب نیست و در این پژوهش در کنار MAE و RMSE گزارش می‌شود.

۳-۵-۲ ارزیابی جهت خطا

برای سنجش مستقیم جهت خطا، نسبت کم‌برآورد نیز محاسبه می‌شود:

$$r_{\text{under}} = \frac{|\{i : \hat{y}_i < y_i\}|}{N}. \quad (۱۱-۳)$$

مقدار بالاتر r_{under} نشان‌دهنده آن است که سهم بیشتری از پیش‌بینی‌ها در سمت کم‌برآورد قرار گرفته‌اند. در این پژوهش، این شاخص به‌تنهایی معیار «خوب بودن» مدل تلقی نمی‌شود؛ زیرا افزایش بیش از حد کم‌برآورد نیز می‌تواند باعث کاهش دقت و افزایش هزینه نگهداری غیرضروری شود. هدف، بررسی وجود یک سوگیری کنترل‌شده به سمت کم‌برآورد در کنار حفظ دقت قابل قبول است.

بنابراین، اثر تابع زیان نامتقارن با ترکیب چهار شاخص MAE، RMSE، و r_{under} تحلیل خواهد شد. این ترکیب امکان بررسی هم‌زمان مقدار خطا، حساسیت به خطاهای بزرگ، هزینه نامتقارن و جهت خطا را فراهم می‌کند.

۳-۵-۳ ارزیابی عملکرد سامانه چندعاملی

ارزیابی معماری پیشنهادی در سطح سامانه نیز به‌صورت مستقل از مدل پیش‌بینی انجام می‌شود. در این سطح، سه دسته شاخص در نظر گرفته می‌شود: زمان پاسخ، صحت مسیریابی درخواست و کیفیت پاسخ توضیحی.

شاخص نخست، زمان پاسخ سامانه است. این معیار فاصله زمانی میان دریافت یک درخواست یا مشاهده جدید و تولید پاسخ مربوطه را اندازه‌گیری می‌کند. در صورت استفاده از پردازش برخط، میانگین، میانه و صدک‌های بالای زمان پاسخ می‌توانند گزارش شوند تا علاوه بر رفتار متوسط، تأخیرهای غیرمعمول نیز مشخص شوند.

شاخص دوم، صحت اجرای درخواست است. در این ارزیابی، مجموعه‌ای از درخواست‌های از پیش تعریف‌شده به سامانه ارائه می‌شود و بررسی می‌شود که آیا عامل تعامل زبانی توانسته است نوع عملیات و موجودیت مورد نظر را به‌درستی تشخیص داده و درخواست را به عامل مناسب هدایت کند یا خیر. این معیار برای معماری حاضر اهمیت ویژه‌ای دارد، زیرا عامل زبانی مسئول تولید مستقیم مقدار عددی عمر مفید باقیمانده نیست؛ بلکه باید درخواست زبان طبیعی را به عملیات ساختاریافته تبدیل کند.

شاخص سوم، کیفیت پاسخ توضیحی است. برای جلوگیری از ارزیابی صرفاً زبانی، این شاخص باید بر مؤلفه‌های قابل بررسی متمرکز شود. از جمله این مؤلفه‌ها می‌توان به صحت مقدار گزارش‌شده عمر مفید باقیمانده، انطباق توضیح با وضعیت ثبت‌شده موتور، عدم افزودن اطلاعاتی که در وضعیت سامانه وجود ندارد و خوانایی

پاسخ اشاره کرد. بنابراین، ارزیابی کیفیت توضیح باید میان «روان بودن متن» و «صحت محتوای فنی» تمایز قائل شود.

در این چارچوب، عامل زبانی به‌عنوان جایگزین مدل پیش‌بینی ارزیابی نمی‌شود. صحت پیش‌بینی عددی با معیارهای MAE، RMSE و R^2 سنجیده می‌شود، در حالی که عملکرد عامل زبانی در سطح تعامل و تبدیل اطلاعات ساختاریافته به پاسخ طبیعی ارزیابی می‌شود. این تفکیک، امکان تعیین منشأ خطا را نیز فراهم می‌کند؛ برای مثال، می‌توان مشخص کرد که یک پاسخ نادرست ناشی از خطای مدل پیش‌بینی عمر مفید باقیمانده بوده یا از مسیریابی نادرست عامل تعامل ناشی شده است.

۳-۵-۴ خطوط مبنا و مقایسه تجربی

برای تعیین جایگاه مدل پیشنهادی، عملکرد آن دو حالت ارائه می‌شود. حالت اول با استفاده از خطای MSE و حالت دوم با استفاده از خطای Pinball است. نتایج این دو حالت با مدل LSTM ارائه شده در پژوهش [۵۸] مقایسه و ارزیابی می‌شود.

نتایج نهایی فصل ارزیابی در سه سطح گزارش خواهند شد: عملکرد عددی مدل، رفتار جهت‌دار خطا و عملکرد سامانه چندعاملی. این ساختار امکان پاسخ به سه پرسش مستقل را فراهم می‌کند: آیا مدل عمر مفید باقیمانده دقیق است؟ آیا سوگیری مورد نظر در جهت کاهش بیش‌برآورد ایجاد شده است؟ و آیا معماری پیشنهادی در سطح سامانه قابلیت استفاده و تعامل مورد انتظار را فراهم می‌کند؟

۳-۶ جمع‌بندی

در این فصل، فرایند تبدیل مسئله پیش‌بینی عمر مفید باقیمانده موتورهای توربوفن به یک نمونه آزمایشگاهی قابل ارزیابی تشریح شد. ابتدا مجموعه داده CMAPSS معرفی شد و با توجه به هدف آزمایش، زیرمجموعه FD001 به‌عنوان سناریوی اصلی انتخاب گردید. انتخاب این زیرمجموعه امکان ارزیابی اولیه معماری را در شرایطی با یک حالت خرابی و یک شرایط عملیاتی فراهم می‌کند و در عین حال ساختار سری زمانی چندمتغیره لازم برای بررسی مدل‌های توالی‌محور را حفظ می‌کند [۱۱].

در مرحله آماده‌سازی داده، ویژگی‌های فاقد اطلاعات مؤثر، ویژگی‌های کم‌اطلاع و برخی متغیرهای دارای هم‌خطی شدید بررسی و بر اساس تحلیل انجام‌شده در پژوهش حذف شدند. در نهایت، ۱۳ حسگر برای ورود به مدل انتخاب شد و یک نمایش استانداردشده از موقعیت زمانی موتور نیز ایجاد گردید. در این فرایند میان شناسه موتور به‌عنوان مشخصه هویتی موجودیت و ویژگی‌های فیزیکی مورد استفاده برای پیش‌بینی تمایز گذاشته شد. این تفکیک برای جلوگیری از تفسیر نادرست شناسه موتور به عنوان یک متغیر سلامت و همچنین برای

حفظ قابلیت تعمیم مدل اهمیت دارد.

برچسب عمر مفید باقیمانده برای موتورهای آموزشی از فاصله هر چرخه تا آخرین چرخه موتور محاسبه شد. برای موتورهای آزمون نیز با استفاده از مقدار عمر مفید باقیمانده موجود در فایل مرجع و آخرین چرخه مشاهده‌شده، برچسب هر مشاهده بازسازی گردید. سپس پارامترهای استانداردشده تنها از داده آموزشی استخراج و برای داده آزمون نیز بدون بازبرآورد استفاده شدند. در ادامه، داده‌های متوالی با پنجره‌ای به طول ۳۰ چرخه برای ورود به مدل LSTM سازمان‌دهی شدند. این فرایند باعث شد داده خام CMAPSS به نمایش‌های زمانی ساختاریافته‌ای تبدیل شود که هم برای مدل پیش‌بینی و هم برای جریان داده معماری پیشنهادی قابل استفاده هستند [۴۹].

در مرحله بعد، معماری پیشنهادی بر مسئله CMAPSS نگاشت شد. در این نگاشت، هر موتور به‌عنوان یک موجودیت مستقل، داده‌های حسگرها به‌عنوان جریان داده، لایه ادغام به‌عنوان مسئول استانداردسازی و تشکیل توالی، عامل دوقلوی دیجیتال به‌عنوان نگهدارنده وضعیت و عامل‌های کاربردی به‌عنوان ارائه‌دهندگان خدمات تحلیلی و تعاملی در نظر گرفته شدند. لازم است تأکید شود که در این پژوهش، داده CMAPSS یک داده شبیه‌سازی‌شده است و بنابراین دوقلوی دیجیتال پیاده‌سازی‌شده در آزمایش، بازنمایی نرم‌افزاری معماری مورد نظر است و نباید با یک دوقلوی دیجیتال صنعتی متصل به تجهیز واقعی یکسان تلقی شود. این تمایز باعث می‌شود ادعاهای مربوط به سطح پیاده‌سازی با شواهد آزمایشگاهی سازگار باقی بمانند [۲۱، ۲۲].

در سطح خدمات کاربردی، عامل پیش‌بینی مسئول تولید مقدار عددی عمر مفید باقیمانده با استفاده از مدل LSTM است، در حالی که عامل پایش وضعیت موتور را تحلیل می‌کند و عامل تعامل زبانی مسئول دریافت درخواست‌های طبیعی، تبدیل آن‌ها به عملیات ساختاریافته و ارائه پاسخ قابل فهم است. این تفکیک باعث می‌شود مدل زبانی جایگزین مدل تخصصی پیش‌بینی نشود و صحت مقدار عددی عمر مفید باقیمانده مستقل از کیفیت تعامل زبانی قابل ارزیابی باشد. همچنین، ساختار مذکور با اصول تفکیک نقش در سامانه‌های چندعاملی و رویکردهای ترکیب دوقلوهای دیجیتال و عامل‌های هوشمند سازگار است [۱۶، ۲۸].

در بخش پیش‌بینی، علاوه بر مدل زمانی LSTM، هزینه نامتقارن خطا نیز در تابع هدف لحاظ شد. تابع زیان Pinball با $\tau = 0.125$ به‌گونه‌ای انتخاب شد که بیش‌برآورد عمر مفید باقیمانده نسبت به کم‌برآورد جریمه بیشتری دریافت کند. این انتخاب بر این فرض کاربردی استوار است که بیش‌برآورد می‌تواند خطر به‌تعویق‌افتادن عملیات نگهداری را افزایش دهد؛ رویکردی که با ادبیات ریسک‌گریز در پیش‌بینی عمر مفید باقیمانده هم‌راستا است [۵۷]. با این حال، مقدار $\tau = 0.125$ یک انتخاب طراحی خاص این پژوهش است و ارزیابی تجربی آن برای تعیین سودمندی واقعی این سوگیری ضروری است.

در نهایت، چارچوب ارزیابی در دو سطح مدل و سامانه طراحی شد. در سطح مدل، معیارهای MAE، RMSE و R^2 برای اندازه‌گیری دقت عددی و نسبت کم‌برآورد برای بررسی رفتار جهت‌دار خطا استفاده می‌شوند. در سطح سامانه نیز زمان پاسخ، صحت مسیریابی درخواست و کیفیت پاسخ توضیحی برای ارزیابی عملکرد عامل‌ها در نظر گرفته شده‌اند. بنابراین، ارزیابی پیشنهادی تنها به این پرسش محدود نمی‌شود که مدل تا چه اندازه عمر مفید باقیمانده را دقیق پیش‌بینی می‌کند، بلکه دو پرسش تکمیلی را نیز بررسی می‌کند: آیا مدل به‌صورت کنترل‌شده از بیش‌برآورد اجتناب می‌کند؟ و آیا معماری چندعاملی می‌تواند پیش‌بینی عددی را به یک خدمت قابل استفاده و قابل تعامل تبدیل کند؟

بدین ترتیب، فصل حاضر چارچوب روش‌شناختی لازم برای آزمایش‌های فصل بعد را فراهم می‌کند. داده، نحوه تولید برچسب، پیش‌پردازش، تشکیل دنباله، نگاشت معماری، مدل پیش‌بینی و معیارهای ارزیابی به‌صورت جداگانه تعریف شده‌اند تا نتایج فصل بعد بتوانند به‌صورت قابل‌ردیابی به هر یک از این مؤلفه‌ها نسبت داده شوند. در فصل بعد، نتایج مدل پیش‌بینی، مقایسه با خطوط مبنا، رفتار تابع زیان نامتقارن و عملکرد اجزای چندعاملی گزارش و تحلیل خواهد شد.

فصل چهارم

پیاده‌سازی

۴-۱ مقدمه

در فصل سوم، معماری پیشنهادی دوقلوی دیجیتال چندعاملی و نحوه نگاشت اجزای آن به مسئله پیش‌بینی عمر مفید باقیمانده موتورهای توربوفن تشریح شد. هدف آن فصل، تعریف ساختار منطقی سامانه، تعیین مسئولیت عامل‌ها و مشخص کردن جریان داده و فرمان میان اجزای مختلف بود. در فصل حاضر، این معماری از سطح مفهومی به یک نمونه آزمایشگاهی قابل اجرا منتقل می‌شود و جزئیات پیاده‌سازی، نحوه استقرار، رابط‌های ارتباطی و فرایندهای عملیاتی سامانه ارائه می‌گردد.

پیاده‌سازی انجام‌شده صرفاً به توسعه یک مدل یادگیری عمیق برای تخمین عمر مفید باقیمانده محدود نیست، بلکه مجموعه‌ای از خدمات نرم‌افزاری را دربرمی‌گیرد که در کنار یکدیگر یک زنجیره عملیاتی کامل را تشکیل می‌دهند. این زنجیره از داده‌های خام مجموعه CMAPSS آغاز می‌شود، در عامل دوقلوی دیجیتال نگهداری و عرضه می‌گردد، توسط عامل پیش‌بینی برای تخمین عمر مفید باقیمانده پردازش می‌شود، در اختیار عامل پایش قرار می‌گیرد و در نهایت از طریق عامل تعامل زبانی به کاربر ارائه می‌شود. علاوه بر این، عامل زبانی می‌تواند بر اساس درخواست کاربر، فرمان‌هایی را به عامل دوقلو ارسال کند و اثر این فرمان‌ها از طریق عامل تابلو وضعیت مشاهده شود.

از آنجا که داده‌های CMAPSS ذاتاً یک جریان حسگری برخط نیستند و به‌صورت فایل‌های متنی ذخیره شده‌اند، در پیاده‌سازی حاضر سازوکاری برای شبیه‌سازی پیشرفت زمان و دریافت تدریجی داده‌ها طراحی شده است. از این طریق، امکان ارزیابی منطق پایش و تعامل عامل‌ها بدون نیاز به اتصال مستقیم به یک تجهیز فیزیکی فراهم شده است. از این منظر، سامانه حاضر یک نمونه آزمایشگاهی از معماری پیشنهادی به شمار می‌رود و نباید به‌عنوان یک دوقلوی دیجیتال صنعتی متصل به موتور واقعی تفسیر شود. با این حال، تفاوت این نمونه آزمایشگاهی با یک دوقلوی دیجیتال واقعی دارای موجودیت فیزیکی در صنعت، تنها در ورود داده اولیه است که به صورت برخط و از موجودیت فیزیکی واقعی نیست. این تمایز با تعریف دوقلوی دیجیتال به‌عنوان یک بازنمایی دیجیتال پویا و متصل به موجودیت فیزیکی سازگار است [۲۱، ۲۲].

ساختار این فصل از معرفی معماری پیاده‌سازی آغاز می‌شود و پس از تشریح روش استقرار، هر یک از عامل‌های اصلی بررسی می‌شوند. در ادامه، نحوه تعامل عامل‌ها در دو فرایند سرتاسری ارائه می‌شود تا انسجام عملی سامانه در سطح کاربرد نشان داده شود.

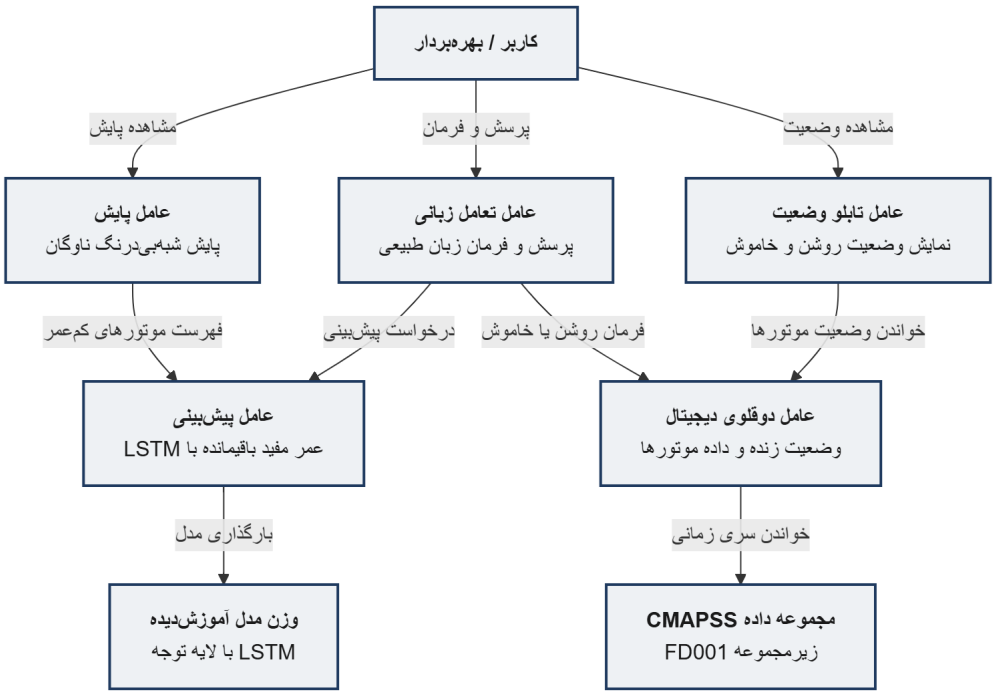
۴-۲ نمای کلی معماری پیاده‌سازی

سامانه آزمایشگاهی بر مبنای زیرمجموعه FD001 مجموعه داده CMAPSS پیاده‌سازی شده است و پنج عامل مستقل را ارائه می‌دهد. این عامل‌ها شامل عامل دوقلوی دیجیتال، عامل پیش‌بینی عمر مفید باقیمانده، عامل تعامل زبانی، عامل پایش و عامل تابلو وضعیت است. ساختار سامانه با هدف جداسازی مسئولیت‌ها طراحی شده است؛ به این معنا که نگهداری وضعیت، استنتاج عددی، تعامل زبانی و نمایش اطلاعات در یک مؤلفه واحد ادغام نشده‌اند.

این جداسازی از دیدگاه مهندسی سامانه اهمیت دارد، زیرا امکان تغییر هر جزء بدون بازطراحی کامل سایر اجزا را فراهم می‌کند. برای نمونه، مدل پیش‌بینی می‌تواند بدون تغییر رابط زبانی جایگزین شود یا رابط کاربری می‌تواند بدون تغییر منطق پیش‌بینی توسعه یابد [۲۵، ۲۸، ۲۹].

در پیاده‌سازی حاضر، ارتباط میان سرویس‌ها از طریق رابط‌های REST مبتنی بر HTTP برقرار شده است. این انتخاب باعث می‌شود مرز میان سرویس‌ها صریح باشد و هر عامل بتواند بدون وابستگی مستقیم به جزئیات داخلی عامل دیگر، از خدمات آن استفاده کند. شکل ۴-۱ ساختار پیاده‌سازی آزمایشگاهی را به‌صورت یکجا نشان می‌دهد. در این شکل، کاربر از سه مسیر به عامل‌های کاربرد متصل می‌شود. تعامل زبانی برای پرسش و فرمان، پایش برای مشاهده وضعیت سلامت موتورها و تابلو وضعیت برای مشاهده روشن یا خاموش بودن موتورها. عامل تعامل زبانی درخواست پیش‌بینی را به عامل پیش‌بینی و فرمان تغییر وضعیت را به عامل دوقلوی

دیجیتال ارسال می‌کند. عامل پایش فهرست موتورهای کم‌عمر را از عامل پیش‌بینی دریافت می‌کند و عامل تابلو وضعیت، وضعیت موتورها را از عامل دوقلو می‌خواند. در لایه داده، عامل پیش‌بینی به وزن مدل آموزش‌دیده و عامل دوقلو به داده‌های CMAPSS متکی است. این تفکیک نشان می‌دهد که استنتاج عددی، نگهداری وضعیت و تعامل کاربر در سرویس‌های مستقل پیاده‌سازی شده‌اند و از طریق قرارداد HTTP با یکدیگر ارتباط دارند.



شکل ۴-۱: نمای کلی معماری پیاده‌سازی: پنج عامل سامانه، کاربر و جریان ارتباط میان آن‌ها

۴-۲-۱ پشته فناوری

پشته فناوری سامانه با توجه به دو ملاحظه اصلی انتخاب شده است. نخست، تناسب ابزار با وظیفه مورد نظر و دوم، سهولت یکپارچه‌سازی میان اجزای ناهمگون سامانه. برای آماده‌سازی داده و آموزش مدل از زبان Python و کتابخانه‌های TensorFlow/Keras، pandas و scikit-learn استفاده شده است. سرویس‌های API با چارچوب FastAPI پیاده‌سازی شده‌اند و رابط‌های کاربری با استفاده از React توسعه یافته‌اند. عامل تعامل زبانی نیز بر بستر Dify Workflow پیاده‌سازی شده است.

جدول ۴-۱ اجزای اصلی پشته فناوری را نشان می‌دهد.

جدول ۴-۱: پشته فناوری سامانه به تفکیک مؤلفه

مؤلفه	فناوری مورد استفاده
آموزش مدل	Python 3.10، TensorFlow/Keras 2.17، pandas، scikit-learn 1.5.2، Jupyter Notebook
عامل پیش‌بینی	FastAPI 0.115، Uvicorn 0.32، TensorFlow
عامل دوقلو	FastAPI، pandas
عامل تعامل زبانی	Dify Workflow، مدل‌های زبانی OpenAI
عامل پایش	Create React App + React 18، nginx
عامل تابلو وضعیت	Vite 4 + React 18، nginx
هماهنگ‌سازی	Docker Compose و Bash
داده	CMAPSS FD001 (train/test/RUL)

۴-۲-۲ راه‌اندازی سرویس‌ها

پنج سرویس اصلی سامانه در محیط آزمایشگاهی به‌صورت مستقل مستقر شده‌اند. از نظر وابستگی اجرایی، سرویس‌های هسته یعنی عامل دوقلو و عامل پیش‌بینی باید در دسترس باشند تا عامل‌های کاربردی بتوانند درخواست‌های اولیه خود را بدون خطای اتصال ارسال کنند. جدول ۴-۲ مشخصات سرویس‌ها و درگاه‌های مورد استفاده را نشان می‌دهد.

جدول ۴-۲: مشخصات سرویس‌های سامانه و پورت مورد استفاده

ردیف	سرویس	مسیر پیاده‌سازی	درگاه
۱	عامل دوقلوی دیجیتال	DTAgent/	8001
۲	عامل پیش‌بینی	lstm-rul-api/	8000
۳	عامل تعامل زبان طبیعی	dify/	80/443
۴	عامل تابلو وضعیت	motor-dashboard/	3000
۵	عامل پایش	engine-monitor/	3001

ارتباطات میان سرویس‌ها از طریق HTTP انجام می‌شود و مسیرهای REST API مرز عملیاتی میان عامل‌ها را مشخص می‌کنند. جدول ۴-۳ مهم‌ترین ارتباط‌های میان سرویسی را نشان می‌دهد.

جدول ۴-۳: ماتریس ارتباط میان سرویس‌های سامانه

مبدأ	مقصد	قرارداد	پارامتر یا پیکربندی
عامل تعامل زبان طبیعی	عامل پیش‌بینی	HTTP GET	lstm_host_addr
عامل تعامل زبان طبیعی	عامل دوقلوی دیجیتال	HTTP POST	dt_host_addr
عامل تعامل زبان طبیعی	عامل پیش‌بینی	HTTP GET	REACT_APP_API_BASE_URL
عامل تابلو وضعیت	عامل دوقلوی دیجیتال	HTTP GET	VITE_API_URL

از منظر جریان داده، عامل زبان طبیعی تنها سرویسی است که در فرایندهای کنترلی، علاوه بر دریافت داده، امکان ارسال فرمان تغییر وضعیت به عامل دوقلوی دیجیتال را نیز دارد. بنابراین، این عامل در سطح کاربرد

به‌عنوان واسط تصمیم‌گیری برای کاربر عمل می‌کند.

۴-۳ روش استقرار سامانه

استقرار سامانه با استفاده از Docker و مجموعه فایل‌های Docker Compose انجام شده است. قطعه کد docker-up.sh مسئول راه‌اندازی سرویس‌های اصلی است و به‌جای متکی بودن به یک فایل واحد، هر سرویس را در قالب پیکربندی مستقل خود اجرا می‌کند. این روش امکان مدیریت جداگانه چرخه عمر سرویس‌ها را فراهم می‌سازد و در محیط آزمایشگاهی برای تکرارپذیری اجرای آزمایش، مناسب است.

یکی از متغیرهای مهم محیطی، HOST_IP است. در محیط کانتینری، مقدار localhost درون هر کانتینر به همان کانتینر اشاره می‌کند؛ ازاین‌رو برای دسترسی متقابل سرویس‌ها یا دسترسی مرورگر کاربر به رابط‌ها باید آدرس قابل دسترس میزبان به‌درستی تنظیم شود. در این پیاده‌سازی، همین آدرس برای برقراری ارتباط میان اجزای مختلف و دسترسی به رابط‌های کاربری استفاده شده است.

از نظر منابع سخت‌افزاری، آموزش مدل یادگیری عمیق پرهزینه‌ترین مرحله از نظر محاسباتی است و در محیط جداگانه با استفاده از GPU انجام شده است. پس از پایان آموزش، وزن‌های مدل در سرویس پیش‌بینی قرار می‌گیرند و فرایند استنتاج در محیط اجرایی سامانه به GPU مستقل نیاز ندارد. در نتیجه، در پیاده‌سازی حاضر میان محیط آموزش و محیط استقرار تفکیک ایجاد شده است.

۴-۴ عامل دوقلوی دیجیتال

۴-۴-۱ نقش عامل در معماری

عامل دوقلوی دیجیتال یکی از اجزای مرکزی سامانه است، زیرا هم مسئول ارائه داده‌های موتور به سایر اجزا است و هم وضعیت عملیاتی موتورها را نگهداری می‌کند. در پیاده‌سازی آزمایشگاهی، این سرویس بخشی از نقش لایه جمع‌آوری داده و بخشی از نقش لایه عامل‌های دوقلوی دیجیتال را بر عهده دارد. این تجمیع به دلیل ماهیت نمونه آزمایشگاهی صورت گرفته است و منطق مسئولیت‌ها در داخل سرویس تفکیک شده باقی مانده است.

برای هر موتور شناسه‌ای به‌صورت عدد صحیح در نظر گرفته شده است:

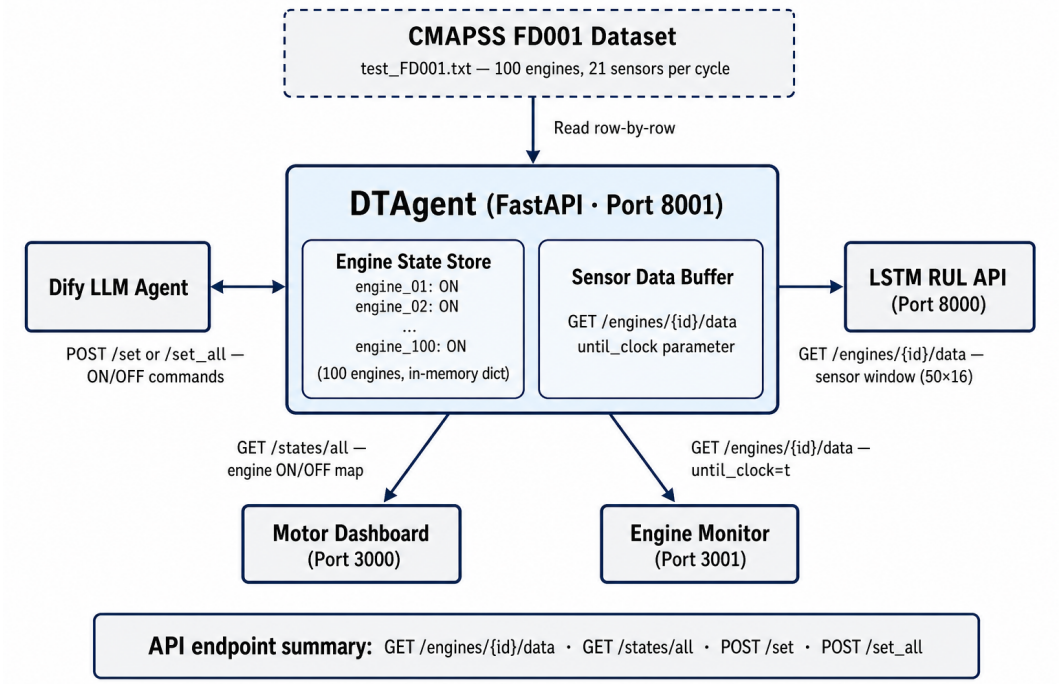
$$k \in \{1, \ldots, 100\}.$$

و وضعیت عملیاتی هر موتور به‌صورت یک متغیر گسسته تعریف می‌شود:

$$s_k \in \{\text{ON}, \text{OFF}\}.$$

در زمان راه‌اندازی، وضعیت تمام موتورهای موجود در مجموعه آزمون ON در نظر گرفته می‌شود. سپس این وضعیت می‌تواند به‌صورت انتخابی برای تعدادی از موتورها یا به‌صورت سراسری برای کل موتورها تغییر کند.

تصویر ۲-۴ سرویس‌های مربوط به عامل دوقلوی دیجیتال را به همراه ارتباط آن‌ها نشان می‌دهد. در این تصویر، شماره درگاه دسترسی به هر سرویس و هم چنین قابل مشاهده است.



شکل ۲-۴: ساختار داخلی عامل دوقلوی دیجیتال و ارتباط آن با داده‌های CMAPSS، عامل زبانی و رابط تابلو وضعیت

۲-۴-۴ ساختار داخلی سرویس

عامل دوقلوی دیجیتال از سه جزء اصلی تشکیل شده است. جزء نخست مخزن وضعیت موتور است که در پیاده‌سازی فعلی به‌صورت یک ساختار درون حافظه نگهداری می‌شود. جزء دوم، حافظه موقت داده‌های حسگری است که از خواندن مکرر فایل داده جلوگیری می‌کند. جزء سوم، رابط REST API است که دسترسی خواندنی به داده‌ها و دسترسی نوشتنی برای تغییر وضعیت را فراهم می‌کند.

۴-۴-۳ رابط برنامه‌نویسی

رابط برنامه‌نویسی عامل دوقلوی دیجیتال چند نقطه پایانی[1] برای دسترسی به داده و کنترل وضعیت فراهم می‌کند. نقاط پایانی خواندنی برای دریافت داده حسگرها و وضعیت موتورها و نقاط پایانی نوشتنی برای تغییر وضعیت موتورها استفاده می‌شوند.

جدول ۴-۴: نقاط پایانی رابط برنامه‌نویسی عامل دوقلو

متد	مسیر	ورودی	خروجی
GET	/engines/{engine_number}	until_clock	داده‌های حسگرهای یک موتور
GET	/engines/states/all	—	وضعیت تمامی موتورها
POST	/engines/states/set?state=ON|OFF	فهرست شناسه موتورها	وضعیت‌های به‌روزشده
POST	/engines/states/set_all?state=ON|OFF	وضعیت مقصد	وضعیت همه موتورها
GET	/	—	پیام سلامت سرویس

پارامتر until_clock یکی از عناصر اصلی سازوکار شبیه‌سازی زمانی است. عامل مصرف‌کننده می‌تواند به‌جای دریافت کل تاریخچه موتور، تنها داده‌های موجود تا چرخه مشخصی را درخواست کند. از این طریق، فایل ایستا به یک منبع داده پویا تبدیل می‌شود که امکان اجرای آزمایش‌های شبه‌بی‌درنگ را فراهم می‌کند.

۴-۴-۴ محدودیت وضعیت درون‌حافظه‌ای

وضعیت ON/OFF در حافظه سرویس نگهداری می‌شود. در نتیجه، با راه‌اندازی مجدد کانتینر، وضعیت اولیه مجدداً ایجاد می‌شود و موتورها به حالت ON بازمی‌گردند. همچنین به دلیل هزینه بالای حافظه موقت، در صورت بالا رفتن حجم داده‌ای که ذخیره می‌شود، مقیاس‌پذیری و افزایش ظرفیت آن دشوار است. زمانی این امکان وجود دارد که تعداد موتورها بسیار بالا و وضعیت ذخیره شده برای هرکدام بسیار پر حجم – شامل مؤلفه‌های زیاد و دارای اطلاعات باینری مانند تصویر یا فیلم – باشد. با این حال، تا زمانی که این روش ذخیره‌سازی مشکل هزینه و بازدهی ایجاد نکند، می‌توان به استفاده آن ادامه داد.

۴-۵ عامل پیش‌بینی عمر مفید باقیمانده

۴-۵-۱ معماری شبکه پیش‌بینی

در عامل پیش‌بینی عمر مفید باقیمانده، از یک شبکه بازگشتی چندلایه مبتنی بر LSTM استفاده شده است. انتخاب این ساختار با توجه به ماهیت ترتیبی و چندمتغیره داده‌های CMAPSS انجام شده است؛ زیرا وضعیت موتور در هر چرخه به مجموعه‌ای از اندازه‌گیری‌های حسگری وابسته است و تغییرات متوالی این اندازه‌گیری‌ها

[1] End Point

می‌توانند اطلاعات مهمی درباره روند فرسایش و نزدیک‌شدن به خرابی فراهم کنند.

معماری مدل از سه لایه بازگشتی LSTM تشکیل شده است. لایه نخست دارای ۱۲۸ واحد و لایه دوم دارای ۶۴ واحد است. خروجی این دو لایه به‌صورت دنباله‌ای حفظ می‌شود تا اطلاعات زمانی برای لایه بازگشتی بعدی در دسترس باشد. لایه سوم دارای ۳۲ واحد است و خروجی نهایی آن به دو لایه کاملاً متصل منتقل می‌شود.

در بخش انتهایی شبکه، دو لایه Dense به‌ترتیب با ۹۶ و ۱۲۸ نورون و تابع فعال‌سازی ReLU قرار دارند. در نهایت، یک نورون خروجی با فعال‌سازی خطی مقدار عددی عمر مفید باقیمانده را تولید می‌کند. ساختار شبکه در جدول ۴-۵ خلاصه شده است.

جدول ۴-۵: معماری شبکه پیش‌بینی عمر مفید باقیمانده

لایه	مشخصات	نقش
Input	30×14	دریافت پنجره زمانی ۳۰ چرخه‌ای با ۱۴ ویژگی
LSTM-1	۱۲۸ واحد، tanh	استخراج الگوهای زمانی اولیه
LSTM-2	۶۴ واحد، tanh	استخراج نمایش بازگشتی سطح بالاتر
LSTM-3	۳۲ واحد، tanh	فشرده‌سازی اطلاعات زمانی در یک نمایش نهایی
Dense-1	۹۶ واحد، ReLU	یادگیری روابط غیرخطی میان ویژگی‌های استخراج‌شده
Dense-2	۱۲۸ واحد، ReLU	پردازش و تبدیل نمایش نهفته
Output	یک واحد، خطی	تولید مقدار پیش‌بینی‌شده عمر مفید باقیمانده

۴-۵-۲ پارامترهای آموزش

پارامترهای اصلی آموزش مدل پیش‌بینی در جدول ۴-۶ ارائه شده‌اند. این پارامترها در هر دو پیکربندی مدل پایه و مدل مبتنی بر تابع زیان نامتقارن یکسان نگه داشته شده‌اند تا تفاوت نتایج تا حد امکان به تغییر تابع زیان نسبت داده شود.

در هر دو مدل، بهینه‌ساز Adam با نرخ یادگیری اولیه ۰٫۰۰۱ به‌کار گرفته شده است. همچنین، برای تنظیم نرخ یادگیری از یک زمان‌بند استفاده شده است؛ به‌گونه‌ای که نرخ یادگیری در پنج دوره ابتدایی برابر ۰٫۰۰۱ بوده و از دوره ششم به بعد به ۰٫۰۰۰۱ کاهش یافته است.

اندازه دسته برابر ۱۲۸ انتخاب شده است. بنابراین، در هر مرحله به‌روزرسانی وزن‌ها، ۱۲۸ نمونه آموزشی پردازش می‌شوند که هر نمونه شامل یک پنجره ۳۰ چرخه‌ای با ۱۴ ویژگی است. در نتیجه، ابعاد ورودی هر دسته آموزشی به‌صورت $128 \times 30 \times 14$ خواهد بود.

آموزش هر مدل در ۵۰ دوره انجام شده است. برای ارزیابی روند یادگیری، مجموعه اعتبارسنجی شامل ۲۰

جدول ۴-۶: پارامترهای اصلی آموزش مدل پیش‌بینی

پارامتر	مقدار
طول پنجره ورودی	۳۰ چرخه
تعداد ویژگی‌های ورودی	۱۴ ویژگی
بهینه‌ساز	Adam
نرخ یادگیری اولیه	0.001
نرخ یادگیری پس از دوره پنجم	0.0001
اندازه دسته	۱۲۸
تعداد دوره‌های آموزش	۵۰
نسبت آموزش به اعتبارسنجی	۸۰ به ۲۰
بذر تصادفی تقسیم داده	۸۳
تابع زیان مدل پایه	MSE
تابع زیان مدل دوم	PinballLoss، $\tau = 0.125$

درصد نمونه‌های توالی در نظر گرفته شده و در طول آموزش مورد استفاده قرار گرفته است. این مجموعه در به‌روزرسانی وزن‌های شبکه مشارکت ندارد و صرفاً برای محاسبه خطای اعتبارسنجی به کار می‌رود.

تفاوت اصلی دو پیکربندی در تابع زیان آن‌هاست. در مدل پایه از خطای میانگین مربعات (MSE) استفاده شده است؛ در حالی که مدل دوم با تابع زیان نامتقارن Pinball و ضریب $\tau = 0.125$ آموزش داده شده است. بدین ترتیب، ساختار شبکه و تنظیمات اصلی آموزش ثابت نگه داشته شده و امکان بررسی اثر تغییر تابع زیان بر رفتار پیش‌بینی فراهم می‌شود.

۴-۵-۳ سرویس پیش‌بینی

پس از پایان آموزش، مدل در قالب یک سرویس مستقل REST API مبتنی بر FastAPI مورد استفاده قرار گرفته است. مدل در هنگام راه‌اندازی سرویس بارگذاری می‌شود تا هزینه بارگذاری اولیه در اولین درخواست کاهش یابد. ساختار بارگذاری مدل به‌گونه‌ای است که در صورت بروز خطا، سرویس دچار شکست نشود و نقاط پایانی بتوانند خطای مناسب را گزارش کنند.

مهم‌ترین نقاط پایانی سرویس در جدول ۴-۷ ارائه شده‌اند.

جدول ۴-۷: نقاط پایانی عامل پیش‌بینی

متد	مسیر	کاربرد
GET	/api/health	بررسی سلامت سرویس
GET	/api/predict/predict_rul/{engine_number}	پیش‌بینی RUL برای موتور مشخص
GET	/api/predict/engines_with_low_rul/	شناسایی موتورهای کم‌عمر
POST	/api/predict/predict_new_engine_rul/	پیش‌بینی برای توالی دلخواه

نقطه پایانی predict_rul پرکاربردترین مسیر سرویس است. این نقطه پس از دریافت شناسه موتور، داده لازم

را از مجموعه آزمون استخراج می‌کند، آخرین پنجره زمانی معتبر را می‌سازد، مدل را اجرا می‌کند و مقدار عمر مفید باقیمانده را در قالب پاسخ JSON بازمی‌گرداند.

یک نمونه ساختار پاسخ به‌صورت زیر است:

```
{
 "engine_number": 10,
 "predicted_rul": 164.67
}
```

این ساختار باعث می‌شود خروجی مدل عددی از منطق واسط کاربر مستقل باقی بماند و سایر عامل‌ها بتوانند بدون وابستگی به قالب نمایشی، مقدار پیش‌بینی‌شده را مصرف کنند.

۴-۶ عامل تعامل زبانی

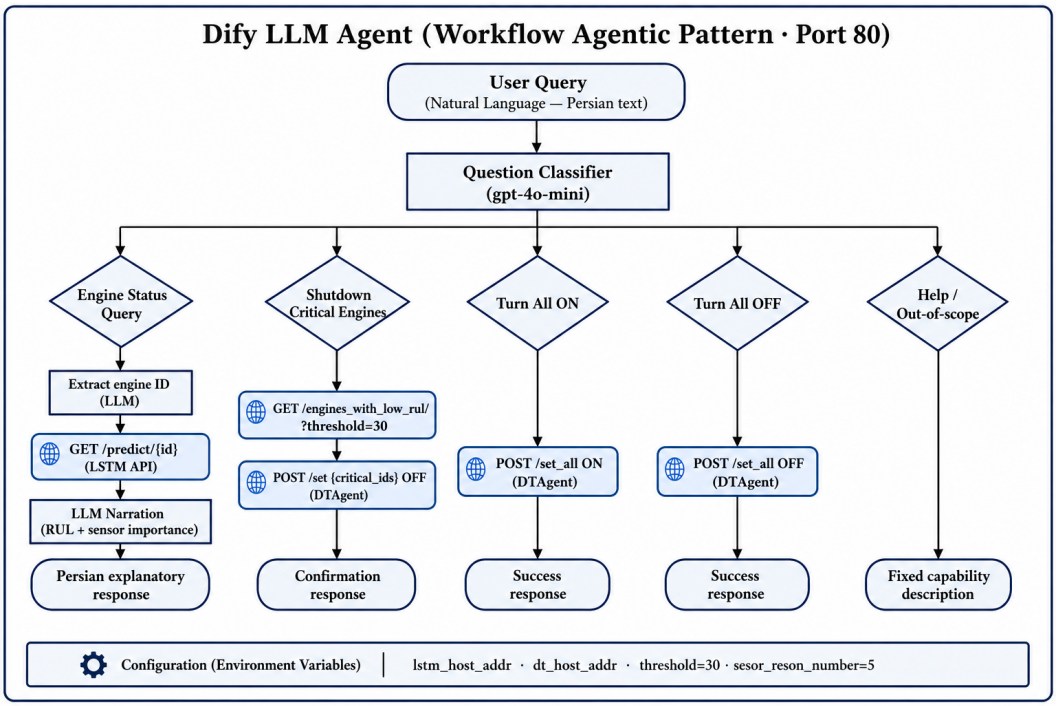
۴-۶-۱ الگوی طراحی

عامل تعامل زبانی واسط میان کاربر و خدمات تخصصی سامانه است. به‌جای آنکه مدل زبانی آزادانه مسیر انجام هر درخواست را تعیین کند، یک روندکار[1] از پیش تعریف‌شده در Dify ایجاد شده است. در این ساختار، ابتدا سوال کاربر دسته‌بندی می‌شود و سپس درخواست مطابق همان دسته، به یک مسیر مشخص هدایت می‌گردد.

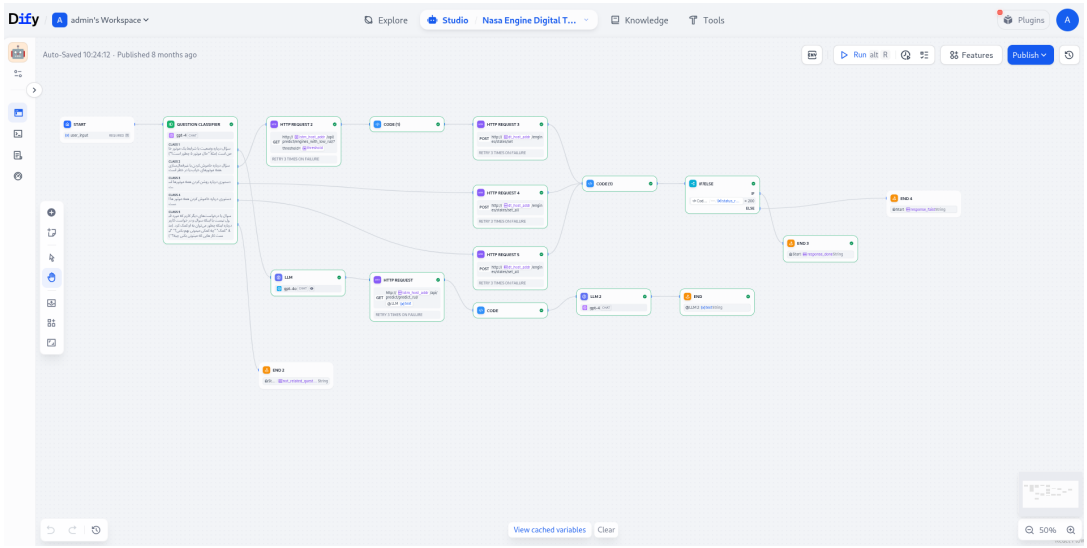
انتخاب روندکار کنترل‌شده برای مسئله حاضر از آن جهت اهمیت دارد که بدون نیاز به نوشتن کد سطح پایین، می‌توان قابلیت‌های متنوعی به عامل زبان طبیعی اضافه کرد و دستورات جدیدی پشتیبانی داد. بنابراین، استفاده از روندکار برای ایجاد عامل، انعطاف‌پذیری قابل توجهی را برای عامل ایجاد می‌کند به طوری که در هر لحظه، بتوان به سادگی کارکرد آن را تغییر داد یا بهبود بخشید. این دیدگاه با پژوهش‌های جدید درباره ادغام مدل‌های زبانی بزرگ و دوقلوهای دیجیتال که بر نقش مدل زبانی به‌عنوان واسط تعامل و تحلیل سطح‌بالا تأکید می‌کنند، هم‌راستا است [۹].

تصویر ۴-۳ معماری داخلی عامل مدل زبانی بزرگ را که با استفاده از Dify ایجاد شده است، نشان می‌دهد. در ابتدا طبق سوالی که کاربر پرسیده است، تشخیص داده می‌شود که سوال کاربر در کدام دسته قرار میگیرد. سپس بر اساس دسته‌ای که تشخیص داده شده است، نقاط پایانی مناسب استفاده می‌شود. در نهایت هم پاسخ مناسب برای کاربر ایجاد شده و نمایش داده می‌شود. تصویر ۴-۴ نیز روندکار ایجاد شده در محیط Dify نشان داده می‌شود.

[1] Workflow



شکل ۴-۳: ساختار Workflow عامل تعامل زبانی و مسیرهای اصلی پردازش درخواست



شکل ۴-۴: نمای Workflow پیاده‌سازی‌شده در محیط Dify و انشعاب مسیرهای تصمیم بر اساس سوال کاربر

۴-۶-۲ فضای نیت و مسیرهای تصمیم

فضای نیت بر اساس قابلیت‌های مورد نیاز سامانه تعریف شده است. در مجموع پنج کلاس اصلی برای درخواست کاربر، در نظر گرفته شده است که هر کدام مسیر اجرایی مشخصی دارند.

یکی از ویژگی‌های این طراحی آن است که همه شاخه‌ها نیازمند فراخوانی مدل زبانی بزرگ نیستند. در شاخه‌های فرمان سراسری، درخواست پس از تشخیص نیت می‌تواند مستقیماً به فراخوانی مناسب HTTP تبدیل

جدول ۴-۸: کلاس‌های نیت و اقدام متناظر در عامل تعامل زبانی

ردیف	نیت	نمونه ورودی	اقدام
۱	وضعیت یک موتور	«موتور ۱ چه زمانی خراب می‌شود؟»	استخراج شناسه و فراخوانی سرویس پیش‌بینی
۲	خاموش‌سازی موتورهای در خطر	«موتورهای در خطر را خاموش کن»	دریافت فهرست کم‌عمرها و ارسال فرمان OFF
۳	روشن کردن همه موتورها	«همه موتورها را روشن کن»	ارسال فرمان set_all ON
۴	خاموش کردن همه موتورها	«همه موتورها را خاموش کن»	ارسال فرمان set_all OFF
۵	راهنما یا خارج از حوزه	«چه کمکی می‌توانی بکنی؟»	نمایش فهرست قابلیت‌های سامانه

شود. در مقابل، شاخه وضعیت موتور به پردازش زبانی بیشتری نیاز دارد، زیرا ابتدا باید شناسه موتور از متن طبیعی استخراج و سپس پاسخ قابل فهم برای کاربر تولید شود.

۴-۶-۳ نقاط پایانی HTTP و پیکربندی

نقاط پایانی HTTP پل ارتباطی میان روندکار و سرویس‌های تخصصی هستند. مسیرهای اصلی این نقاط در جدول ۴-۹ ارائه شده‌اند.

جدول ۴-۹: نقاط پایانی HTTP مورد استفاده در Workflow عامل زبانی

متد	مسیر	کاربرد
GET	/api/predict/predict_rul/{id}	دریافت RUL موتور مشخص
GET	/api/predict/engines_with_low_rul/?threshold=	دریافت فهرست موتورهای کم‌عمر
POST	/engines/states/set?state=OFF	خاموش‌سازی انتخابی
POST	/engines/states/set_all?state=ON	روشن کردن سراسری
POST	/engines/states/set_all?state=OFF	خاموش کردن سراسری

متغیرهای محیطی به‌عنوان لایه پیکربندی میان روندکار و زیرساخت سرویس‌ها عمل می‌کنند. مهم‌ترین متغیرها در جدول ۴-۱۰ آمده‌اند.

جدول ۴-۱۰: متغیرهای محیطی اصلی عامل تعامل زبانی

متغیر	نمونه مقدار	کاربرد
lstm_host_addr	10.226.63.45:8000	آدرس عامل پیش‌بینی
dt_host_addr	10.226.63.45:8001	آدرس عامل دوقلو
threshold	30	آستانه تشخیص موتور در خطر
sesor_reson_number	5	تعداد متغیرهای نمایش‌داده‌شده در پاسخ
response_done	متن فارسی	پیام موفقیت عملیات
not_related_question	متن فارسی	پاسخ خارج از حوزه

۴-۶-۴ نمونه‌های عملیاتی

در نخستین نمونه ۴-۵ ، کاربر پرسشی خارج از محدوده عملیاتی سامانه مطرح می‌کند یا از عامل می‌خواهد که قابلیت‌های خود را بیان کند. عامل با فعال کردن شاخه راهنما، قابلیت‌های قابل ارائه را بدون اجرای عملیات تحلیلی اضافی نمایش می‌دهد.

> **کاربر:** چه کمکی می‌توانی به من بکنی؟

> **دستیار (ناسا):**
> سلام! من **ناسا** هستم و می‌توانم دربارهٔ وضعیت و عملکرد موتورهای شبیه‌سازی‌شدهٔ دوقلوی مجازی موتورهای **CMAPSS** به تو کمک کنم. کارهایی که می‌توانی از من بخواهی عبارت‌اند از:
>
> **۱. بررسی وضعیت یک موتور خاص**
> می‌توانم وضعیت عملکردی یک موتور مشخص را برایت تحلیل کنم.
> *مثال‌ها:*
> - موتور ۴ در چه شرایطی است؟
> - موتور ۱۰ چه زمانی خراب می‌شود؟
>
> **۲. خاموش کردن موتورهای در خطر**
> می‌توانم موتورهایی را که در خطر خرابی هستند خاموش کنم تا از آسیب بیشتر جلوگیری شود.
> *مثال‌ها:*
> - موتورهای در خطر را خاموش کن.
>
> **۳. خاموش کردن همهٔ موتورها**
> می‌توانم در صورت نیاز، همهٔ موتورها را به‌طور هم‌زمان خاموش کنم.
> *مثال‌ها:*
> - همهٔ موتورها را خاموش کن.
>
> **۴. روشن کردن همهٔ موتورها**
> می‌توانم همهٔ موتورها را روشن کنم تا دوباره سیستم فعال شود.
> *مثال‌ها:*
> - همهٔ موتورها را روشن کن.

شکل ۴-۵: نمونه پاسخ عامل زبانی در شاخه راهنما و معرفی قابلیت‌های سامانه

در نمونه دوم که در تصویر ۴-۶ قابل مشاهده است، پرس‌وجو برای موتور ۲ را نمایش می‌دهد. موتور ۲ دارای مقدار پیش‌بینی‌شده عمر مفید باقیمانده برابر ۷۷.۶۳ چرخه است. این مقدار نسبت به آستانه که ۳۰ چرخه است فاصله زیادی دارد و در نتیجه موتور در محدوده عادی قرار می‌گیرد. همچنین در نمونه سوم که در تصویر ۴-۷ مشاهده می‌شود، پرس‌وجو برای موتور ۲۴ را نمایش می‌دهد. موتور ۲۴ دارای مقدار عمر مفید باقیمانده برابر ۴۱.۲۷ چرخه است که پایین‌تر از آستانه ۳۰ قرار می‌گیرد و در نتیجه وضعیت بحرانی برای آن گزارش می‌شود.

در این نمونه‌ها، عامل زبانی مقدار RUL را خود تولید نمی‌کند، بلکه آن را از سرویس تخصصی دریافت

کاربر: وضعیت موتور ۲ چطور است؟

دستیار (ناسا):

RUL وضعیت فعلی موتور بر اساس مقدار پیش‌بینی‌شده برابر با **۵۵.۱۴۰** سیکل است که بیشتر از حد بحرانی ۳۰ سیکل می‌باشد، بنابراین وضعیت موتور در وضعیت **عادی** قرار دارد.

سنسورهای مؤثر در این مقدار RUL به ترتیب اهمیت عبارت‌اند از:

- **T۳۰** (دمای کل در خروجی HPC): افزایش غیرعادی در این سنسور ممکن است نشان‌دهندهٔ فرسودگی یا مشکل در بخش HPC باشد.
- **Ps۳۰** (فشار استاتیک در خروجی HPC): تغییرات آن می‌تواند نشان‌دهندهٔ کاهش کارایی سیستم باشد.
- **NRf** (سرعت اصلاح‌شده فن): کاهش یا افزایش ناگهانی آن می‌تواند نشانهٔ مشکلات مکانیکی باشد.
- **BPR** (نسبت فشار عبوری): تغییرات آن نشان‌دهندهٔ تغییر در وضعیت عملکرد موتور است.
- **Nf** (سرعت فن): نوسان‌های غیرعادی در آن ممکن است نشان‌دهندهٔ مشکل مکانیکی باشد.

. پیشنهاد عملیاتی:

- اگر **RUL** بیشتر از **threshold** (سیکل ۳۰) باقی بماند، **ادامهٔ پرواز** با موتور بلامانع است.
- اگر **RUL** کاهش یابد ولی بیشتر از نصف **threshold** (سیکل ۱۵) باقی بماند، **برنامه‌ریزی تعمیر** برای موتور توصیه می‌شود.
- اگر **RUL** کمتر از نصف **threshold** (سیکل ۱۵) باشد، **بازرسی فوری** و ارزیابی کامل ضروری است.

شکل ۴-۶: نمونه پاسخ عامل زبانی برای پرس‌وجوی وضعیت موتور شماره ۲ و تبدیل خروجی عددی به روایت فارسی ساختاریافته

کرده و به زبان طبیعی تفسیر می‌کند. این تفکیک از نظر روش‌شناختی مهم است، زیرا ارزیابی مقدار عددی پیش‌بینی می‌تواند مستقل از ارزیابی کیفیت پاسخ زبانی انجام شود.

۴-۷ عامل پایش شبه‌بی‌درنگ

۴-۷-۱ شبیه‌سازی جریان زمانی

مجموعه داده CMAPSS به‌صورت فایل ایستا ارائه شده است و به‌خودی‌خود یک جریان حسگری برخط ایجاد نمی‌کند. برای بازنمایی رفتار یک سامانه پایش، عامل پایش از یک ساعت منطقی استفاده می‌کند که با گذشت هر دوره زمانی افزایش می‌یابد:

$$t_{\text{clock}} \leftarrow t_{\text{clock}} + \Delta t. \tag{۴-۱}$$

در هر تکرار، مقدار t_{clock} به سرویس پیش‌بینی ارسال می‌شود:

```
GET /api/predict/engines_with_low_rul/
?threshold=theta&until_clock=t
```

کاربر: وضعیت موتور ۲۴ چطور است؟

دستیار (ناسا):

RUL وضعیت فعلی موتور بر اساس مقدار پیش‌بینی‌شده برابر با **۴۱.۲۷** سیکل است که کمتر از حد بحرانی ۳۰ سیکل است؛ بنابراین وضعیت این موتور **بحرانی** است و نیازمند اقدامات فوری است. سنسورهای مؤثر در این مقدار RUL، به شرح زیر هستند:

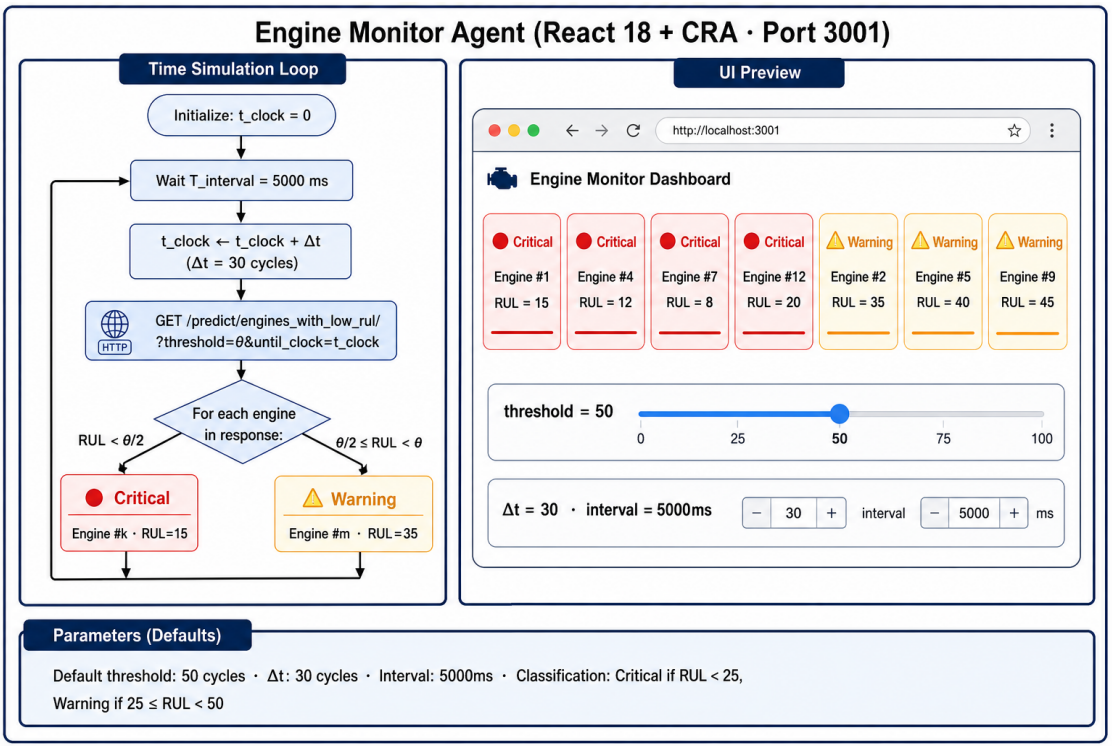
- **T۳۰** و **Ps۳۰**، هر دو با درصد ۶.۳۶، نشان می‌دهند که فشار و دمای خروجی از HPC در وضعیت غیرعادی قرار دارند و ممکن است نشان‌دهنده فرسودگی یا نقص در این بخش باشند.
- **T۲۴**، با درصد ۴۳.۷، اهمیت کمتری دارد ولی در کنار سایر سنسورها، نشانه‌ای از وضعیت فنی موتور است.
- **BPR**، با درصد ۶۵.۵، نشان‌دهنده تغییر در نسبت فشارهای بای‌پس است که می‌تواند بر کارکرد موتور تأثیر بگذارد.
- **phi**، با درصد ۰۸.۵، اشاره به نرخ سوخت و هوا دارد که ممکن است در ادامه منجر به کاهش عمر موتور شود.

. پیشنهاد عملیاتی:

- اگر **RUL** کمتر از نصف ۳۰، یعنی زیر ۱۵ سیکل باشد، **بازرسی فوری** و بررسی کامل موتور ضروری است تا علت کاهش RUL مشخص و برطرف شود.
- اگر **RUL** بین ۱۵ و ۳۰ باشد، **برنامه‌ریزی تعمیر و نگهداری** انجام شود تا پیش از رسیدن به وضعیت بحرانی، مشکل برطرف و عمر مفید موتور حفظ شود.
- اگر **RUL** بیشتر از ۳۰ باشد، ادامهٔ پرواز با نظارت مداوم مجاز است، اما اقدامات پیشگیرانه و مانیتورینگ دقیق باید ادامه یابد.

شکل ۴-۷: گفتگوی کاربر با دستیار هوشمند دربارهٔ وضعیت موتور (RUL ۲۴ = ۴۱.۲۷ سیکل — وضعیت بحرانی)

پارامتر until_clock باعث می‌شود مدل فقط اطلاعات موجود تا زمان شبیه‌سازی‌شده را مشاهده کند. در نتیجه، پیشرفت زمان باعث تغییر توالی داده ورودی و در نهایت تغییر مقدار RUL پیش‌بینی‌شده می‌شود. تصویر ۴-۸ رابط کاربری به همراه منطق چگونگی شبیه‌سازی پایش بی‌درنگ این عامل را نمایش می‌دهد.



شکل ۴-۸: معماری عامل پایش شبه‌بی‌درنگ؛ بخش سمت چپ منطق پیشرفت زمان و فراخوانی API و بخش سمت راست رابط کارت‌محور پایش را نشان می‌دهد

۴-۷-۲ مؤلفه‌های پایش

عامل پایش سه مؤلفه اصلی دارد که شامل آستانه ورود به فهرست پایش، گام زمانی شبیه‌سازی و فاصله زمانی میان دو اجرای متوالی حلقه است.

جدول ۴-۱۱: پارامترهای پیش‌فرض عامل پایش

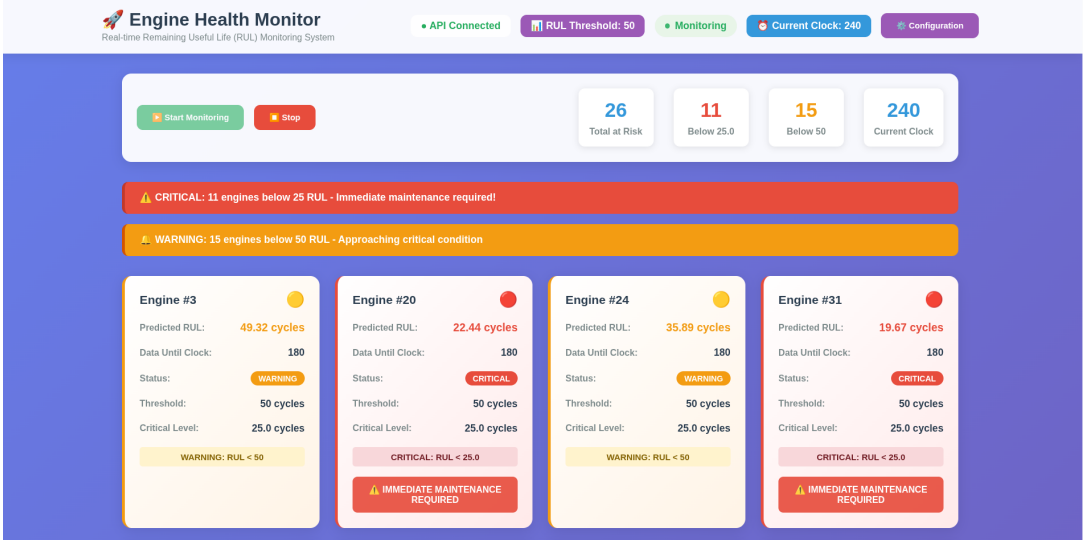
پارامتر	مقدار	توضیح
threshold (θ)	۵۰ چرخه	آستانه ورود به فهرست پایش
step (Δt)	۳۰ چرخه	میزان پیشرفت ساعت شبیه‌سازی در هر گام
interval	۵۰۰۰ میلی‌ثانیه	فاصله زمانی اجرای حلقه
آستانه بحرانی	۲۵ چرخه	مرز تفکیک وضعیت هشدار و بحرانی (نصف θ)

بر اساس این تنظیم، با گذشت زمان، موتوری که عمر مفید باقیمانده آن کمتر از ۵۰ چرخه شود وارد فهرست پایش می‌شود و وضعیت آن به صورت هشدار[1] اعلام می‌شود. پس از گذشت زمان بیشتر، موتورها به آستانه عمر مفید خود نزدیک‌تر می‌شوند و در نتیجه میزان عمر مفید باقیمانده پیش‌بینی شده برای آن‌ها به کمتر از ۲۵ میرسد. در این لحظه وضعیت موتور به صورت بحرانی[2] گزارش می‌شود.

[1] Warning
[2] Critical

۴-۷-۳ رابط کاربری عامل پایش

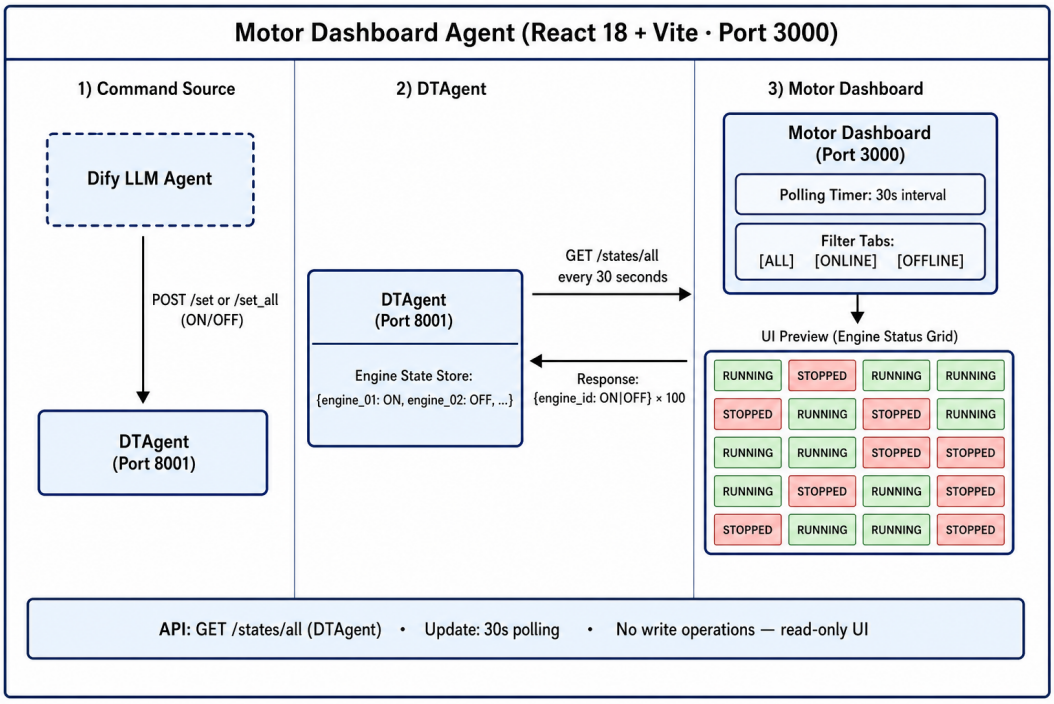
رابط کاربری عامل پایش وضعیت موتورهای کم‌عمر را با کارت‌های جداگانه نمایش می‌دهد. استفاده از کدگذاری رنگی باعث می‌شود کاربر بتواند وضعیت موتورها را بدون بررسی جداگانه مقدار عمر مفید باقیمانده در هر موتور ارزیابی کند. در تصویر ۴-۹ این کارت‌ها قابل مشاهده هستند. همچنین امکان تنظیم گام زمانی و دوره تکرار حلقه در رابط کاربری فراهم شده است.



شکل ۴-۹: رابط عامل پایش پس از فعال شدن ناوگان؛ کارت‌های هشدار و بحرانی بر اساس مقدار RUL نمایش داده می‌شوند

۴-۸ عامل تابلو وضعیت

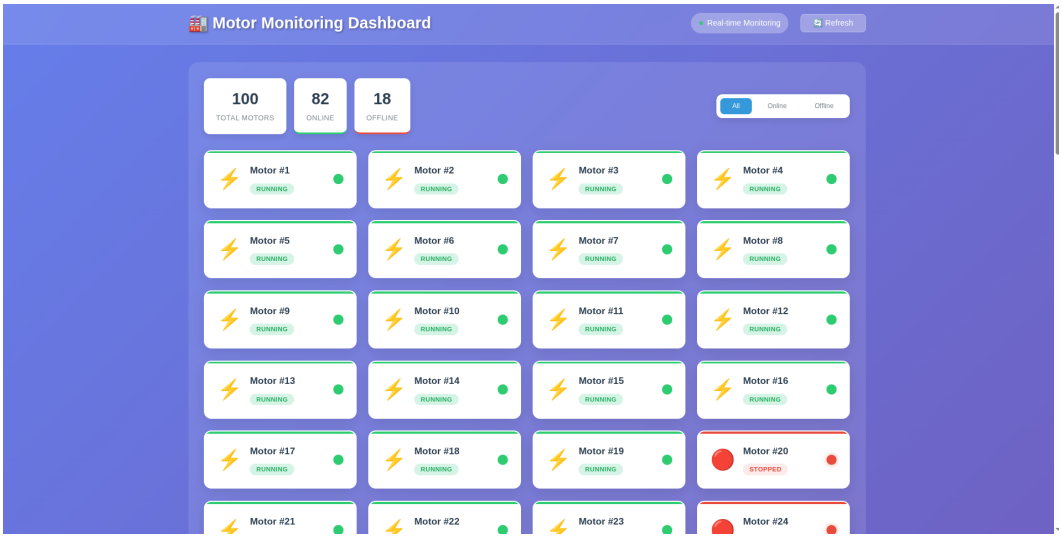
عامل تابلو وضعیت وظیفه نمایش وضعیت عملیاتی موتورها را بر عهده دارد. برخلاف عامل پایش، این عامل وارد فرایند پیش‌بینی نمی‌شود و صرفاً وضعیت ثبت‌شده در عامل دوقلو را نمایش می‌دهد. در نتیجه، مرز میان منطق تحلیلی و منطق نمایش در این سرویس حفظ شده است.



شکل ۴-۱۰: معماری عامل تابلو وضعیت و جریان یک‌طرفه اطلاعات از عامل دوقلو به رابط نمایش

همانطور که در تصویر ۴-۱۰ قابل مشاهده است، وضعیت موتورها در دوقلوی دیجیتال از طریق عامل مدل‌های زبانی بزرگ می‌تواند تغییر کند و این وضعیت به صورت در لحظه، در عامل تابلو وضعیت قابل مشاهده است. برای دریافت وضعیت جدید، عامل تابلو وضعیت از الگوی نظرسنجی دوره‌ای استفاده می‌کند. فاصله پیش‌فرض بین درخواست‌ها ۳۰ ثانیه است. این روش در یک محیط آزمایشگاهی ساده و کم‌هزینه است، اگرچه در یک سامانه صنعتی با نیاز به بازخورد فوری می‌توان از سازوکارهای رویدادمحور مانند WebSocket یا Server-Sent Events نیز استفاده کرد.

رابط کاربری از سه فیلتر اصلی ALL، ONLINE و OFFLINE استفاده می‌کند. این فیلترها امکان تمرکز کاربر روی بخش مشخصی از موتورها را فراهم می‌کنند. رابط کاربری عامل در تصویر ۴-۱۱ قابل مشاهده است.



شکل ۴-۱۱: رابط کاربری عامل تابلو وضعیت و فیلترهای ALL، ONLINE و OFFLINE

در نتیجه، عامل تابلو وضعیت را می‌توان یک واسط مشاهده‌گر دانست که وظیفه اصلی آن انتقال وضعیت داخلی دوقلوی دیجیتال به یک نمایش قابل فهم برای کاربر است.

۴-۹ فرایندهای سرتاسری سامانه

برای ارزیابی انسجام معماری در سطح عملیاتی، دو فرایند اصلی در سامانه اجرا شده است. فرایند اول بر دریافت اطلاعات و پاسخ‌گویی تمرکز دارد و فرایند دوم مسیر تصمیم و کنترل را بررسی می‌کند.

۴-۹-۱ فرایند اول: پرس‌وجوی وضعیت موتور

در این فرایند، کاربر یک پرسش فارسی درباره وضعیت موتور مطرح می‌کند. درخواست ابتدا وارد روندکار عامل زبانی می‌شود و نیت مربوط به «وضعیت موتور» تشخیص داده می‌شود. سپس شناسه موتور از متن استخراج و درخواست پیش‌بینی به سرویس مربوط ارسال می‌شود.

عامل پیش‌بینی آخرین پنجره زمانی معتبر موتور را دریافت کرده و مقدار عمر مفید باقیمانده را محاسبه می‌کند. پاسخ عددی به صورت ساختاریافته به عامل زبانی بازمی‌گردد و این عامل مقدار عددی را با توجه به آستانه‌های تعریف‌شده تفسیر کرده و به زبان طبیعی فارسی ارائه می‌کند.

۴-۹-۲ فرایند دوم: خاموش‌سازی موتورهای در خطر

در فرایند دوم، اپراتور دستور می‌دهد موتورهای در خطر خاموش شوند. عامل زبانی ابتدا فهرست موتورهایی را که عمر مفید باقیمانده آن‌ها از آستانه پایین‌تر است از عامل پیش‌بینی دریافت می‌کند. سپس شناسه این موتورها را به عامل دوقلوی دیجیتال ارسال کرده و فرمان OFF اجرا می‌شود.

پس از تغییر وضعیت، عامل تابلو وضعیت در نظرسنجی بعدی وضعیت جدید موتور را مشاهده می‌کند و کارت موتور از RUNNING به STOPPED تغییر می‌یابد. هم‌زمان، عامل پایش در اجرای بعدی حلقه خود، موتور خاموش‌شده را دیگر در فهرست موتورهای فعال کم‌عمر قرار نمی‌دهد. این مسیر نشان‌دهنده شکل‌گیری یک حلقه بسته میان پیش‌بینی، تصمیم، کنترل و بازخورد است.

۱۰-۴ جمع‌بندی

در این فصل، معماری پیشنهادی فصل سوم در قالب یک نمونه آزمایشگاهی متشکل از پنج سرویس مستقل پیاده‌سازی شد. عامل دوقلو وظیفه نگهداری داده و وضعیت موتورها را بر عهده گرفت، عامل پیش‌بینی عمر مفید باقیمانده را محاسبه کرد، عامل زبانی امکان تعامل طبیعی و ارسال فرمان را فراهم نمود و دو عامل پایش و تابلو وضعیت، وضعیت سامانه را به کاربر نمایش دادند.

نتیجه پیاده‌سازی نشان می‌دهد که جداسازی مسئولیت‌ها در قالب سرویس‌های مستقل امکان ایجاد یک زنجیره قابل ردیابی از داده تا تصمیم را فراهم کرده است. همچنین، استفاده از پارامتر until_clock امکان شبیه‌سازی جریان زمانی داده‌های CMAPSS را بدون نیاز به یک منبع حسگری واقعی فراهم کرده است.

در سطح زیرساخت نیز استقرار کانتینری و استفاده از رابط‌های REST امکان اجرای مستقل سرویس‌ها و مدیریت ساده‌تر وابستگی میان آن‌ها را فراهم کرده است. در مقابل، وضعیت درون‌حافظه‌ای، نظرسنجی دوره‌ای و استفاده از داده شبیه‌سازی‌شده از جمله محدودیت‌هایی هستند که هنگام انتقال سامانه از محیط آزمایشگاهی به محیط صنعتی باید برطرف شوند.

در نهایت، اجرای فرایندهای سرتاسری نشان داد که معماری حاضر صرفاً یک زنجیره پیش‌بینی نیست، بلکه می‌تواند پیش‌بینی را در قالب یک جریان چندعاملی به تصمیم و سپس تغییر وضعیت عملیاتی تبدیل کند. ارزیابی کمی مدل و ارزیابی عملی عملکرد این زنجیره در فصل پنجم ارائه می‌شود.

فصل پنجم

ارزیابی و بحث

۵-۱ مقدمه

در فصل چهارم، معماری پیشنهادی دوقلوهای دیجیتال چندعاملی از سطح طراحی به یک نمونه آزمایشگاهی قابل اجرا منتقل شد و نحوه پیاده‌سازی عامل دوقلوی دیجیتال، عامل پیش‌بینی عمر مفید باقیمانده، عامل تعامل زبانی، عامل پایش و عامل تابلو وضعیت تشریح گردید. همچنین نحوه ارتباط میان سرویس‌ها، شبیه‌سازی ورود تدریجی داده‌های مجموعه CMAPSS، استقرار سرویس‌ها و اجرای فرایندهای سرتاسری سامانه بررسی شد. ازاین‌رو، هدف فصل حاضر ارزیابی این است که آیا سامانه پیاده‌سازی‌شده توانسته است اهداف اصلی پژوهش را در سه سطح **پیش‌بینی، یکپارچه‌سازی و تعامل** محقق سازد یا خیر.

بر این اساس، ارزیابی پژوهش در دو سطح انجام می‌شود. در سطح نخست، عملکرد عامل پیش‌بینی عمر مفید باقیمانده از طریق مقایسه یک مدل پایه با نسخه نهایی بررسی می‌شود. این ارزیابی با هدف ادعای ارائه بهترین معماری یادگیری عمیق برای مجموعه CMAPSS انجام نمی‌شود؛ بلکه هدف آن تعیین این موضوع است که آیا یک مدل پیش‌بینی با عملکرد قابل قبول و رفتار متناسب با نیازهای واقعی صنعت، می‌تواند به عنوان یک بخش تخصصی در معماری چندعاملی مورد استفاده قرار گیرد یا خیر. این تفکیک از اهمیت روش‌شناختی برخوردار است، زیرا در معماری پیشنهادی، مدل یادگیری عمیق تنها یکی از اجزای سامانه محسوب می‌شود و

ارزش پژوهش به عملکرد مدل به‌تنهایی محدود نمی‌شود.

در سطح دوم، عملکرد معماری چندعاملی از منظر یکپارچگی سرویس‌ها، پایش شبه‌بی‌درنگ، تعامل با زبان طبیعی، تفسیر خروجی پیش‌بینی و اجرای فرمان‌های کنترلی ارزیابی می‌شود. چنین ارزیابی‌ای با جهت‌گیری پژوهش‌های جدید در زمینه دوقلوهای دیجیتال عامل‌محور نیز هم‌راستا است. در این پژوهش‌ها، هدف از ترکیب دوقلوی دیجیتال و عامل‌های هوشمند، حرکت از یک بازنمایی صرفاً اطلاعاتی به سمت سامانه‌هایی است که بتوانند وضعیت را درک کرده، تصمیم مناسب پیشنهاد دهند و در چارچوب کنترل‌شده در فرایند عملیاتی مشارکت کنند [۱۶، ۵۹، ۶۰].

بنابراین، پرسش اصلی این فصل چنین بیان می‌شود: آیا معماری پیشنهادی می‌تواند یک مدل پیش‌بینی عمر مفید باقیمانده را به یک جزء قابل استفاده در یک سامانه چندعاملی تبدیل کند که علاوه بر تخمین عمر مفید، امکان پایش، توضیح وضعیت، تعامل طبیعی و اعمال فرمان را نیز فراهم آورد؟ پاسخ به این پرسش، بر اساس نتایج کمی مدل، مطالعات موردی عامل زبانی، بررسی حلقه بسته تصمیم و مقایسه با پژوهش‌های مرتبط ارائه خواهد شد.

۵-۲ راهبرد ارزیابی

راهبرد ارزیابی پژوهش با توجه به ماهیت چندلایه سامانه طراحی شده است. از آنجا که معماری پیشنهادی از چند مؤلفه مستقل تشکیل شده است، ارزیابی صرفاً بر یک معیار عددی مانند MAE نمی‌تواند میزان موفقیت کل سامانه را نشان دهد. به همین دلیل، چهار بعد اصلی برای ارزیابی در نظر گرفته شده است:

۱. ارزیابی عملکرد پیش‌بینی عمر مفید باقیمانده؛

۲. ارزیابی رفتار محافظه‌کارانه مدل در برابر خطای بیش‌برآورد؛

۳. ارزیابی قابلیت تعامل و تفسیر خروجی توسط عامل زبانی؛

۴. ارزیابی یکپارچگی معماری از طریق اجرای حلقه بسته پیش‌بینی، تصمیم، کنترل و بازخورد.

این رویکرد با روند جدید پژوهش در زمینه نگهداری پیش‌بینانه و کاربرد در صنعت نیز سازگار است. پژوهش‌های جدید عمر مفید باقیمانده نشان می‌دهند که ارزیابی مدل تنها بر اساس خطای نقطه‌ای کافی نیست و عواملی مانند عدم‌قطعیت، قابلیت اعتماد پیش‌بینی و هزینه نامتقارن خطاها باید در نظر گرفته شوند [۶۱، ۶۲]. به‌خصوص در تجهیزات صنعتی، بیش‌برآورد عمر مفید می‌تواند از نظر عملیاتی خطرناک‌تر از کم‌برآورد آن باشد؛

زیرا کم‌برآورد عمدتاً به بازرسی یا نگهداری زودتر منجر می‌شود، درحالی‌که بیش‌برآورد می‌تواند موجب ادامه بهره‌برداری از تجهیزی شود که به انتهای عمر خود نزدیک شده است.

از این منظر، هدف مدل پیش‌بینی در این پژوهش کمینه‌سازی کورکورانه خطای عددی نیست، بلکه تولید پیش‌بینی‌ای است که در زنجیره تصمیم‌گیری سامانه بتوان به آن تکیه کرد. این موضوع یکی از تفاوت‌های مهم میان رویکرد حاضر و پژوهش‌هایی است که مسئله CMAPSS را صرفاً به عنوان یک مسئله رقابت برای کاهش MAE یا RMSE در نظر می‌گیرند.

۵-۳ تنظیم آزمایش‌ها

۵-۳-۱ مجموعه داده و پروتکل ارزیابی

تمام آزمایش‌های کمی این پژوهش بر روی زیرمجموعه FD001 مجموعه داده CMAPSS انجام شده است. انتخاب FD001 به این دلیل صورت گرفته است که این زیرمجموعه دارای یک شرایط عملیاتی و یک حالت خرابی است و در نتیجه امکان بررسی رفتار مدل بدون ورود هم‌زمان به پیچیدگی ناشی از چندین شرایط عملیاتی فراهم می‌شود.

مجموعه آموزشی همانطور که در جدول ۵-۱ مشخص شده، شامل ۱۰۰ موتور و ۲۰,۶۳۱ رکورد حسگر و مجموعه آزمون شامل ۱۰۰ موتور و ۱۳,۰۹۶ رکورد است. برای هر موتور آزمون، داده‌ها تا یک نقطه زمانی مشخص در اختیار سامانه قرار گرفته و هدف، تخمین عمر مفید باقیمانده موتور در همان نقطه است. این ساختار با ماهیت کاربردی پیش‌بینی خرابی سازگار است؛ زیرا در یک کاربرد واقعی نیز سامانه باید بر اساس اطلاعات موجود تا زمان جاری، وضعیت آینده تجهیز را تخمین بزند.

جدول ۵-۱: مشخصات مجموعه داده مورد استفاده در ارزیابی

مشخصه	مقدار
زیرمجموعه	FD001
شرایط عملیاتی	یک شرایط عملیاتی
حالت خرابی	یک حالت خرابی
تعداد موتورهای آموزش	۱۰۰
تعداد موتورهای آزمون	۱۰۰
تعداد رکوردهای آموزش	۲۰,۶۳۱
تعداد رکوردهای آزمون	۱۳,۰۹۶
طول پنجره زمانی	۳۰ چرخه
تعداد ویژگی‌ها	۱۴ ویژگی در هر گام زمانی

انتخاب FD001 را نباید به عنوان ادعای تعمیم‌یافتن نتایج مدل به تمام شرایط عملیاتی تفسیر کرد. این انتخاب صرفاً یک نقطه شروع کنترل‌شده برای ارزیابی معماری است. پژوهش‌های جدید نیز نشان داده‌اند که تغییر شرایط عملیاتی و انتقال بین زیرمجموعه‌های مختلف CMAPSS می‌تواند مسئله پیش‌بینی عمر مفید

باقیمانده را به‌طور قابل توجهی دشوارتر کند [۶۱، ۶۳].

۵-۳-۲ مدل‌های مورد مقایسه

برای بررسی اثر استفاده از تابع زیان نامتقارن بر پیش‌بینی عمر مفید باقیمانده، دو پیکربندی از یک معماری ثابت مبتنی بر LSTM مورد ارزیابی قرار گرفته است.

پیکربندی نخست به‌عنوان مدل پایه (LSTM-MSE) در نظر گرفته شده است. این مدل از سه لایه بازگشتی LSTM و دو لایه کاملاً متصل استفاده می‌کند و با تابع زیان میانگین مربعات خطا (MSE) آموزش داده می‌شود. هدف از این پیکربندی، فراهم‌کردن یک خط مبنای داخلی برای ارزیابی اثر تغییر تابع زیان است.

پیکربندی دوم با عنوان LSTM-Pinball مشخص می‌شود. در این مدل، ساختار شبکه و پارامترهای آموزش مشابه مدل پایه هستند، اما تابع زیان MSE با تابع زیان نامتقارن Pinball و ضریب $\tau = 0.125$ جایگزین شده است.

با ثابت نگه‌داشتن معماری، پیش‌پردازش و تنظیمات آموزش، امکان بررسی اثر تابع زیان بر دقت عددی و جهت خطای پیش‌بینی فراهم می‌شود. مشخصات این دو پیکربندی در جدول ۵-۲ ارائه شده است.

جدول ۵-۲: مشخصات مدل‌های مورد استفاده در ارزیابی

مدل	معماری	تابع زیان	بهینه‌ساز
LSTM-MSE	سه لایه LSTM و دو لایه Dense	MSE	Adam
LSTM-Pinball	سه لایه LSTM و دو لایه Dense	Pinball، $\tau = 0.125$	Adam

علاوه بر مقایسه داخلی این دو پیکربندی، برای بررسی جایگاه عملکرد مدل پایه، نتیجه گزارش‌شده برای مدل LSTM در مطالعه مو و ایاکا نیز به‌عنوان یک مرجع، مورد استفاده قرار می‌گیرد [۵۸]. با توجه به تفاوت در معماری، استانداردسازی، طول پنجره و تنظیمات آموزش، این مقایسه به‌عنوان مقایسه با نتیجه منتشرشده در ادبیات تفسیر می‌شود و نه آزمایشی با تنظیمات کاملاً یکسان.

۵-۴ ارزیابی مدل پیش‌بینی عمر مفید باقیمانده

۵-۴-۱ معیارهای ارزیابی

برای ارزیابی مدل‌ها از معیارهای MAE، RMSE، R^2 و نسبت کم‌برآورد استفاده شده است. MAE میانگین قدر مطلق خطا را نشان می‌دهد و تصویری مستقیم از میزان خطای پیش‌بینی ارائه می‌کند. RMSE نسبت به خطاهای بزرگ حساس‌تر است و بنابراین می‌تواند برای بررسی وجود خطاهای شدید مفید باشد. همچنین R^2 میزان توانایی مدل در توضیح تغییرات مقدار واقعی RUL را اندازه‌گیری می‌کند.

با این حال، در مسئله حاضر نسبت کم‌برآورد نیز اهمیت ویژه‌ای دارد. این معیار به صورت رابطه ۵-۱

تعریف می‌شود.

$$r_{\text{under}} = \frac{\sum_{i=1}^{N} \mathbb{I}(\hat{y}_i < y_i)}{N}, \tag{۵-۱}$$

که در آن $\hat{y}_i$ مقدار پیش‌بینی‌شده و y_i مقدار واقعی عمر مفید باقیمانده است.

این معیار نشان می‌دهد چه نسبتی از پیش‌بینی‌ها کمتر از عمر واقعی قرار گرفته‌اند. افزایش این نسبت لزوماً به معنای بهتر شدن مدل از نظر معیارهای عمومی نیست؛ بلکه در این پژوهش به عنوان یک ویژگی ایمنی مطلوب تفسیر می‌شود. پژوهش‌های جدید نیز به اهمیت پیش‌بینی ریسک‌آگاه و لحاظ عدم‌قطعیت در تصمیم‌های نگهداری اشاره کرده‌اند [۶۱، ۶۲].

علاوه بر معیارهای عمومی خطای پیش‌بینی، از امتیاز نامتقارن ناسا (NASA S-score) نیز برای بررسی شدت و جهت خطا استفاده شده است. در این معیار، اختلاف پیش‌بینی و مقدار واقعی به‌صورت زیر تعریف می‌شود:

$$d_i = \hat{y}_i - y_i, \tag{۵-۲}$$

که در آن $\hat{y}_i$ مقدار پیش‌بینی‌شده و y_i مقدار واقعی عمر مفید باقیمانده است. امتیاز برای هر نمونه به‌صورت زیر محاسبه می‌شود:

$$s_i = \begin{cases} \exp\left(-\dfrac{d_i}{13}\right) - 1, & d_i < 0, \\ \exp\left(\dfrac{d_i}{10}\right) - 1, & d_i \geq 0. \end{cases} \tag{۵-۳}$$

در نهایت، امتیاز کل مجموعه آزمون برابر است با:

$$S_{\text{NASA}} = \sum_{i=1}^{N} s_i. \tag{۵-۴}$$

در این معیار، خطاهای بیش‌برآورد و کم‌برآورد به‌صورت متقارن جریمه نمی‌شوند. بنابراین، این شاخص در کنار RMSE امکان بررسی رفتار مدل از دیدگاه خطر پیش‌بینی را فراهم می‌کند. مقدار کمتر این امتیاز نشان‌دهنده عملکرد بهتر بر اساس تابع جریمه تعریف‌شده است.

۵-۴-۲ نتایج کمی و مقایسه با ادبیات

نتایج حاصل از ارزیابی دو پیکربندی مدل پیش‌بینی روی ۱۰۰ موتور مجموعه آزمون FD001 در جدول ۵-۳ ارائه شده است. در هر دو پیکربندی، معماری شبکه یکسان بوده و تفاوت اصلی در تابع زیان مورد استفاده برای آموزش مدل است. در مدل پایه از تابع زیان MSE استفاده شده، در حالی که در مدل دوم، تابع زیان نامتقارن Pinball با $\tau = 0.125$ به کار رفته است. تمام معیارهای جدول بر اساس پیش‌بینی آخرین پنجره زمانی هر موتور محاسبه شده‌اند.

جدول ۵-۳: مقایسه نتایج مدل‌های پژوهش حاضر با مدل LSTM گزارش‌شده در ادبیات

معیار	LSTM-MSE	LSTM-Pinball	Mo & Iacca (2024)
MAE	۱۱٫۹۵	۱۴٫۷۲	—
R^2	۰٫۸۵	۰٫۷۶	—
RMSE	۱۵٫۹۳	۲۰٫۴۹	۱۶٫۱۴
نسبت کم‌برآورد	۵۲%	۷۱%	—
NASA S-score	۴۲۳٫۶۸	۶۷۴٫۵۷	حدود ۳۴۰

توضیح: مقدار RMSE مربوط به مطالعه مو و ایاکا از نتایج گزارش‌شده در آن پژوهش استخراج شده است. خط تیره به معنای وارد نشدن مقدار متناظر در این مقایسه است.

بر اساس نتایج جدول، مدل پایه LSTM-MSE به مقادیر MAE برابر با ۱۱٫۹۵، RMSE برابر با ۱۵٫۹۳ و ضریب تعیین $R^2 = 0.85$ دست یافته است. همچنین، نسبت پیش‌بینی‌های کم‌برآورد در این مدل برابر با ۵۲ درصد است؛ به این معنا که از مجموع ۱۰۰ پیش‌بینی انجام‌شده، در ۵۲ مورد مقدار پیش‌بینی‌شده برای عمر مفید باقیمانده کمتر از مقدار واقعی بوده است.

در مدل LSTM-Pinball، نسبت کم‌برآورد به ۷۱ درصد افزایش یافته است؛ بنابراین، تعداد پیش‌بینی‌هایی که در آن‌ها عمر مفید باقیمانده کمتر از مقدار واقعی برآورد شده، از ۵۲ مورد به ۷۱ مورد رسیده است. این افزایش ۱۹ واحد درصدی نشان می‌دهد که تغییر تابع زیان توانسته است جهت خطای مدل را به سمت کم‌برآورد سوق دهد. این رفتار با نحوه تعریف تابع زیان Pinball در آزمایش حاضر سازگار است؛ زیرا در آن، بیش‌برآورد عمر مفید باقیمانده با ضریب بزرگ‌تری نسبت به کم‌برآورد جریمه می‌شود. در نتیجه، مدل در فرایند آموزش به پیش‌بینی مقادیر محافظه‌کارانه‌تر تمایل پیدا می‌کند.

با این حال، افزایش نسبت کم‌برآورد با کاهش دقت عددی مدل همراه بوده است. مقدار RMSE از ۱۵٫۹۳ به ۲۰٫۴۹ چرخه، یعنی حدود ۲۸٫۶ درصد، افزایش یافته و مقدار MAE نیز از ۱۱٫۹۵ به ۱۴٫۷۲ رسیده است. همچنین، ضریب تعیین از ۰٫۸۵ به ۰٫۷۶ کاهش یافته است. مقدار NASA S-score نیز از ۴۲۳٫۶۸ به ۶۷۴٫۵۷ افزایش پیدا کرده است که بر اساس تعریف این معیار در آزمایش حاضر، بیانگر افزایش خطای تجمعی مدل است. بنابراین، تابع زیان Pinball در این آزمایش موجب بهبود دقت عمومی پیش‌بینی نشده است،

بلکه با تغییر جهت خطا، میان دقت عددی و تمایل به کم‌برآورد مبادله‌ای ایجاد کرده است.

برای ارزیابی جایگاه مدل پایه در مقایسه با نتایج منتشرشده، می‌توان مقدار RMSE آن را با نتیجه گزارش‌شده برای مدل LSTM در پژوهش مو و ایاکا (۲۰۲۴) مقایسه کرد [۵۸]. در آن پژوهش، مدل مرجع LSTM از دو لایه بازگشتی با ۳۲ واحد در هر لایه و دو لایه کاملاً متصل با ۸ نورون در هر لایه تشکیل شده است. برای آموزش آن نیز از بهینه‌ساز RMSprop با نرخ یادگیری ۰/۰۰۱ و اندازه دسته ۵۱۲ استفاده شده و داده‌ها به بازه $[-1, 1]$ نرمال‌سازی شده‌اند. همچنین، ورودی مدل از پنجره‌های زمانی تشکیل شده است که طول آن‌ها با توجه به شرایط مجموعه آزمون هر زیرمجموعه تعیین شده است.

در مقایسه، مدل پایه پژوهش حاضر از سه لایه LSTM با ۱۲۸، ۶۴ و ۳۲ واحد، به‌همراه دو لایه کاملاً متصل با ۹۶ و ۱۲۸ نورون تشکیل شده است. این مدل با بهینه‌ساز Adam، اندازه دسته ۱۲۸، استانداردسازی StandardScaler و پنجره‌های زمانی ۳۰ چرخه‌ای آموزش داده شده است. مقدار RMSE گزارش‌شده برای مدل LSTM در مطالعه مو و ایاکا برابر با ۱۶/۱۴ چرخه است؛ در حالی که مدل پایه پژوهش حاضر به مقدار ۱۵/۹۳ چرخه دست یافته است. بنابراین، خطای مدل پایه حاضر از نظر عددی حدود ۰/۲۱ چرخه، معادل تقریباً ۱/۳ درصد، کمتر از مقدار گزارش‌شده در آن مطالعه است.

البته این اختلاف اندک را نمی‌توان اثبات قطعی برتری مدل پایه دانست؛ زیرا دو پژوهش از نظر معماری شبکه، روش استانداردسازی، طول پنجره زمانی، اندازه دسته و تنظیمات آموزش تفاوت دارند. افزون بر این، نتایج حاضر بر اساس یک اجرای آموزش به دست آمده‌اند و برای نتیجه‌گیری آماری درباره برتری مدل‌ها، انجام آزمایش‌های تکرارشونده با بذرهای تصادفی متفاوت ضروری است. از این رو، مقایسه با مطالعه مو و ایاکا بیشتر به‌عنوان یک نقطه مرجع در ادبیات تفسیر می‌شود، نه یک مقایسه کاملاً کنترل‌شده و هم‌شرایط.

با وجود افزایش خطای عددی در مدل LSTM-Pinball، نتایج آن را نمی‌توان صرفاً به دلیل مقدار بیشتر RMSE نامطلوب ارزیابی کرد. در مسئله نگهداری پیش‌بینانه، جهت خطای پیش‌بینی نیز می‌تواند به اندازه مقدار آن اهمیت داشته باشد. بیش‌برآورد عمر مفید باقیمانده ممکن است موجب به‌تعویق‌افتادن بازرسی یا تعمیر و در نتیجه افزایش احتمال وقوع خرابی پیش‌بینی‌نشده شود؛ در مقابل، کم‌برآورد عمر مفید باقیمانده می‌تواند به برنامه‌ریزی محافظه‌کارانه‌تر برای نگهداری منجر شود، هرچند ممکن است هزینه بازرسی یا تعمیر زودهنگام را افزایش دهد.

از این منظر، افزایش نسبت کم‌برآورد از ۵۲ به ۷۱ درصد، دستاوردی مرتبط با هدف عملیاتی این پژوهش محسوب می‌شود. به بیان دیگر، مدل LSTM-Pinball در ازای افزایش حدود ۲۸/۶ درصدی RMSE نسبت به مدل پایه، توانسته است تعداد پیش‌بینی‌های کم‌برآورد را ۱۹ واحد درصد افزایش دهد. چنانچه در کاربرد مورد

نظر، هزینه و پیامدهای بیش‌برآورد عمر مفید باقیمانده به‌مراتب بیشتر از هزینه ناشی از نگهداری زودهنگام باشد، این مبادله می‌تواند از نظر عملیاتی قابل قبول و حتی ارزشمند باشد. در چنین شرایطی، پذیرش مقداری افزایش در خطای عددی برای دستیابی به پیش‌بینی محافظه‌کارانه‌تر، تصمیمی قابل دفاع خواهد بود.

بنابراین، نتیجه این آزمایش را باید نه به‌عنوان برتری مطلق یکی از دو مدل، بلکه به‌عنوان تفاوت در اولویت‌های پیش‌بینی تفسیر کرد: مدل LSTM-MSE برای دستیابی به دقت عددی بهتر مناسب‌تر است، در حالی که مدل LSTM-Pinball با وجود خطای عددی بیشتر، تمایل قوی‌تری به کم‌برآورد عمر مفید باقیمانده دارد. انتخاب میان این دو پیکربندی باید بر اساس موازنه میان دقت پیش‌بینی، پیامدهای بیش‌برآورد و هزینه نگهداری زودهنگام انجام شود. در نتیجه، استفاده از تابع زیان نامتقارن را می‌توان گامی در جهت کنترل جهت خطای پیش‌بینی و انطباق رفتار مدل با نیازهای عملیاتی سامانه نگهداری پیش‌بینانه دانست.

۵-۴-۳ تحلیل کم‌برآورد و انتخاب تابع زیان

یکی از ویژگی‌های اصلی طراحی مدل نهایی، استفاده از تابع زیان Pinball با $\tau = 0.125$ است. انگیزه این انتخاب، ایجاد یک مدل صرفاً دقیق‌تر از نظر میانگین خطا نبوده است، بلکه هدف، ایجاد گرایش کنترل‌شده به سمت کم‌برآورد عمر مفید باقیمانده بوده است.

در آزمایش حاضر، نسبت کم‌برآورد از ۰٫۵۲ در مدل LSTM-MSE به ۰٫۷۱ در مدل LSTM-Pinball افزایش یافته است.

این افزایش باید به عنوان یک **ویژگی طراحی‌شده** تفسیر شود، نه صرفاً یک بهبود آماری. در واقع، مدل نهایی آگاهانه از بخشی از دقت بی‌طرفانه فاصله گرفته تا رفتار محافظه‌کارانه‌تری در زنجیره تصمیم ایجاد کند. این ویژگی برای معماری پیشنهادی اهمیت دارد، زیرا خروجی مدل مستقیماً به عامل پایش منتقل شده و می‌تواند وضعیت موتور را از عادی به هشدار یا بحرانی تغییر دهد.

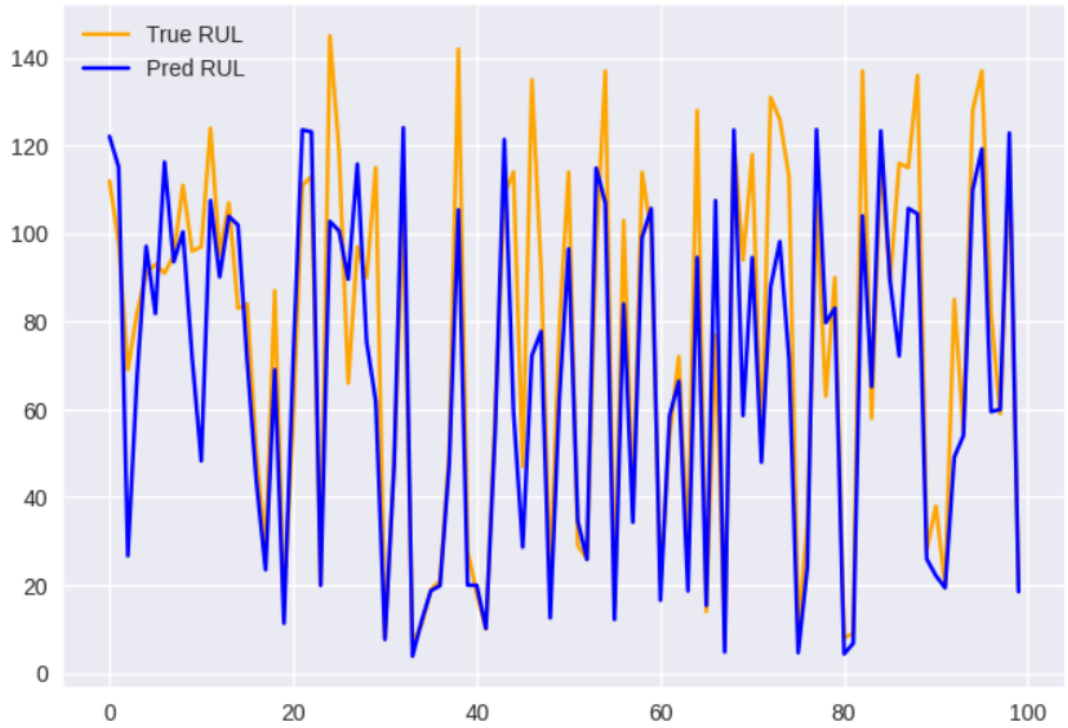
در نتیجه، تابع زیان انتخاب‌شده یکی از نقاطی است که در آن نیاز صنعتی مستقیماً وارد طراحی مدل شده است. به عبارت دیگر، مدل برای یک مسئله انتزاعی پیش‌بینی عددی طراحی نشده، بلکه برای قرار گرفتن در یک سامانه تصمیم‌یار نگهداری طراحی شده است.

۵-۴-۴ مقایسه پیش‌بینی و مقدار واقعی

نمودار ۵-۱ مقایسه مقدار واقعی و مقدار پیش‌بینی‌شده عمر مفید باقیمانده را برای ۱۰۰ موتور مجموعه آزمون نشان می‌دهد. این نمودار بر اساس پیش‌بینی آخرین پنجره زمانی هر موتور تهیه شده است.

در مدل LSTM-MSE، پیش‌بینی‌ها از نظر عددی به مقادیر واقعی نزدیک‌تر هستند و مقدار خطای کلی

کمتری ایجاد می‌کنند. در مقابل، مدل LSTM-Pinball در تعداد بیشتری از موتورهای آزمون، مقدار عمر مفید باقیمانده را کمتر از مقدار واقعی برآورد کرده است. این رفتار با هدف استفاده از تابع زیان نامتقارن سازگار است.



شکل ۵-۱: مقایسه مقادیر پیش‌بینی‌شده و واقعی RUL برای موتورهای آزمون

قرار گرفتن بخش قابل توجهی از پیش‌بینی‌ها در پایین‌تر از مقادیر واقعی با هدف استفاده از تابع زیان نامتقارن سازگار است. در نتیجه، شکل حاصل علاوه بر آنکه عملکرد مدل را نمایش می‌دهد، رفتار طراحی‌شده آن را نیز آشکار می‌کند.

البته کم‌برآورد بیش از حد نیز می‌تواند هزینه عملیاتی ایجاد کند. اگر عمر موتور به صورت دائمی کمتر از مقدار واقعی برآورد شود، ممکن است بازرسی‌ها و تعمیرات غیرضروری افزایش یابند. بنابراین، هدف کاربردی یک سامانه صنعتی، دستیابی به کم‌برآورد حداکثری نیست؛ بلکه دستیابی به نقطه‌ای مناسب میان ایمنی، هزینه نگهداری و عدم‌قطعیت است. مقدار $\tau = 0.125$ در این پژوهش به عنوان یک انتخاب اولیه و محافظه‌کارانه ارزیابی شده و نه به عنوان مقدار بهینه عمومی برای همه انواع موتورها. بنا به نوع و جنس موجودیت‌ها در لایه فیزیکی و میزان خسارتی که خرابی آن‌ها به بار می‌آورند، می‌توان ضریب tau را تغییر داد.

۵-۵ جایگاه مدل LSTM در معماری پیشنهادی

نتایج این بخش نشان می‌دهد که مدل LSTM انتخاب‌شده توانسته است یک سرویس پیش‌بینی قابل استفاده برای سامانه فراهم کند. با این حال، لازم است جایگاه این نتیجه در کل پژوهش به‌درستی مشخص شود.

هدف پژوهش حاضر طراحی یک معماری جدید برای رقابت مستقیم با تمامی مدل‌های پیشرفته پیش‌بینی عمر مفید باقیمانده نیست. LSTM در اینجا به عنوان یک مدل تخصصی پیش‌بینی در عامل پیش‌بینی قرار گرفته است. این جداسازی از نظر معماری اهمیت دارد، زیرا مدل پیش‌بینی می‌تواند در آینده با مدل‌های دیگری جایگزین شود، بدون آنکه عامل دوقلو، عامل پایش، عامل زبانی یا واسط کاربر نیازمند بازطراحی اساسی باشند.

این ویژگی یکی از مزایای اصلی معماری چندعاملی است. در سیستم‌های چندعاملی، مسئولیت‌ها میان عامل‌های تخصصی توزیع می‌شوند و هر عامل می‌تواند وظیفه مشخصی را انجام دهد [۱۶، ۲۵، ۲۸]. از این منظر، مدل LSTM بخشی از معماری است و نه خود معماری.

در مقایسه با این مسیر، سهم مدل پیش‌بینی حاضر در آن است که یک مدل نسبتاً ساده و قابل پیاده‌سازی را به عنوان جزء محاسباتی معماری چندعاملی به کار گرفته و خروجی آن را در یک زنجیره کامل داده، پیش‌بینی، پایش، توضیح و کنترل قرار داده است. همچنین استفاده واقعی در صنعت را نیز در نظر گرفته و نسبت کم‌برآوردها را افزایش داده است.

۵-۶ ارزیابی عامل تعامل زبانی

یکی از اهداف اصلی معماری پیشنهادی، ایجاد یک رابط طبیعی میان کاربر و دوقلوی دیجیتال است. همان‌طور که در فصل چهارم توضیح داده شد، عامل زبانی، خود وظیفه تولید مقدار عمر مفید باقیمانده را بر عهده ندارد؛ بلکه خروجی عددی عامل پیش‌بینی را دریافت کرده، وضعیت موتور را تفسیر کرده و در صورت نیاز فرمان مناسب را به عامل دوقلو ارسال می‌کند. این جداسازی برای جلوگیری از مخلوط شدن وظیفه استنتاج عددی با وظیفه تعامل انسانی اهمیت دارد.

برای ارزیابی عامل زبانی، شش فرایند کاربردی اجرا شده است. این فرایندها شامل معرفی قابلیت‌های عامل، پرس‌وجوی وضعیت موتور سالم، پرس‌وجوی وضعیت موتور بحرانی، خاموش‌کردن همه موتورها، روشن‌کردن همه موتورها و خاموش‌کردن موتورهای در معرض خطر بوده‌اند.

در آزمایش انجام‌شده، ۳۰ درخواست مختلف برای عامل زبانی مورد بررسی قرار گرفته و نرخ موفقیت درخواست‌ها ۱۰۰ درصد گزارش شده است. منظور از موفقیت در اینجا، اجرای صحیح مسیر تعریف‌شده در گردش‌کار، دریافت داده مورد انتظار و تولید پاسخ یا اعمال فرمان مورد انتظار است؛ بنابراین این عدد نباید با

جدول ۵-۴: فرایندهای ارزیابی عامل تعامل زبانی

#	فرایند	هدف	نتیجه
۱	معرفی عامل	بررسی دسترسی به قابلیت‌ها	صحیح
۲	پرس‌وجوی موتور سالم	دریافت و تفسیر عمر مفید باقیمانده	صحیح
۳	پرس‌وجوی موتور بحرانی	تشخیص وضعیت و ارائه دلیل	صحیح
۴	خاموش‌کردن همه موتورها	اجرای فرمان کنترلی	موفق
۵	روشن‌کردن همه موتورها	بازگرداندن وضعیت عملیاتی	موفق
۶	خاموش‌کردن موتورهای در خطر	ترکیب پیش‌بینی و کنترل	موفق

معیارهایی مانند دقت مدل زبانی عمومی یا صحت آزاد و نامحدود استدلال مقایسه شود.

۵-۶-۱ تفسیر خروجی پیش‌بینی توسط عامل زبانی

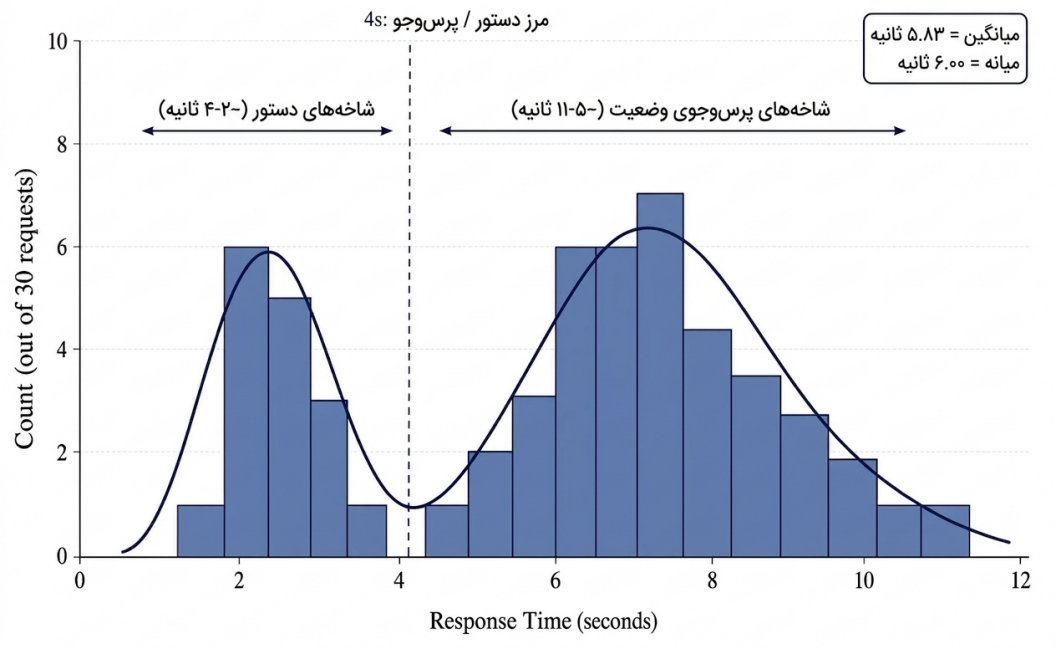
یکی از کاربردهای مهم عامل زبانی، تبدیل مقدار عددی عمر مفید باقیمانده به اطلاعات قابل فهم برای کاربر است. برای نمونه، در آزمایش انجام‌شده، مقدار عمر مفید باقیمانده موتور ۲ برابر ۶۳٫۷۷ چرخه و مقدار عمر مفید باقیمانده موتور ۲۴ برابر ۲۷٫۴۱ چرخه گزارش شده است. با توجه به آستانه تعریف‌شده، موتور ۲ در محدوده عادی و موتور ۲۴ در وضعیت بحرانی قرار گرفته است. تصاویر موجود در شکل‌های ۴-۶ و ۴-۷ نمونه پرسیدن در باره موتورهای ۲ و ۲۴ را از عامل زبانی می‌توان دید.

نکته مهم آن است که عامل زبانی مقدار عمر مفید باقیمانده را به صورت مستقل محاسبه نمی‌کند. مقدار عددی از سرویس پیش‌بینی دریافت می‌شود و مدل زبانی بزرگ صرفاً وظیفه تفسیر و ارائه آن را بر عهده دارد. این معماری از نظر قابلیت اعتماد اهمیت دارد، زیرا محاسبه عددی در یک سرویس تخصصی و قابل ارزیابی باقی می‌ماند و مدل زبانی در نقش واسط و هماهنگ‌کننده قرار می‌گیرد.

در فرایند موتور ۲۴ نمایش داد شده در شکل ۴-۷ ، عامل زبانی علاوه بر بیان مقدار عمر مفید باقیمانده، مهم‌ترین حسگرهای مؤثر را نیز به کاربر معرفی کرده و برای هر یک تفسیری ارائه می‌دهد. این قابلیت، خروجی یک مدل عددی را به اطلاعاتی تبدیل می‌کند که برای کاربر نهایی قابل استفاده‌تر است.

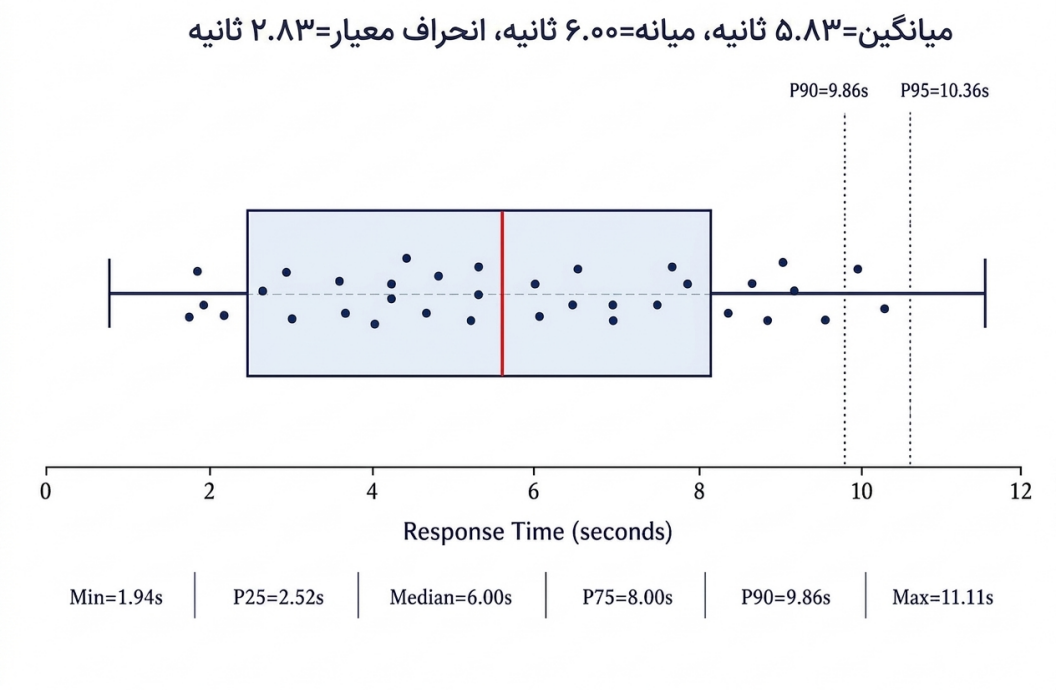
۵-۶-۲ ارزیابی زمان پاسخ

علاوه بر صحت مسیرهای عملیاتی، زمان پاسخ عامل زبانی نیز اندازه‌گیری شده است. برای ۳۰ درخواست بررسی‌شده، توزیع زمان پاسخ دارای دو ناحیه اصلی است.



شکل ۵-۲: توزیع زمان پاسخ عامل زبانی برای ۳۰ درخواست

با توجه به نمودار ۵-۲، بخش اول در حدود ۲ تا ۴ ثانیه مربوط به درخواست‌های ساده کنترلی است، درحالی‌که درخواست‌های مربوط به وضعیت موتور به دلیل طی‌کردن چند مرحله، زمان بیشتری نیاز دارند.



شکل ۵-۳: نمودار جعبه‌ای زمان پاسخ عامل زبانی

در نمودار جعبه‌ای ۵-۳ نیز مشخص است که میانه زمان پاسخ حدود ۶ ثانیه و صدک نودم برابر ۹/۸۶

ثانیه به دست آمده است. این مقدار برای نمونه آزمایشگاهی حاضر قابل قبول است، اما برای یک سامانه صنعتی بلادرنگ نمی‌توان صرفاً بر همین نتیجه تکیه کرد. کاهش وابستگی به API خارجی، استفاده از مدل‌های سبک‌تر، حافظه نهان، پردازش محلی و روش‌های رویدادمحور می‌توانند زمان پاسخ را کاهش دهند.

۵-۷ ارزیابی پایش و حلقه بسته تصمیم

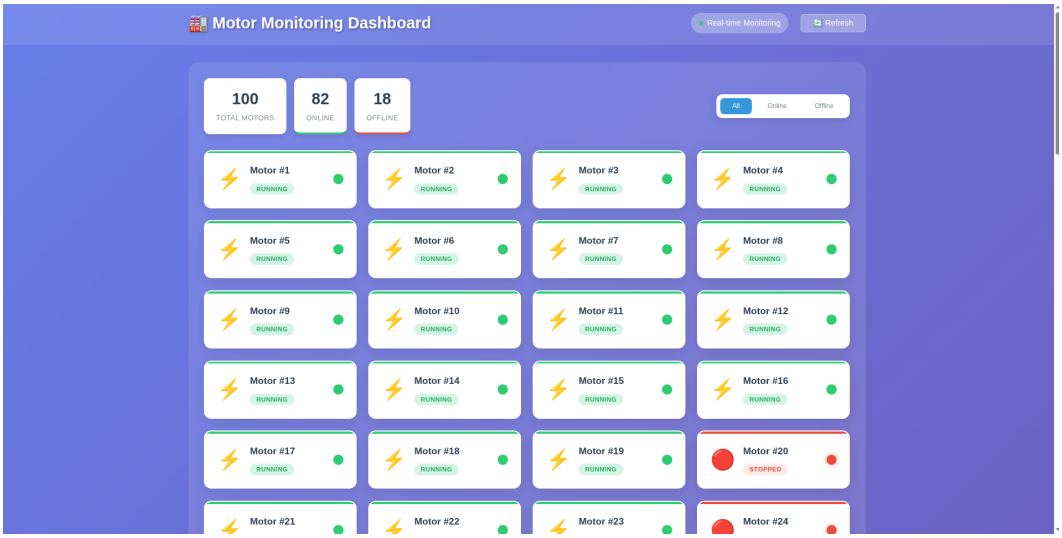
مهم‌ترین تفاوت میان یک مدل پیش‌بینی مستقل و معماری پیشنهادی، در امکان تبدیل خروجی پیش‌بینی به یک جریان عملیاتی است. در فصل چهارم، این جریان در سطح پیاده‌سازی نشان داده شد. در این فصل، نتیجه آن از دیدگاه ارزیابی معماری بررسی می‌شود.

در فرایند نخست، کاربر درباره وضعیت یک موتور پرس‌وجو می‌کند. درخواست پس از تشخیص نیت، به عامل پیش‌بینی ارسال می‌شود و نتیجه به عامل زبانی بازمی‌گردد. عامل زبانی نتیجه را به شکل قابل فهم ارائه می‌کند.

در فرایند دوم، کاربر دستور می‌دهد موتورهای در معرض خطر خاموش شوند. در این حالت، مسیر به صورت جریان ۵-۵ طی می‌شود.

$$\text{مشاهده وضعیت} \rightarrow \text{به‌روزرسانی وضعیت} \rightarrow \text{کنترل} \rightarrow \text{تصمیم} \rightarrow \text{پیش‌بینی} \qquad (۵-۵)$$

این حلقه نشان می‌دهد که دوقلوی دیجیتال در پیاده‌سازی حاضر تنها یک مخزن اطلاعات نیست. تغییر وضعیت ایجادشده توسط فرمان نیز به دوقلو بازمی‌گردد و در نمایش پایش قابل مشاهده می‌شود. چنین ویژگی‌ای با مفهوم دوقلوی دیجیتال به عنوان یک سیستم پویا و متصل به موجودیت متناظر سازگارتر است [۲۱، ۲۲].



شکل ۵-۴: رابط پایش پس از اجرای فرمان خاموش‌سازی موتورهای در معرض خطر

از منظر معماری، این آزمایش اهمیت بیشتری از یک پاسخ موفق مدل زبانی بزرگ دارد؛ زیرا نشان می‌دهد چند سرویس مستقل توانسته‌اند یک فرایند مشترک را تکمیل کنند. عامل پیش‌بینی بدون عامل دوقلو نمی‌تواند وضعیت عملیاتی را تغییر دهد، عامل زبانی بدون سرویس پیش‌بینی نمی‌تواند درباره عمر مفید باقیمانده پاسخ تخصصی ارائه کند و عامل پایش بدون دریافت خروجی پیش‌بینی قادر به تشخیص موتورهای کم‌عمر نیست. بنابراین، ارزش معماری دقیقاً در تعامل این اجزا آشکار می‌شود.

۵-۸ مقایسه با پژوهش‌های مرتبط

هدف از این بخش، مشخص کردن جایگاه پژوهش حاضر نسبت به پژوهش‌هایی است که هر یک بخشی از مسئله مورد نظر این پژوهش را بررسی کرده‌اند. از این رو، چند پژوهش پایه از حوزه‌های دوقلوهای دیجیتال، سیستم‌های چندعاملی، نگهداری پیش‌بینانه و مدل‌های زبانی بزرگ انتخاب شده‌اند و قابلیت‌های آن‌ها در کنار قابلیت‌های چارچوب پیشنهادی مقایسه می‌شود.

موهانراج و بالاجی در سال ۲۰۲۶ در یک مرور جامع، روند توسعه فناوری دوقلوهای دیجیتال، معماری‌ها، کاربردها، روش‌های مدل‌سازی و چالش‌های یکپارچه‌سازی آن با فناوری‌هایی مانند هوش مصنوعی و اینترنت اشیاء را بررسی کرده‌اند [۶۴]. یکی از نکات مهم این مطالعه، تأکید بر ضرورت حرکت دوقلوهای دیجیتال از یک نمایش مجازی ساده به سمت سامانه‌هایی یکپارچه، داده‌محور و هوشمند است. همچنین موضوعاتی مانند مقیاس‌پذیری، قابلیت همکاری و یکپارچه‌سازی اجزای مختلف به عنوان مسائل مهم توسعه دوقلوهای دیجیتال آینده مطرح شده‌اند. پژوهش حاضر این دیدگاه را در سطح پیاده‌سازی دنبال می‌کند. به این صورت که دوقلوی

دیجیتال، عامل پایش، عامل پیش‌بینی و عامل مدل زبانی به صورت اجزای مستقل در یک معماری واحد قرار گرفته‌اند. بنابراین، سهم پژوهش حاضر در این بخش، تبدیل قابلیت‌های عمومی مطرح‌شده در مطالعه‌ی مروری به یک نمونه اجرایی قابل آزمایش است.

در حوزه ترکیب سیستم‌های چندعاملی و دوقلوهای دیجیتال، کولیبالی و همليش در سال ۲۰۲۶ یک مرور نظام‌مند بر بیش از ۵۴۷ پژوهش انجام داده‌اند و ضمن ارائه طبقه‌بندی معماری‌های ترکیبی، چالش‌های موجود در کاربرد دوقلوهای دیجیتال چندعاملی برای نگهداری پیش‌بینانه را بررسی کرده‌اند [۴۲]. اهمیت این پژوهش برای پژوهش حاضر بیش از یک مطالعه مروری معمولی است، زیرا نویسندگان سه مسئله باز را به عنوان مسیرهای اصلی پژوهش آینده مطرح می‌کنند که یکی از مسئله‌ها، سازمان‌دهی سلسله‌مراتبی دوقلوهای دیجیتال برای کنترل هوشمند که در آن برآورد عمر مفید باقیمانده و هوش مصنوعی توضیح‌پذیر نیز در نظر گرفته شود.

این مسئله مطرح‌شده توسط کولیبالی و همليش ارتباط مستقیمی با جایگاه پژوهش حاضر دارد. در آن مقاله بیان می‌شود که هنوز سامانه‌ای که بتواند دوقلوهای دیجیتال، هماهنگی عامل‌ها، برآورد عمر مفید باقیمانده و توضیح‌پذیری را در یک راهکار یکپارچه و سلسله‌مراتبی برای کاربردهای صنعتی ترکیب کند، به طور کامل ارائه نشده است [۴۲]. پژوهش حاضر بخشی از این خلأ را در یک نمونه اجرایی مشخص پوشش می‌دهد. در این پژوهش، عامل پیش‌بینی عمر مفید باقیمانده در کنار عامل دوقلوی دیجیتال و سایر عامل‌های کاربردی قرار گرفته و خروجی پیش‌بینی نیز مستقیماً در اختیار عامل مدل زبانی قرار می‌گیرد. به این ترتیب، نتیجه پیش‌بینی تنها یک مقدار عددی نیست، بلکه می‌تواند از طریق زبان طبیعی برای کاربر توضیح داده شود و بر اساس شرایط موتور، پیشنهاد عملی ارائه کند. بنابراین، پژوهش حاضر می‌تواند یک نمونه عملی از این مسئله باز را ارائه دهد و به عنوان یک گام اجرایی در راستای پرسش باز این مقاله در نظر گرفته شود.

از سوی دیگر، پژوهش کولیبالی و همليش عمدتاً بر طبقه‌بندی معماری‌ها، فناوری‌ها و چالش‌های موجود تمرکز دارد و هدف آن ارائه یک پیاده‌سازی موردی برای یک تجهیز مشخص نیست. در پژوهش حاضر، مفاهیم مطرح‌شده به یک معماری عملیاتی تبدیل شده‌اند. به گونه‌ای که هر قابلیت اصلی در قالب یک عامل مستقل قابل توسعه قرار گرفته است. این ویژگی باعث می‌شود عامل پیش‌بینی بتواند در آینده با مدل دیگری جایگزین شود، بدون آنکه الزاماً عامل دوقلو یا عامل زبان طبیعی تغییر کند. از این منظر، چند عاملی بودن معماری پیشنهادی، پاسخی عملی به نیاز مطرح‌شده در مطالعات جدید برای ایجاد معماری‌های انعطاف‌پذیر و قابل توسعه است.

در حوزه استفاده از مدل‌های زبانی بزرگ، فن و همکاران در سال ۲۰۲۶ چارچوبی برای استفاده از مدل زبانی بزرگ در محیط‌های صنعتی مبتنی بر دوقلوی دیجیتال ارائه کرده‌اند که در آن مدل‌های زبانی بزرگ در فرآیند تصمیم‌گیری و یادگیری تقویتی مورد استفاده قرار می‌گیرد [۶۵]. این پژوهش نشان می‌دهد که مدل‌های

زبانی بزرگ می‌توانند دوقلوی دیجیتال را از یک محیط صرفاً شبیه‌سازی و تحلیل به محیطی برای تصمیم‌گیری هوشمند تبدیل کنند. با این حال، تمرکز آن بر هدایت فرآیند یادگیری تقویتی است. در حالی که در پژوهش حاضر مدل زبانی بزرگ در نقش واسط شناختی و تعاملی میان کاربر و دوقلوی دیجیتال قرار می‌گیرد. عامل زبان طبیعی می‌تواند وضعیت موتور را بازیابی کند، درباره مقدار عمر مفید باقیمانده پرس‌وجو کند، دلیل وضعیت پیش‌بینی‌شده را بر اساس اطلاعات موجود توضیح دهد و در صورت تعریف دستورات مجاز، فرمان عملیاتی را به عامل مربوطه منتقل کند.

این تفاوت با جهت‌گیری پژوهش‌های جدید در زمینه عامل‌های هوشمند نیز هم‌راستا است. حسن و نگوین در سال ۲۰۲۶ بر ترکیب عامل‌های هوشمند و دوقلوهای دیجیتال برای ایجاد سامانه‌های تصمیم‌گیری هوشمند تأکید کرده‌اند [۶۶]. در چنین رویکردهایی، دوقلوی دیجیتال می‌تواند به عنوان منبع وضعیت سامانه و عامل هوشمند به عنوان لایه استدلال و تصمیم‌گیری عمل کند. پژوهش حاضر این ایده را به یک فرایند نگهداری پیش‌بینانه منتقل کرده است. به این صورت که عامل زبانی نه جایگزین دوقلوی دیجیتال یا مدل پیش‌بینی، بلکه به عنوان یک لایه تعامل روی آن‌ها قرار می‌گیرد. بنابراین، خروجی عددی مدل یادگیری عمیق به اطلاعات قابل استفاده برای کاربر تبدیل می‌شود.

در بخش پیش‌بینی، پژوهش‌های مبتنی بر مجموعه داده CMAPSS عمدتاً با هدف کاهش خطای پیش‌بینی عمر مفید باقیمانده و توسعه معماری‌های یادگیری عمیق انجام شده‌اند. در پژوهش حاضر نیز LSTM به عنوان مدل پایه پیش‌بینی استفاده شده است؛ با این تفاوت که هدف پژوهش، ارائه بهترین مدل پیش‌بینی برای CMAPSS نیست. LSTM در اینجا یک مؤلفه قابل تعویض در معماری است که وظیفه فراهم کردن سرویس تخمین عمر مفید باقیمانده را بر عهده دارد. از این رو، امکان جایگزینی آن با مدل‌های دیگر در آینده وجود دارد، بدون آنکه ساختار کلی دوقلوی دیجیتال چندعاملی نیازمند بازطراحی اساسی باشد.

تفاوت مهم دیگر در نحوه استفاده از خروجی مدل پیش‌بینی است. در بسیاری از پژوهش‌های CMAPSS، خروجی اصلی مدل یک مقدار عمر مفید باقیمانده یا مجموعه‌ای از معیارهای خطای پیش‌بینی است و ارزیابی عمدتاً در سطح مدل انجام می‌شود. در پژوهش حاضر، این مقدار بخشی از وضعیت دوقلوی دیجیتال محسوب شده و می‌تواند در اختیار عامل‌های دیگر قرار گیرد. علاوه بر این، تابع زیان با توجه به اهمیت عملی خطای بیش‌برآورد عمر مفید باقیمانده طراحی شده است تا در شرایط خطا، پیش‌بینی بیش از حد خوش‌بینانه نسبت به وضعیت واقعی موتور تا حد امکان کاهش یابد. این انتخاب با هدف استفاده صنعتی از سامانه انجام شده است، زیرا در نگهداری پیش‌بینانه، پیامدهای یک پیش‌بینی بیش از حد خوش‌بینانه می‌تواند از یک پیش‌بینی محافظه‌کارانه بسیار پر هزینه‌تر باشد.

برآیند این مطالعات نشان می‌دهد که هر یک از پژوهش‌های پایه بخش مهمی از چارچوب مورد نیاز را پوشش داده‌اند، اما تمرکز آن‌ها متفاوت است. مقایسه قابلیت‌های اصلی در جدول ۵-۵ ارائه شده است.

جدول ۵-۵: مقایسه قابلیت‌های پژوهش حاضر با پژوهش‌های پایه

قابلیت	موهانراج و بالاجی (۲۰۲۶)	کولیبالی و همليش (۲۰۲۶)	فن و همکاران (۲۰۲۶)	حسن و نگوین (۲۰۲۶)	پژوهش حاضر
دوقلوی دیجیتال	✓	✓	✓	✓	✓
سیستم چندعاملی	–	✓	محدود	✓	✓
معماری ماژولار و عامل‌های مستقل	محدود	✓	محدود	✓	✓
پیش‌بینی RUL	محدود	✓	–	–	✓
استفاده از LSTM	–	–	–	–	✓
استفاده از CMAPSS	–	–	–	–	✓
کاهش هدفمند بیش‌برآورد RUL	–	مطرح‌شده	–	–	✓
پایش وضعیت تجهیز	✓	✓	✓	✓	✓
دوقلوی دیجیتال دوطرفه در نمونه اجرایی	محدود	مطرح‌شده	محدود	محدود	✓
ادغام LLM با DT	–	–	✓	✓	✓
تعامل با زبان طبیعی	–	–	✓	✓	✓
توضیح خروجی پیش‌بینی برای کاربر	–	**هدف آینده**	محدود	محدود	✓
ارائه پیشنهاد به کاربر	–	**هدف آینده**	محدود	محدود	✓
نمونه اجرایی CMAPSS + MA-LLM + LSTM + DT	–	–	–	–	✓

جدول ۵-۵ نشان می‌دهد که پژوهش حاضر در یک ویژگی منفرد لزوماً جایگزین پژوهش‌های پیشین نیست، بلکه قابلیت‌هایی را که پیش‌تر عمدتاً به صورت جداگانه بررسی شده‌اند، در یک معماری واحد به یکدیگر متصل می‌کند. این موضوع به ویژه در ارتباط با یافته‌های Coulibaly و Hamlich اهمیت دارد؛ زیرا مسئله‌ای که آن‌ها در سطح مرور ادبیات به عنوان یک پرسش باز مطرح کرده‌اند، یعنی ترکیب دوقلوی دیجیتال، هماهنگی عامل‌ها، برآورد عمر مفید باقیمانده و توضیح‌پذیری، در پژوهش حاضر در سطح یک نمونه اجرایی مشخص دنبال شده است.

بنابراین، جایگاه پژوهش حاضر را می‌توان ایجاد یک پل میان چهار مسیر اصلی پژوهش دانست. دوقلوی دیجیتال برای نمایش و همگام‌سازی وضعیت موجودیت، سیستم چندعاملی برای تفکیک و مدیریت خدمات، یادگیری عمیق برای تخمین عمر مفید باقیمانده و مدل زبانی بزرگ برای تعامل، توضیح و تصمیم‌یار. مزیت این ترکیب در اجزای مستقل و قابل تعویض آن است؛ به گونه‌ای که مدل پیش‌بینی، روش تعامل کاربر یا حتی نوع موجودیت فیزیکی می‌تواند در آینده تغییر کند، بدون آنکه اصل معماری نیازمند تغییر اساسی باشد.

۵-۹ مزیت‌های معماری پیشنهادی

مهم‌ترین مزیت پژوهش حاضر را می‌توان در ترکیب چند قابلیت در یک معماری واحد دانست. هر یک از فناوری‌های استفاده‌شده پیش از این به صورت مستقل در پژوهش‌های مختلف بررسی شده‌اند، اما معماری حاضر تلاش می‌کند آن‌ها را در قالب یک زنجیره عملیاتی منسجم کنار یکدیگر قرار دهد.

نخستین مزیت، **جداسازی مسئولیت‌ها** است. عامل دوقلو، عامل پیش‌بینی، عامل پایش و عامل زبانی وظایف

متفاوتی دارند. این جداسازی امکان جایگزینی هر جزء را بدون بازطراحی کل سامانه فراهم می‌کند.

دومین مزیت، **قابلیت توسعه** است. برای نمونه، می‌توان مدل LSTM را با مدل دیگری جایگزین کرد، بدون آنکه عامل زبانی یا رابط پایش تغییر اساسی کند.

سومین مزیت، **قابلیت تعامل طبیعی** است. کاربر برای دریافت وضعیت موتور مجبور نیست مستقیماً API یا ساختار داده را بشناسد و می‌تواند درخواست خود را به زبان طبیعی بیان کند.

چهارمین مزیت، **قابلیت اقدام** است. عامل زبانی صرفاً وضعیت را توضیح نمی‌دهد، بلکه در چارچوب فرمان‌های تعریف‌شده می‌تواند درخواست تغییر وضعیت را به دوقلوی دیجیتال منتقل کند.

پنجمین مزیت، **توجه به هزینه نامتقارن خطا** است. مدل پیش‌بینی با هدف یک کاربرد نگهداری، طراحی شده است و صرفاً به کمینه‌سازی خطا محدود نیست.

ششمین مزیت، **قابلیت توضیح خروجی** است. ترکیب وزن‌های توجه، داده حسگرها و عامل زبانی امکان ارائه توضیحی قابل فهم‌تر از یک مقدار عددی خام را فراهم کرده است.

هفتمین مزیت، **قابلیت انتقال معماری** است. از آنجا که ارتباط میان عامل‌ها از طریق سرویس‌ها و قراردادهای مشخص انجام می‌شود، می‌توان در آینده منبع داده یا مدل پیش‌بینی را تغییر داد.

۵-۱۰ محدودیت‌های پژوهش

با وجود نتایج به‌دست‌آمده، برای جلوگیری از تعمیم بیش از حد یافته‌ها، محدودیت‌های پژوهش باید به‌صورت صریح بیان شوند.

نخستین محدودیت به مجموعه داده مربوط است. آزمایش کمی تنها روی FD001 انجام شده است. این زیرمجموعه یک شرایط عملیاتی و یک حالت خرابی دارد و بنابراین نمی‌توان نتایج حاصل را مستقیماً به FD002 تا FD004 یا شرایط واقعی عملیاتی تعمیم داد.

دومین محدودیت، مصنوعی بودن داده‌ها است. اگرچه CMAPSS یکی از مجموعه داده‌های استاندارد و پرکاربرد در پژوهش‌های نگهداری پیش‌بینانه است، داده‌های آن جایگزین داده‌های حسگر واقعی موتور در حال بهره‌برداری نیستند. بنابراین، سامانه حاضر باید به عنوان یک نمونه آزمایشگاهی و اثبات امکان‌پذیری معماری تفسیر شود، نه یک سامانه آماده بهره‌برداری روی موتور واقعی.

سومین محدودیت، شبه‌بی‌درنگ بودن داده‌ها است. داده‌ها از فایل‌های CMAPSS استخراج و با پیشرفت ساعت شبیه‌سازی وارد سامانه شده‌اند. بنابراین، عملکرد واقعی شبکه حسگر، تأخیر ارتباطی، خرابی حسگر و نویز محیط واقعی در این آزمایش ارزیابی نشده است.

چهارمین محدودیت، نگهداری وضعیت در حافظه است. وضعیت ON/OFF موتور در نمونه فعلی پایدار نیست و با راه‌اندازی مجدد کانتینر از بین می‌رود. برای محیط صنعتی باید از پایگاه داده پایدار یا سامانه‌های مدیریت وضعیت توزیع‌شده استفاده شود.

پنجمین محدودیت، وابستگی عامل زبانی به سرویس بیرونی است. زمان پاسخ و هزینه فراخوانی مدل زبانی در مقیاس صنعتی می‌تواند اهمیت زیادی پیدا کند.

ششمین محدودیت، استفاده از آستانه‌های ثابت است. آستانه‌های وضعیت موتور در نسخه فعلی ثابت هستند، درحالی‌که یک سامانه صنعتی می‌تواند به آستانه‌های وابسته به شرایط عملیاتی، نوع موتور و وضعیت تاریخی تجهیز نیاز داشته باشد.

هفتمین محدودیت، نبود ارزیابی رسمی متخصصان حوزه هوافضا برای توضیحات تولیدشده توسط مدل زبانی بزرگ است. پاسخ‌های تولیدشده در این پژوهش از نظر ساختاری و عملکردی بررسی شده‌اند، اما اعتبار فیزیکی همه توضیحات حسگری باید در آینده توسط متخصصان موتور و نگهداری ارزیابی شود.

۵-۱۱ جمع‌بندی

در این فصل، عملکرد سامانه پیشنهادی از دو منظر مدل پیش‌بینی و معماری چندعاملی ارزیابی شد تا مشخص شود آیا چارچوب ارائه‌شده توانایی تبدیل یک مدل پیش‌بینی عمر مفید باقیمانده به بخشی از یک سامانه یکپارچه برای پایش، تفسیر و تصمیم‌گیری را دارد یا خیر. ارزیابی کمی مدل پیش‌بینی بر روی زیرمجموعه FD001 از مجموعه داده CMAPSS انجام شد و عملکرد مدل LSTM-MSE و مدل LSTM-Pinball با استفاده از معیارهای MAE، RMSE، R^2 و نسبت کم‌برآورد مورد مقایسه قرار گرفت. نتایج نشان داد که مدل LSTM-Pinball با استفاده و تابع زیان Pinball با $\tau = 0.125$ توانسته است نسبت کم‌برآورد را از ۰٫۵۲ در مدل LSTM-MSE به ۰٫۷۱ در مدل نهایی افزایش دهد. این تغییر در نسبت کم‌برآورد به عنوان یک ویژگی طراحی‌شده و مرتبط با هدف ایجاد رفتار محافظه‌کارانه در پیش‌بینی تفسیر شد، نه صرفاً به عنوان یک بهبود عمومی در دقت مدل. در عین حال، نتایج نشان دادند که این انتخاب نباید به معنای تلاش برای بیشینه‌سازی کم‌برآورد تلقی شود، زیرا کم‌برآورد بیش از حد نیز می‌تواند به افزایش بازرسی‌ها و اقدامات نگهداری غیرضروری منجر شود. از این رو، مقدار $\tau = 0.125$ در این پژوهش به عنوان یک انتخاب اولیه و محافظه‌کارانه برای قرار دادن مدل در زنجیره تصمیم‌گیری در نظر گرفته شده است.

از منظر معماری، نتایج نشان داد که مدل LSTM به عنوان یک مؤلفه تخصصی و قابل تعویض، توانسته است سرویس پیش‌بینی مورد نیاز معماری را فراهم کند، بدون آنکه مدل پیش‌بینی به هسته اصلی معماری وابسته

باشد. این موضوع با هدف کلی پژوهش سازگار است، زیرا مسئله اصلی پژوهش رقابت میان مدل‌های مختلف یادگیری عمیق برای دستیابی به کمترین خطای ممکن روی CMAPSS نبوده است؛ بلکه هدف، قرار دادن یک مدل پیش‌بینی قابل قبول درون یک معماری چندعاملی بوده است. بنابراین، نتایج مدل باید در ارتباط با نقش آن در کل سامانه تفسیر شوند و نه به عنوان ادعایی درباره برتری عمومی LSTM یا مدل lrLSTM-Pinball نسبت به تمامی روش‌های موجود.

در ادامه، عامل تعامل زبانی از نظر قابلیت اجرای فرایندهای تعریف‌شده، تفسیر خروجی پیش‌بینی و زمان پاسخ مورد بررسی قرار گرفت. در ۳۰ درخواست آزمایش‌شده، نرخ موفقیت فرایندهای تعریف‌شده ۱۰۰ درصد به دست آمد. این ارزیابی نشان داد که عامل زبانی می‌تواند مقدار عمر مفید باقیمانده دریافت‌شده از سرویس پیش‌بینی را به اطلاعات قابل فهم برای کاربر تبدیل کند. همچنین می‌تواند وضعیت موتور را بر اساس آستانه‌های تعریف‌شده تفسیر نماید و در چارچوب فرمان‌های مجاز، درخواست‌های کنترلی را به عامل دوقلوی دیجیتال منتقل کند.علاوه بر این اندازه‌گیری زمان پاسخ نشان داد که میانه زمان پاسخ حدود ۶ ثانیه و صدک نودم برابر با ۹/۸۶ ثانیه بوده است. این زمان برای نمونه آزمایشگاهی حاضر قابل قبول ارزیابی شد، اما به دلیل وابستگی به سرویس بیرونی و تفاوت میان محیط آزمایشگاهی و محیط صنعتی، نمی‌توان آن را به عنوان تضمین عملکرد بلادرنگ در کاربردهای صنعتی در نظر گرفت.

مهم‌ترین یافته معماری در ارزیابی، حلقه بسته تصمیم است. در این فرایند، خروجی پیش‌بینی به تصمیم‌گیری منتقل شده، تصمیم به فرمان کنترلی تبدیل گردیده، وضعیت دوقلوی دیجیتال به‌روزرسانی شده و نتیجه تغییر وضعیت در لایه پایش قابل مشاهده بوده است. در نتیجه، دوقلوی دیجیتال در نمونه پیاده‌سازی‌شده صرفاً به عنوان یک مخزن اطلاعاتی مورد استفاده قرار نگرفته، بلکه در یک چرخه عملیاتی میان داده، پیش‌بینی، تصمیم، کنترل و بازخورد قرار گرفته است. این ویژگی نشان می‌دهد که ارزش معماری پیشنهادی تنها در عملکرد مستقل هر عامل نیست، بلکه در نحوه همکاری عامل‌های تخصصی برای تکمیل یک فرایند سرتاسری نمایان می‌شود.

مقایسه با پژوهش‌های مرتبط نیز نشان داد که پژوهش حاضر در یک قابلیت منفرد لزوماً جایگزین مطالعات پیشین نیست، بلکه تلاش می‌کند چند مسیر پژوهشی شامل دوقلوهای دیجیتال، سیستم‌های چندعاملی، پیش‌بینی عمر مفید باقیمانده، پایش و مدل‌های زبان بزرگ را در قالب یک نمونه اجرایی واحد به یکدیگر متصل کند. جداسازی مسئولیت‌ها میان عامل دوقلوی دیجیتال، عامل پیش‌بینی، عامل پایش و عامل زبان طبیعی، امکان توسعه و جایگزینی مستقل اجزای سامانه را فراهم می‌کند و در عین حال، استفاده از مدل زبانی را از محاسبه مستقیم مقدار عمر مفید باقیمانده جدا نگه می‌دارد. بر این اساس، مهم‌ترین نتیجه فصل حاضر آن است که معماری پیشنهادی توانسته است یک مدل پیش‌بینی را از یک مؤلفه مستقل محاسباتی به بخشی از یک زنجیره

عملیاتی شامل پیش‌بینی، تفسیر، تصمیم، کنترل و بازخورد تبدیل کند.

در نهایت، محدودیت‌های ارزیابی نیز باید در تفسیر این نتایج مورد توجه قرار گیرند. آزمایش کمی مدل تنها بر روی زیرمجموعه FD001 مجموعه داده CMAPSS انجام شده و جریان داده به صورت شبه‌بی‌درنگ شبیه‌سازی شده است. همچنین وضعیت عملیاتی موتور در نمونه فعلی در یک زیرساخت پایدار ذخیره نمی‌شود و عامل زبان طبیعی به یک سرویس بیرونی وابسته است. بنابراین، نتایج این فصل را باید در چارچوب یک نمونه آزمایشگاهی و اثبات امکان‌پذیری معماری تفسیر کرد. با وجود این محدودیت‌ها، مجموعه آزمایش‌های انجام‌شده نشان می‌دهد که اجزای اصلی معماری پیشنهادی توانسته‌اند در کنار یکدیگر یک جریان عملیاتی منسجم ایجاد کنند و مبنای مناسبی برای جمع‌بندی نهایی پژوهش و بررسی دستاوردها و مسیرهای توسعه آینده فراهم آورند.

فصل ششم

نتیجه‌گیری و پیشنهادها

۶-۱ مقدمه

در فصل‌های پیشین، ابتدا مسئله پژوهش و ضرورت استفاده از دوقلوهای دیجیتال و عامل‌های هوشمند در پایش و نگهداری پیش‌بینانه بررسی شد و سپس مبانی نظری و مطالعات مرتبط با دوقلوهای دیجیتال، سیستم‌های چندعاملی، مدل زبانی بزرگ و پیش‌بینی عمر مفید باقیمانده مورد بررسی قرار گرفت. در ادامه، معماری پیشنهادی دوقلوی دیجیتال چندعاملی طراحی و اجزای آن شامل عامل دوقلوی دیجیتال، عامل پیش‌بینی، عامل تعامل زبانی، عامل پایش و عامل تابلو وضعیت تعریف و پیاده‌سازی شد. در فصل پنجم نیز عملکرد مدل پیش‌بینی و قابلیت‌های معماری چندعاملی از دید پیش‌بینی، تعامل، پایش و اجرای حلقه بسته تصمیم ارزیابی گردید. فصل حاضر به جمع‌بندی پژوهش و ارائه نتیجه‌گیری نهایی اختصاص دارد و در ادامه، مسیرهای پیشنهادی برای توسعه و تکمیل پژوهش در آینده ارائه می‌شوند. هدف از این فصل، قرار دادن یافته‌های فصل‌های پیشین در یک چارچوب واحد و تبیین میزان تحقق هدف پژوهش بر اساس نتایج به‌دست‌آمده است.

۲-۶ جمع‌بندی پژوهش

پژوهش حاضر با تمرکز بر مسئله پایش و پیش‌بینی وضعیت موتورهای توربوفن، با هدف بررسی امکان طراحی و پیاده‌سازی یک چارچوب دوقلوی دیجیتال چندعاملی شکل گرفت. مسئله اصلی از این نیاز آغاز شد که یک سامانه نگهداری پیش‌بینانه صرفاً به تولید یک مقدار عددی برای عمر مفید باقیمانده محدود نباشد، بلکه بتواند وضعیت موجودیت را به صورت یکپارچه دریافت و نمایش دهد، خروجی مدل پیش‌بینی را در اختیار اجزای دیگر قرار دهد، اطلاعات حاصل را برای کاربر قابل فهم کند و در چارچوب سیاست‌های تعریف‌شده، امکان انجام اقدامات عملیاتی را نیز فراهم آورد. بر این اساس، پژوهش به جای تمرکز صرف بر توسعه یک مدل یادگیری عمیق مستقل، بر طراحی معماری‌ای متمرکز شد که در آن مدل پیش‌بینی، دوقلوی دیجیتال و عامل‌های کاربردی از جمله زبان طبیعی، بتوانند در قالب یک سامانه واحد با یکدیگر تعامل داشته باشند.

در گام نخست، مبانی نظری مرتبط با دوقلوهای دیجیتال، سیستم‌های چندعاملی، دوقلوهای دیجیتال چندعاملی، مدل‌های زبان بزرگ و نگهداری پیش‌بینانه بررسی شد. مرور مطالعات مرتبط نشان داد که این حوزه‌ها هر یک بخش مهمی از مسئله را پوشش داده‌اند، اما ترکیب آن‌ها در قالب یک معماری اجرایی و یکپارچه همچنان دارای ظرفیت پژوهشی است. بر اساس این بررسی، معماری پیشنهادی با رویکردی ماژولار طراحی شد تا مسئولیت‌های اصلی میان عامل‌های تخصصی توزیع شوند. در این معماری، عامل دوقلوی دیجیتال مسئول نگهداری و ارائه وضعیت موجودیت، عامل پیش‌بینی مسئول تخمین عمر مفید باقیمانده، عامل پایش مسئول مشاهده و پیگیری وضعیت، و عامل تعامل زبانی مسئول برقراری ارتباط طبیعی با کاربر و هماهنگی برخی فرایندهای عملیاتی است. در گام بعد، معماری طراحی‌شده در قالب یک نمونه آزمایشگاهی پیاده‌سازی شد. برای ارزیابی بخش پیش‌بینی، از مجموعه داده CMAPSS و به طور مشخص زیرمجموعه FD001 استفاده شد. مدل LSTM در این ساختار به عنوان یک مؤلفه تخصصی و قابل تعویض در نظر گرفته شد و نسخه نهایی آن با استفاده از سازوکار توجه و تابع زیان Pinball با هدف ایجاد رفتار محافظه‌کارانه‌تر در برابر بیش‌برآورد عمر مفید باقیمانده آموزش داده شد. نتایج ارزیابی نشان داد که این مدل می‌تواند عملکرد مورد نیاز برای ایفای نقش سرویس پیش‌بینی در معماری را فراهم کند. در عین حال، جایگاه مدل در چارچوب پژوهش به گونه‌ای تعریف شد که جایگزینی آن با مدل‌های پیش‌بینی دیگر در آینده، بدون نیاز به بازطراحی اساسی سایر اجزای معماری امکان‌پذیر باشد.

در سطح سامانه، عامل زبانی طبیعی به عنوان واسط میان کاربر و عامل‌های تخصصی قرار می‌گیرد. در این ساختار، محاسبه مقدار عمر مفید باقیمانده به مدل زبانی واگذار نشده و مقدار پیش‌بینی‌شده از سرویس تخصصی دریافت می‌گردد. عامل زبانی سپس این مقدار و سایر اطلاعات موجود را برای کاربر تفسیر کرده و در مسیرهای عملیاتی تعریف‌شده، درخواست‌های مناسب را به عامل‌های مربوطه منتقل می‌کند. این جداسازی مسئولیت‌ها

سبب شد که محاسبه عددی، تفسیر زبانی و کنترل عملیاتی در عامل‌ها مشخص و قابل ارزیابی باقی بمانند.

در نهایت، اجرای فرایندهای سرتاسری نشان داد که اجزای سامانه می‌توانند در یک زنجیره مشترک با یکدیگر همکاری کنند. در این زنجیره، داده وارد سامانه شده، وضعیت دوقلوی دیجیتال شکل گرفته، مدل پیش‌بینی عمر مفید را تخمین زده، عامل پایش وضعیت را ارزیابی کرده و عامل زبان طبیعی امکان تعامل کاربر با این اطلاعات و انجام فرمان‌های مجاز را فراهم کرده است. همچنین در فرایند حلقه بسته، تغییر ایجادشده در وضعیت عملیاتی دوباره به دوقلوی دیجیتال منتقل شده و در لایه پایش قابل مشاهده است. بنابراین، پژوهش حاضر نشان می‌دهد که می‌توان یک مدل پیش‌بینی و مجموعه‌ای از خدمات مستقل را در قالب یک معماری چندعاملی به یک جریان عملیاتی منسجم تبدیل کرد.

با توجه به مجموعه نتایج، می‌توان گفت مسئله پژوهش از یک دیدگاه صرفاً مدل‌محور به یک دیدگاه سامانه‌محور توسعه یافته است. در این رویکرد، کیفیت سامانه تنها به دقت مدل پیش‌بینی وابسته نیست، بلکه به توانایی اجزای مختلف در همکاری، انتقال اطلاعات، تفسیر نتایج و تبدیل خروجی تحلیلی به اقدام نیز وابسته است. از این رو، معماری پیشنهادی تلاشی برای ایجاد ارتباط میان مدل پیش‌بینی، دوقلوی دیجیتال و لایه تعامل هوشمند است و نمونه پیاده‌سازی‌شده امکان بررسی این ارتباط را در یک فرایند مشخص فراهم کرده است.

۳-۶ نتیجه‌گیری

بر اساس نتایج به‌دست‌آمده، می‌توان نتیجه گرفت که هدف اصلی پژوهش در سطح یک نمونه اثبات امکان‌پذیری محقق شده است. چارچوب توسعه‌یافته توانست مؤلفه‌های دوقلوی دیجیتال، عامل‌های تخصصی، مدل پیش‌بینی عمر مفید باقیمانده و عامل زبانی را در یک معماری واحد گردآوری کند و ارتباط میان این مؤلفه‌ها را در قالب فرایندهای پایش، تحلیل، تصمیم و کنترل نشان دهد. بنابراین، پاسخ کلی پژوهش به مسئله مطرح‌شده آن است که ترکیب این فناوری‌ها می‌تواند بستری برای ایجاد یک سامانه تصمیم‌یار تعاملی و قابل توسعه در زمینه نگهداری پیش‌بینانه فراهم کند. در عین حال، نتایج نشان نمی‌دهند که چارچوب حاضر یک سامانه صنعتی نهایی یا یک مدل پیش‌بینی بهینه برای موتورهای توربوفن است. اعتبار نتایج پیش‌بینی به داده و شرایط آزمایش وابسته است و عملکرد عامل زبانی نیز در محدوده فرایندها و درخواست‌های تعریف‌شده ارزیابی شده است. ازاین‌رو، تعمیم مستقیم نتایج به محیط عملیاتی نیازمند اعتبارسنجی‌های گسترده‌تر، استفاده از داده‌های واقعی حسگر، بررسی شرایط متنوع عملیاتی و ارزیابی توسط متخصصان حوزه خواهد بود. با وجود این، پژوهش حاضر نشان می‌دهد که ارزش چارچوب پیشنهادی صرفاً در دقت یک مدل پیش‌بینی منفرد خلاصه نمی‌شود، بلکه در نحوه قرار گرفتن این مدل در یک معماری عملیاتی و تعاملی است. در این معماری، پیش‌بینی می‌تواند

به تشخیص وضعیت منجر شود، وضعیت می‌تواند مبنای تصمیم قرار گیرد، تصمیم می‌تواند به اقدام تبدیل شود و نتیجه اقدام می‌تواند دوباره در وضعیت دوقلوی دیجیتال بازتاب پیدا کند. این زنجیره، مبنایی برای توسعه نسل بعدی سامانه‌های نگهداری پیش‌بینانه فراهم می‌کند که در آن تحلیل داده، تصمیم‌گیری عامل‌محور و تعامل طبیعی کاربر در یک چارچوب مشترک قرار می‌گیرند. در نهایت، می‌توان گفت که پژوهش حاضر یک گام عملی در جهت توسعه دوقلوهای دیجیتال چندعاملی تعاملی برای نگهداری پیش‌بینانه برداشته است. چارچوب ارائه‌شده از نظر معماری قابلیت توسعه دارد و می‌تواند در پژوهش‌های آینده با اتصال به داده‌های واقعی، افزایش سطح اعتبارسنجی، مدیریت صریح عدم‌قطعیت، تقویت سازوکارهای ایمنی و اعمال کنترل‌های انسانی در فرمان‌های حساس، به یک سامانه نزدیک‌تر به شرایط عملیاتی تبدیل شود.

۴-۶ پیشنهادهایی برای کارهای آینده

مسیرهای آینده پژوهش را می‌توان در چهار دسته اصلی تقسیم کرد.

در دسته نخست، باید دامنه داده گسترش یابد. آزمایش روی FD002 تا FD004 می‌تواند میزان مقاومت مدل و معماری را در برابر شرایط عملیاتی مختلف مشخص کند. همچنین استفاده از داده‌های واقعی حسگرهای موتور می‌تواند فاصله میان نمونه آزمایشگاهی و کاربرد صنعتی را کاهش دهد.

در دسته دوم، مدل پیش‌بینی می‌تواند از یک مدل نقطه‌ای به سمت مدل‌های احتمالاتی حرکت کند. ترکیب LSTM با سایر مدل‌های احتمالاتی و استفاده از مدل‌های دقیق‌تر با خطای کم‌تر می‌تواند در دقت خروجی مدل کمک کند و در نتیجه خروجی زبان طبیعی را نیز واضح‌تر کند.

در دسته سوم، عامل زبانی می‌تواند با حافظه بلندمدت، پایگاه دانش فنی و دانش‌نگار حوزه هوافضا ترکیب شود. در این صورت، پاسخ عامل تنها بر اساس مقدار فعلی عمر مفید باقیمانده نخواهد بود، بلکه تاریخچه موتور، تعمیرات قبلی، شرایط عملیاتی و سوابق خرابی را نیز در نظر خواهد گرفت.

در دسته چهارم، معماری می‌تواند به حوزه‌های دیگر منتقل شود. برای مثال، در یک کارخانه تولیدی، عامل دوقلو می‌تواند نماینده یک دستگاه CNC باشد؛ عامل پیش‌بینی وضعیت خرابی دستگاه را تخمین بزند؛ عامل پایش وضعیت خط تولید را بررسی کند و عامل زبانی امکان پرس‌وجو و اجرای فرمان را فراهم آورد. به همین ترتیب، معماری می‌تواند برای سایر صنایع مورد نیاز نیز توسعه یابد.

برای نزدیک شدن به استقرار صنعتی نیز پیشنهاد می‌شود ارتباط سرویس‌ها از مدل نظرسنجی دوره‌ای به سازوکارهای رویدادمحور منتقل شود و وضعیت دوقلو در یک زیرساخت پایدار ذخیره گردد. همچنین لازم است سیاست‌های کنترل دسترسی، ثبت رویداد، تأیید انسانی فرمان‌های حساس و سازوکارهای ایمنی در لایه

عامل زبانی اضافه شوند.

واژه‌نامه انگلیسی به فارسی

A

Agentic Digital Twin ..... دوقلوی دیجیتال عامل محور

Agentic Predictive Maintenance ..... نگهداری پیش‌بینانه عامل محور

Application Agents Layer ..... لایه عامل‌های کاربرد

Artificial Intelligence ..... هوش مصنوعی

Artificial Intelligence of Things ..... هوش مصنوعی اشیاء

Autonomy ..... خودمختاری

B

Baseline ..... خط مبنا

Bidirectional ..... دوطرفه

C

Cognitive ..... شناختی

Critical ..... بحرانی

D

تابلو وضعیت ..... Dashboard

لایه جمع‌آوری داده ..... Data Collection Layer

پیوند داده‌ای ..... Data Connection

تصمیم‌محور ..... Decision-oriented

یادگیری عمیق ..... Deep Learning

مدل دیجیتال ..... Digital Model

مدل دیجیتال ..... Digital Model

سایه دیجیتال ..... Digital Shadow

لایه عامل‌های دوقلوی دیجیتال ..... Digital Twin Agents Layer

دوقلوی دیجیتال ..... Digital Twins

E

نقطه پایانی ..... End Point

لایه موجودیت ..... Entity Layer

I

شاخص بلوغ صنعتی ..... Industrial DT Adoption Index

صنعت نسل چهارم و پنجم ..... Industry4 and 5

لایه ادغام ..... Integration Layer

عامل هوشمند ..... Intelligent Agent

اینترنت اشیاء ..... Internet of Things

L

مدل زبانی بزرگ ..... Large Language Model

M

یادگیری ماشین ..... Machine Learning

سازوکار ..... Mechanism

پایش ..... Monitoring

دوقلوی دیجیتال چندعاملی ..... Multi Agent Digital Twins

سیستم چندعاملی ..... Multi Agent System

N

اختلال ..... Noise

هنجارسازی ..... Normalization

O

هماهنگ‌سازی ..... Orchestration

P

منفعل ..... Passive

موجودیت فیزیکی ..... Physical Entity

تابع زیان کوانتیل ..... Pinball Loss (Quantile Loss)

سکو ..... Platform

نگهداری پیش‌بینانه ..... Predictive Maintenance

پیش‌فعالی ..... Proactiveness

قرارداد ..... Protocol

Q

چندک ..... Quantile

R

واکنش‌پذیری ..... Reactivity

یادگیری تقویتی ..... Reinforcement Learning

عمر مفید باقیمانده ..... Remaining Useful Life

حرکت به سوی شکست ..... run-to-failure

S

Sociability ..... اجتماع‌پذیری

T

Transformer ..... تبدیل‌گر

Turbofan ..... موتور جت توربینی

U

Underestimate ..... کم برآورد کردن

Unidirectional ..... یک‌طرفه

W

Warning ..... هشدار

Workflow ..... روندکار

واژه‌نامه فارسی به انگلیسی

ا

اجتماع‌پذیری ..... Sociability

اختلال ..... Noise

اینترنت اشیاء ..... Internet of Things

ب

بحرانی ..... Critical

ت

تابع زیان کوانتیل ..... Pinball Loss (Quantile Loss)

تابلو وضعیت ..... Dashboard

تبدیل‌گر ..... Transformer

تصمیم‌محور ..... Decision-oriented

ح

حرکت به سوی شکست ..... run-to-failure

خ

خط مبنا ..... Baseline

خودمختاری ..... Autonomy

د

دوطرفه ..... Bidirectional

دوقلوی دیجیتال ..... Digital Twins

دوقلوی دیجیتال عامل محور ..... Agentic Digital Twin

دوقلوی دیجیتال چندعاملی ..... Multi Agent Digital Twins

ر

روندکار ..... Workflow

س

سازوکار ..... Mechanism

سایه دیجیتال ..... Digital Shadow

سکو ..... Platform

سیستم چندعاملی ..... Multi Agent System

ش

شاخص بلوغ صنعتی ..... Industrial DT Adoption Index

شناختی ..... Cognitive

ص

صنعت نسل چهارم و پنجم ..... Industry4 and 5

ع

عامل هوشمند ..... Intelligent Agent

عمر مفید باقیمانده ..... Remaining Useful Life

ق

قرارداد ..... Protocol

ل

لایه ادغام ..... Integration Layer
لایه جمع‌آوری داده ..... Data Collection Layer
لایه عامل‌های دوقلوی دیجیتال ..... Digital Twin Agents Layer
لایه عامل‌های کاربرد ..... Application Agents Layer
لایه موجودیت ..... Entity Layer

م

مدل دیجیتال ..... Digital Model
مدل دیجیتال ..... Digital Model
مدل زبانی بزرگ ..... Large Language Model
منفعل ..... Passive
موتور جت توربینی ..... Turbofan
موجودیت فیزیکی ..... Physical Entity

ن

نقطه پایانی ..... End Point
نگهداری پیش‌بینانه ..... Predictive Maintenance
نگهداری پیش‌بینانه عامل محور ..... Agentic Predictive Maintenance

ه

هشدار ..... Warning
هماهنگ‌سازی ..... Orchestration
هنجارسازی ..... Normalization
هوش مصنوعی ..... Artificial Intelligence
هوش مصنوعی اشیاء ..... Artificial Intelligence of Things

و

واکنش‌پذیری ..... Reactivity

پ

پایش ..... Monitoring

پیش‌فعالی ..... Proactiveness

پیوند داده‌ای ..... Data Connection

چ

چندک ..... Quantile

ک

کم برآورد کردن ..... Underestimate

ی

یادگیری تقویتی ..... Reinforcement Learning

یادگیری عمیق ..... Deep Learning

یادگیری ماشین ..... Machine Learning

یک‌طرفه ..... Unidirectional

مراجع

[1] Ismail, L., Abdelmoti, A., Basu, A., Berini, A. D. E., and Naouss, M., "A systematic review of digital twin-driven predictive maintenance in industrial engineering: Taxonomy, architectural elements, and future research directions", *arXiv preprint arXiv:2509.24443*, 2025. arXiv:2509.24443v1 [cs.AI].

[2] Aivaliotis, P., Arkouli, Z., Georgoulias, K., and Makris, S., "Degradation curves integration in physics-based models: Towards the predictive maintenance of industrial robots", *Robotics and Computer-Integrated Manufacturing*, Vol. 71, p. 102177, 2021.

[3] Corchado, J., Morales, L., and Sanchez, M., "Failure analysis of industrial systems: A data-driven approach", *Journal of Failure Analysis and Prevention*, Vol. 19, pp. 200–210, 2019.

[4] Mathur, A., Cavanaugh, K. F., Pattipati, K. R., Willett, P. K., and Galie, T. R., "Reasoning and modeling systems in diagnosis and prognosis", in *Component and Systems Diagnostics, Prognosis, and Health Management* (Willett, P. K. and Kirubarajan, T., eds.), Vol. 4389, pp. 194 – 203, International Society for Optics and Photonics, SPIE, 2001.

[5] Tao, F., Qi, Q., Wang, L., and Nee, A., "Digital twins and cyber–physical systems toward smart manufacturing and industry 4.0: Correlation and comparison", *Engineering*, Vol. 5, No. 4, pp. 653–661, 2019.

[6] Van Dinter, R., Tekinerdogan, B., and Catal, C., "Predictive maintenance using digital twins: A systematic literature review", *Information and Software Technology*, Vol. 151, p. 107008, 2022.

[7] Lv, Z. and Xie, S., "Artificial intelligence in the digital twins: State of the art, challenges, and future research topics", *Digital Twin*, Vol. 1, No. 1, p. 12, 2024. Version 2; peer review: 2 approved.

[8] Kreuzer, T., Papapetrou, P., and Zdravkovic, J., "Artificial intelligence in digital twins—a systematic literature review", *Data & Knowledge Engineering*, Vol. 151, p. 102304, 2024.

[9] Chen, C., Zhao, K., Leng, J., Liu, C., Fan, J., and Zheng, P., "Integrating large language model and digital twins in the context of industry 5.0: Framework, challenges and opportunities", *Robotics and Computer-Integrated Manufacturing*, Vol. 94, p. 102982, 2025.

[10] Rojek, I., Jasiulewicz-Kaczmarek, M., Piechowski, M., and Mikolajewski, D., "An artificial intelligence approach for improving maintenance to supervise machine failures and support their repair", *Applied Sciences*, Vol. 13, No. 8, p. 4971, 2023.

[11] NASA Glenn Research Center, "User's guide for the commercial modular aero-propulsion system simulation (c-mapss)", Technical Memorandum (TM) TM-2007-214956, National Aeronautics and Space Administration (NASA), Glenn Research Center, Oct. 2007. Document ID: 20070034949.

[12] Barricelli, B. R., Casiraghi, E., and Fogli, D., "A survey on digital twin: Definitions, characteristics, applications, and design implications", *IEEE Access*, Vol. 7, pp. 167653–167671, 2019.

[13] Grieves, M. and Vickers, J., "Digital twin: Mitigating unpredictable, undesirable emergent behavior in complex systems", in *Transdisciplinary Perspectives on Complex Systems: New Findings and Approaches* (Kahlen, F.-J., Flumerfelt, S., and Alves, A., eds.), pp. 85–113, Cham: Springer International Publishing, 2017.

[14] Qi, Q. and Tao, F., "Digital twin in industry: State-of-the-art", *Computers in Industry*, Vol. 125, p. 103411, 2021.

[15] Jiang, X., Li, W., and Zhou, F., "Digital twin-driven predictive maintenance in smart manufacturing: A survey", *Journal of Manufacturing Systems*, Vol. 66, pp. 138–155, 2023.

[16] Marah, H. and Challenger, M., "Madtwin: a framework for multi-agent digital twin development: smart warehouse case study", *Annals of Mathematics and Artificial Intelligence*, Vol. 92, pp. 975–1005, August 2024.

[17] Liu, X. and Zhang, Y., "Ai-enhanced digital twin for predictive maintenance and process optimization", *Advanced Engineering Informatics*, Vol. 59, p. 102120, 2024.

[18] Boukaf, M., Fadli, F., and Meskin, N., "A comprehensive review of digital twin technology in building energy consumption forecasting", *IEEE Access*, Vol. 12, pp. 187778–187799, 2024.

[19] Kritzinger, W., Karner, M., Traar, G., Henjes, J., and Sihn, W., "Digital twin: Integrating the cyber and physical worlds", in *Proceedings of the 2018 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM)*, pp. 1711–1715, IEEE, 2018.

[20] Fuller, A., Fan, Z., Day, C., and Barlow, C., "Digital twin: Enabling technologies, challenges and open research", *IEEE Access*, Vol. 8, pp. 108952–108971, 2020.

[21] Qi, Q., Tao, F., Zuo, Y., and Zhao, D., "Enabling technologies and tools for digital twin", *Journal of Manufacturing Systems*, Vol. 58, pp. 3–21, 2021.

[22] Tao, F. and Zhang, M., "Digital twin-driven smart manufacturing: Connotation, reference model, applications and research issues", *Robotics and Computer-Integrated Manufacturing*, Vol. 61, p. 101837, 2019.

[23] Wooldridge, M. *An Introduction to Multiagent Systems*. John Wiley & Sons, 2nd ed. , 2009.

[24] Park, H. and Lee, J., "Interactive multi-agent digital twins powered by large language models", *IEEE Internet of Things Journal*, 2025.

[25] Dorri, A., Kanhere, S. S., and Jurdak, R., "Multi-agent systems: A survey", *IEEE Access*, Vol. 6, pp. 28573–28593, 2018.

[26] Bellifemine, F., Caire, G., and Greenwood, D. *Developing Multi-Agent Systems with JADE*. John Wiley & Sons, 2007.

[28] Pretel, E., Navarro, E., López-Jaquero, V., Moya, A., and González, P., "Multi-agent systems in support of digital twins: A survey", in *Bio-inspired Systems and Applications: from Robotics to Ambient Intelligence*, Vol. 13259 of *Lecture Notes in Computer Science*, pp. 524–533, Springer, 2022.

[29] Wang, Y. and Zhao, T., "A multi-agent based digital twin architecture for smart manufacturing systems", *Journal of Intelligent Manufacturing*, 2024.

[30] OpenAI, “Models – openai api documentation”, 2025. Accessed: 2025-12-16.

[31] xAI, “Welcome to xai”, 2025. Accessed: 2025-12-16.

[32] Pizon, J., Wojcik, L., and Gola, A., “Integrating large language models into digital twins for enhanced manufacturing process control”, *Management and Production Engineering Review*, Vol. 17, pp. 1–10, March 2026.

[33] Liu, F., Chen, Y., and Zhang, L., “Empowering digital twins with large language models: A new paradigm for smart manufacturing”, *Advanced Engineering Informatics*, 2025.

[34] Dihan, M. S., Akash, A. I., Tasneem, Z., Das, P., Das, S. K., Islam, M. R., Islam, M. M., Badal, F. R., Ali, M. F., Ahamed, M. H., Abhi, S. H., Sarker, S. K., and Hasan, M. M., “Digital twin: Data exploration, architecture, implementation and future”, *Heliyon*, Vol. 10, March 2024. doi: 10.1016/j.heliyon.2024.e26503.

[35] Hasan, S. K. K. and Crawford, C. W., “A new era for digital twins: progress and industry adoption”, *Digital Twin*, Vol. 2, No. 4, p. 2555877, 2025.

[36] Airbus Group, “Industrial digital twins in aerospace systems: The skywise experience”, tech. rep., Airbus Innovation Lab, 2025.

[37] Airbus, “Skywise core [x]”, 2024. Accessed: 2025-12-17.

[38] Aridi, R., Aridi, M., and Bigaud, D., “Theoretical foundations and practical values: A comprehensive review of digital twin”, *IET Digital Twins and Applications*, 2026.

[39] Bhuvanesh, R., Vinitha, M., Khurana, D. S., Shrivastava, S. K., Krishnan, R., and Parameswar, M., “A self-learning digital twin framework for continuous optimisation of energy efficiency in iot devices”, in *2026 2nd International Conference on Sustainable Computing and Integrated Communication in Changing Landscape of AI (ICSCAI)*, pp. 1–6, 2026.

[40] Croatti, A., Gabellini, M., Montagna, S., and Ricci, A., “On the integration of agents and digital twins in healthcare”, *Journal of Medical Systems*, Vol. 44, p. 161, August 2020.

[41] Gao, D., Wen, Xiaojianong Lv, J., Si, J., Wang, C., and Bao, J., “Self-evolving digital twins in flexible manufacturing: A large language model-powered multi-agent approach”, *Digital Engineering*, Vol. 10, p. 100099, 2026.

[42] Coulibaly, K. A. and Hamlich, M., “Multi-agent system-driven digital twins for predictive maintenance: architectures, technologies and open research challenges”, 2026.

[43] Patel, A., Singh, K., and Kumar, D., “Chatgpt-enabled real-time anomaly detection in digital twin environments”, *Procedia Computer Science*, Vol. 240, pp. 189–198, 2024.

[44] Yıldırım, U. and Afşer, H., “Linear methods for predictive maintenance: The case of nasa c-mapss datasets”, *Applied Sciences*, Vol. 15, No. 18, p. 9945, 2025.

[45] Tang, D., “A deep learning framework for remaining useful life prediction of turbofan engines with partial sensor failure”, *PLOS ONE*, 2026.

[46] Zhou, R., Chen, D., Jia, Z., Su, Y., Liu, Y., Lu, Y., Shi, D., *et al.*, “Digital twin ai: Opportunities and challenges from large language models to world models”, *arXiv preprint arXiv:2601.01321*, 2026.

[47] Fu, X., Qin, M., Pace, P., Savaglio, C., Li, W., and Fortino, G., “Generative ai-driven digital twin in the manufacturing internet of things: A comprehensive survey”, *IEEE Internet of Things Journal*, Vol. 13, No. 6, pp. 10522–10546, 2026.

[48] Maghanaki, M., Shahin, M., and Chen, F. F., “Large language models in manufacturing: a comprehensive review”, *The International Journal of Advanced Manufacturing Technology*, Jul 2026.

[49] Heimes, F. O., “Recurrent neural networks for remaining useful life estimation”, IEEE, 2008.

[50] Park, D., Jeong, J., Kang, J., and Shin, D., “A standards-aligned hybrid ai–digital twin framework for robust predictive maintenance under data scarcity”, *Applied Sciences*, Vol. 16, No. 11, p. 5303, 2026.

[51] Qiu, P., Yan, J., Xu, H., and Yu, Y., "Lkg-stnet: A large language model-assisted knowledge graph-guided spatiotemporal network for aero-engine remaining useful life prediction", *Advanced Engineering Informatics*, 2026.

[52] Patel, S. and Adisha, S., "Xagentmaint: Explainable agentic systems for predictive maintenance in industrial digital twin environments", in *2026 Applied Systems and Intelligence Conference Proceedings*, 2026. Evaluated on the NASA C-MAPSS turbofan degradation dataset.

[53] Li, C. and Yu, W., "Attention-enhanced lstm for rul prediction in digital twin systems", *IEEE Transactions on Industrial Informatics*, 2025.

[54] He, Q. and Guo, X., "Prediction of remaining life of aircraft engines based on bilstm-gru-attention model", *Big Data*, 2025.

[55] Zhang, L., Wen, T., Luo, Q., Xia, H., Zhang, P., and Li, Y., "Multi-statistic disentangled lstm with hidden-state feature extraction for aero-engine remaining useful life prediction", *Electronics*, Vol. 15, No. 13, p. 2867, 2026.

[56] Dong, H., Sheng, Y., Luo, S., Hu, J., and Zhou, Q., "A bidirectional cross global attention based network for aeroengine remaining useful life prediction", *Engineering Applications of Artificial Intelligence*, Vol. 165, p. 113534, 2026.

[57] Robinson, C., "Remaining useful life estimation for aircraft engines with risk-aware prediction intervals via conformalized quantile regression", *International Journal of Prognostics and Health Management*, 2026.

[58] Mo, H. and Iacca, G., "Evolutionary optimization of convolutional extreme learning machine for remaining useful life prediction", *SN Computer Science*, Vol. 5, No. 1, p. 54, 2023.

[59] Puiu, I. L. and Fortiş, T. F., "Exploring the synergies of multi-agent systems and digital twins", in *Advanced Information Networking and Applications*, Springer, 2025.

[60] Nicoletti, B. and Appolloni, A., "A digital twin framework for enhancing human–agentic ai–machine collaboration", *Journal of Intelligent Manufacturing*, 2026.

[61] Diao, R., Zhou, M., Meng, G., and Wang, S., "Turbofan engine remaining useful life prediction with reliable prediction intervals via lstm-based quantile regression and conformal calibration", *Sensors*, Vol. 26, No. 7, p. 2249, 2026.

[62] Hatipoğlu, A. and Yılmaz, E., "A matrix-statistics-aware attention mechanism for robust rul estimation in aero-engines", *Applied Sciences*, Vol. 15, 2025.

[63] Song, X., Wu, G., Wang, M., Liu, J., Wang, W., Song, M., and Lu, H., "A remaining useful life prediction method for aero-engines based on degradation-aware masked augmentation and a cnn–transformer hybrid network", *Machines*, Vol. 14, No. 8, p. 943, 2026.

[64] Mohanraj, R. and Balaji, S. N., "Digital twin technology: A comprehensive review of modeling, applications, challenges and future directions in complex system integration", *Archives of Computational Methods in Engineering*, 2026.

[65] Fan, H., Chow, E., Lu, T., Fuh, J. Y. H., Lu, W. F., and Li, B., "A unified framework for large language model-guided reinforcement learning in digital twin industrial environments", *Journal of Manufacturing Systems*, 2026.

[66] Hasan, A. and Nguyen, D. T., "Integrating agentic ai and digital twins for intelligent decision-making systems", *Array*, 2026.

Design and Implementation of a Multi-Agent Digital Twin Framework for Intelligent Monitoring, Prediction, and Decision-Making in Industrial Systems

Navid Nasiri
navidnasyry@gmail.com

2026

Department of Electrical and Computer Engineering
Isfahan University of Technology, Isfahan 84156-83111, Iran
Degree: M.Sc. Language: Farsi

Supervisor: Prof. Masoudreza Hashemi (hashemim@iut.ac.ir)
Advisor: Prof. Aref Karimi Afshar (a.karimiafshar@iut.ac.ir)

Abstract

With the increasing complexity of industrial equipment and the costs associated with unplanned downtime, developing systems for continuous condition monitoring, failure prediction, and appropriate decision execution has become essential. Despite the capability of digital twins in connecting physical assets to their virtual representations, integrating remaining useful life prediction, near-real-time monitoring, human–system interaction, and safe decision-making within scalable architectures remains a significant challenge. This research aims to design, implement, and evaluate a multi-agent digital twin framework for industrial equipment monitoring and failure prediction, leveraging deep learning and large language models. The proposed architecture consists of five layers: physical entity, data acquisition, data integration, digital twin agents, and application agents. To evaluate the framework, a digital twin of turbofan engines was developed based on the FD001 subset of NASA's CMAPSS dataset, comprising run-to-failure data from 100 training engines and 100 test engines. To investigate the effect of loss function on prediction behavior, two configurations of a three-layer LSTM-based architecture were evaluated. The baseline model, trained with MSE loss, achieved an RMSE of 15.93 and an MAE of 11.95. The second model employed an asymmetric Pinball loss function with a quantile parameter of $\tau = 0.125$, yielding an RMSE of 20.49 and an MAE of 14.72. Despite the increase in numerical error, the under-estimation ratio improved from 0.51 to 0.71, demonstrating that the asymmetric loss function successfully shifted the prediction bias toward under-estimation, albeit at the cost of higher overall error. Independent monitoring, prediction, status dashboard, and language interaction agents were also implemented to support near-real-time twin state updates, delivery of required operational information, and execution of predefined operational commands. The results indicate that the proposed framework provides a modular, interchangeable, and extensible platform for safe, interactive, and adaptable predictive maintenance, suitable for integration with other industrial assets and datasets.

Key Words: Digital Twin, Multi-Agent System, Multi-Agent Digital Twin, Large Language Model, Predictive Maintenance, Remaining Useful Life, LSTM, NASA CMAPSS, Real-Time Monitoring, Explainable Artificial Intelligence.

Isfahan University of Technology

Department of Electrical and Computer Engineering

Design and Implementation of a Multi-Agent Digital Twin Framework for Intelligent Monitoring, Prediction, and Decision-Making in Industrial Systems

by

Navid Nasiri

Evaluated and Approved by the Thesis Committee, on Jan 01, 2022

1. Masoudreza Hashemi, Prof. (Supervisor)

2. Aref Karimi Afshar, Assoc. Prof. (Advisor)